

成绩	
评阅人	
日期	2024 年 月 号

重庆邮电大学

学生实验实习报告册

学年学期： 2023-2024 学年 ☐ 春 ☒ 秋 学期

课程名称： 人工智能与大数据课程设计

学生学院： 通信与信息工程学院

专业班级： 01012205

学生学号： 2022210410

学生姓名： 雷宇航

联系电话： 18580086873

重庆邮电大学教务处制

课程名称	人工智能与大数据课程设计	课程编号	A2012050
实验地点	YF317	实验时间	2024.12.20
指导教师	胡林		
实验名称	Python 聚类-K-means		
评阅人签字		成绩	
一、实验目的 1、理解聚类非监督学习方法的基本原理。 2、掌握 Python、numpy、pandas、sklearn 实现聚类的方法。 二、实验原理 1、运用 Anaconda 搭建的 Jupyter Notebook 平台编写实例 Python 程序。 2、利用 Python、numpy、pandas、sklearn 实现 K-means 聚类。 3、编写代码，调试程序，完成实验报告。 三、使用软件平台 1、Windows 11 电脑一台。 2、Python、Anaconda、Jupyter Notebook 平台。 四、实验步骤、代码、结果及结果分析（复制代码，结果截图） 1. 实例 1：基于经纬度的城市聚类 代码： <pre>1. import pandas as pd 2. import numpy as np 3. from matplotlib import pyplot as plt 4. from sklearn.cluster import KMeans 5. from sklearn.metrics import silhouette_score, silhouette_samples 6. N_CLUSTERS = 7 # 类簇的数量 7. MARKERS = ['*', 'v', '+', '^', 's', 'x', 'o'] # 标记样式（绘图） 8. COLORS = ['r', 'g', 'm', 'c', 'y', 'b', 'orange'] # 标记颜色（绘图） 9. DATA_PATH = 'China_cities.csv' # 数据集路径 10. df = pd.read_csv(DATA_PATH) 11. df.to_excel('Cites_510.xlsx', index=False) 12. x = df.drop('省级行政区', axis=1)</pre>			

```

13.x = x.drop("城市", axis=1)
14.x_np = np.array(x)          # 将x 转化为numpy 数组
15.model = KMeans(N_CLUSTERS)  # 构建聚类器
16.model.fit(x)                # 训练聚类器
17.labels = model.labels_      # 获取聚类标签
18.plt.figure(figsize=(9, 6))
19.plt.title("Major Cities in China", fontsize=22)
20.plt.xlabel('East Longitude', fontsize=18)
21.plt.ylabel('North Latitude', fontsize=18)
22.
23.for i in range(N_CLUSTERS):
24.    members = labels == i    # members 是一个布尔型数组
25.    plt.scatter(
26.        x_np[members, 1],     # 城市经度数组
27.        x_np[members, 0],     # 城市纬度数组
28.        marker = MARKERS[i],  # 标记样式
29.        c = COLORS[i]         # 标记颜色
30.    ) # 绘制散点图
31.plt.savefig('Cities.png')
32.plt.grid()
33.plt.show()

```

输出：

省级行政区	城市	北纬	东经
北京	北京市	39.90469	116.40717
天津	天津市	39.0851	117.19937
上海	上海市	31.23037	121.4737
重庆	重庆市	29.56471	106.55073
香港特别行政区	九龙	22.327115	114.17495
香港特别行政区	新界	22.341766	114.202408
香港特别行政区	香港岛	22.266416	114.177314
澳门特别行政区	路环岛	22.116226	113.564857
澳门特别行政区	澳门半岛	22.198751	113.549134
澳门特别行政区	氹仔岛	22.156838	113.577669
台湾省	台中市	24.13862	120.67951
台湾省	台北市	25.037798	121.56517
台湾省	台南市	23.172478	120.279363
台湾省	嘉义市	23.481568	120.452538
台湾省	高雄市	22.620856	120.286795
台湾省	基隆市	25.130741	121.746248
台湾省	新北市	25.012366	121.465746
河北省	石家庄市	38.04276	114.5143
河北省	唐山市	39.63048	118.18058
河北省	秦皇岛市	39.93545	119.59964
河北省	邯郸市	36.62556	114.53918
河北省	邢台市	37.07055	114.50443
河北省	保定市	38.87396	115.46459
河北省	张家口市	40.82444	114.88755
河北省	承德市	40.9515	117.9634
河北省	沧州市	38.30441	116.83869
河北省	廊坊市	39.53775	116.68376
河北省	衡水市	37.73886	115.67054
河南省	郑州市	34.74725	113.62493
河南省	开封市	34.79726	114.30731

图1 城市经纬数据表




图 2 城市聚类图

2. 思考 1：鸢尾花聚类

代码：

```
1. ## 思考一
2. import pandas as pd
3. import numpy as np
4. from sklearn.cluster import KMeans #导入 K-Means 聚类算法模型
5. import matplotlib.pyplot as plt
6. path='./iris.data' #数据文件路径，与代码文件在同一个文件夹
7. data=pd.read_csv(path)
8. data.to_excel('flower.xlsx', index=False)
9. col_1=data["花萼长度"]
10. data_1=np.array(col_1)
11. col_2=data["花萼宽度"]
12. data_2=np.array(col_2)
13. col_3=data["花瓣长度"]
14. data_3=np.array(col_3)
15. col_4=data["花瓣宽度"]
16. data_4=np.array(col_4)
17. col_5=data["种类"]
18. data_5=np.array(col_5)
19. s="{0}\t{1:^8}\t{2:^8}\t{3:^8}\t{4:^8}\t{5:^8}"
20. print("序号\t花萼长度\t花萼宽度\t花瓣长度\t花瓣宽度\t种类")
21. for i in range(0,10):
22.     print(s.format(i,data_1[i],data_2[i],data_3[i],data_4[i],data_5[i]))
```

```

23.     print("\n\n")
24. X=[]
25. for i in range(0, len(data)):          #print (data.iloc[i]['花萼长
    度'], data.iloc[i]['花萼宽度'])
26.     X.append([data.iloc[i]['花萼长度'], data.iloc[i]['花萼宽度']])
27. X=np.array(X) #转换成 numpy array(数组)
28. plt.rcParams['font.sans-serif']=['SimHei']      #用来正常显示中文标签
29. plt.figure(1,figsize=(8,4))                  #定义图表大小
30. n=3                                           #类簇的个数k
31. km=KMeans(n_clusters=n)
32. km.fit(X)                                    #把数据和对应的分类数据放
    入聚类函数中进行聚类
33. km.labels_                                  #X 中每项所属分类的一个
    列表
34. markers = ['*', 'v', '+', '^', 's', 'x', 'o']      #图
    中显示的标识
35. for i in range(n):                          #循环 3 次(共 3 个类簇),
    画出 15 个点
36.     m=(km.labels_==i)
37.     plt.scatter(x=X[m,0],y=X[m,1],s=100,marker=markers[i],c='b',alph
    a=0.9)
38.                                     #x,y 为输入数据,s 为点大小;c 为点颜色;marker 为
    点形状;alpha 为透明度(0~1)
39. plt.xlabel("花萼长度
    ",fontsize = 20,color = 'green')              #X 轴标
    签(标题)
40. plt.ylabel("花萼宽度
    ",fontsize = 20,color = 'magenta')            #Y 轴标
    签
41. plt.title('鸢尾花按花萼聚类-510-雷宇
    航 ',family = "SimHei",fontsize = 20,color = 'red') #标题
42. plt.xticks(fontsize=16)                    #x 轴刻度值字号
43. plt.yticks(fontsize=16)                    #y 轴刻度值字号
44. plt.savefig('Flower.png', dpi=300, bbox_inches='tight')
45. plt.show()                                #显示图形

```

输出:




图 3 鸢尾花聚类图

五、碰到的问题及解决办法

对于实例 1，在输出 CSV 数据时，由于每行字符数差异，直接输出整个 CSV 或前五行会导致列对齐问题。为解决此问题，我将每列数据分别存入列表，再逐一输出这些列表，确保数据对齐。对于思考题 1，我同样采用将每列数据存入列表的方法输出。由于只能按花萼或花瓣聚类，我选择了花萼进行聚类分析。为此，我删除了花瓣相关数据，重新整合数据集后进行了聚类

六、实验心得体会

在本次实验中，我深入理解了聚类这一非监督学习方法的基本原理，并熟练掌握了 Python、NumPy、Pandas 以及 sklearn 库来实现聚类分析。同时，我对聚类技术和 Pandas 库读取数据的能力有了更深刻的认识，能够更自如地运用这些工具进行数据分析。