

成绩	
评阅人	
日期	2024 年 月 号

重庆邮电大学

学生实验实习报告册

学年学期： 2023-2024 学年 ☐ 春 ☒ 秋 学期

课程名称： 人工智能与大数据课程设计

学生学院： 通信与信息工程学院

专业班级： 01012205

学生学号： 2022210410

学生姓名： 雷宇航

联系电话： 18580086873

重庆邮电大学教务处制

课程名称	人工智能与大数据课程设计	课程编号	A2012050
实验地点	YF317	实验时间	2024.12.06
指导教师	胡林		
实验名称	Python 网络爬虫-大数据采集		
评阅人签字		成绩	
一、实验目的 1、认识数据爬虫在大数据挖掘中的重要作用。 2、掌握使用 urllib、requests、BeautifulSoup 等方法进行爬虫。 3、了解 Python 中使用 Scrapy 框架进行网络爬虫的方法。 二、实验原理 1、学习并掌握 python 在网络爬虫中常用类库的使用方法，如 requests、BeautifulSoup、urllib、openpyxl、Workbook、pandas、matplotlib 等，熟知这些库的作用及程序编写中的调用方法，理解大数据挖掘的基本思想。 2、结合之前实验内容所学方法，利用列表和字典等数据结构存储从网页中爬取下来的数据，通过切片操作分割字符串，利用文件操作保存爬取数据到文件中。 三、使用软件平台 1、Windows 11 电脑一台。 2、Python、Anaconda、Jupyter Notebook 平台。 四、实验步骤、代码、结果及结果分析（复制代码，结果截图） 1. 实例 1：爬取豆瓣小说页面的相关信息 代码： <pre>1. ## 实例一 2. import requests #用于发送HTTP 请求 3. from bs4 import BeautifulSoup #用于解析HTML 文档 4. headers={'User-Agent':'Mozilla/5.0(Windows NT6.1; Win64;x64)AppleWeb Kit/537.36(KHTML,likeGecko) Chrome/99.0.4844.74 Safari/537.36'}#设置 请求头 5. url="https://www.douban.com/tag/%E5%B0%8F%E8%AF%B4/?focus=book"# 定义 URL</pre>			

```

6. r=requests.get(url,headers=headers)
7. html=r.text #获取文本内容
8. soup=BeautifulSoup(html,"html.parser") #使用parser 实现文本解析
9. book_div=soup.find(attrs={"id":"book"})#查找id 为book 的div 元素
10. book_a=book_div.findAll(attrs={"class":"title"})# 书名
11. for book1 in book_a:
12.     print(book1.string)
13. book_b=book_div.findAll(attrs={"class":"desc"}) # 书信息
14. for book2 in book_b:
15.     print(book2.string.strip('\n'))

```

输出:

骆驼祥子
黄金时代
人间草木
苏菲的世界
阿Q正传
梦里花落知多少
回归故里
步履不停
动物园

老舍 / 人民文学出版社 / 1962-10-1 / 12.00元

王小波 / 花城出版社 / 1999-3 / 19.00元

汪曾祺 / 江苏文艺出版社 / 2005-01 / 20.00元

[挪威] 乔斯坦·贾德 / 萧宝森 / 作家出版社 / 2017-8 / 38.00元

鲁迅 著 / 丰子恺 绘 / 上海书店出版社 / 2003-7 / 14.50元

三毛 / 北京十月文艺出版社 / 2007-6 / 28.00元

[法]迪迪埃·埃里蓬 / 王献 / 上海文化出版社 / 2020-7 / 48.00元

[日] 是枝裕和 / 郑有杰 / 北京联合出版公司 / 2017-5 / 36.80元

[日] 乙一 / 张筱森 / 人民文学出版社 / 2016-8-1 / 49.80

图 1 爬取豆瓣小说页面结果




图 2 豆瓣小说页面

2. 实例 2：将爬取数据存储在文件中

代码：

```
1. ## 实例二
2. import requests
3. from bs4 import BeautifulSoup
4. from openpyxl import Workbook
5. headers={'User-Agent':'Mozilla/5.0(Windows NT6.1; Win64;x64)AppleWeb
   Kit/537.36(KHTML,likeGecko) Chrome/99.0.4844.74 Safari/537.36'}#设置
   请求头
6. url="https://www.douban.com/tag/%E5%B0%8F%E8%AF%B4/?focus=book"# 定义
   URL
7. r=requests.get(url,headers=headers)
8. html=r.text
9. soup=BeautifulSoup(html,"html.parser")
10. book_div=soup.find(attrs={"id":"book"})
11. book_a=book_div.findAll(attrs={"class":"title"})
12. book_b=book_div.findAll(attrs={"class":"desc"})
13. a,b,bb,cc,dd=[],[],[],[],[]
14. for book1 in book_a:
15.     a.append(book1.string)
16. for book1 in book_b:
17.     b.append(book1.string)
18. for i in range(len(b)):
19.     b[i]=b[i].strip('\n ').split('/')
20.     for j in range(len(b[i])):
21.         b[i][j]=b[i][j].strip(' ')
22. for i in range(len(b)):
23.     bb.extend(b[i])
```

```

24.     cc.append({'书名':a[i]})
25.     if(len(bb)==6):
26.         dd.append({'书名':cc[0]["书名"],'作者':bb[0],'译者 1':bb[1],'译者 2':bb[2],'出版社':bb[3],'出版日期':bb[4],'价格':bb[5]})
27.     elif(len(bb)==5):
28.         dd.append({'书名':cc[0]["书名"],'作者':bb[0],'译者 1':bb[1],'译者 2':',' ,'出版社':bb[2],'出版日期':bb[3],'价格':bb[4]})
29.     else:
30.         dd.append({'书名':cc[0]["书名"],'作者':bb[0],'译者 1':',' ,'译者 2':',' ,'出版社':bb[1],'出版日期':bb[2],'价格':bb[3]})
31.
32.     bb.clear()
33.     cc.clear()
34.
35. def save_excel(fin_result,tag_name,file_name):
36.     print("正在导出数据...")
37.     wb=Workbook()
38.     ws=wb.active
39.     ws.append(tag_name)
40.     for row in fin_result:
41.         ws.append(row)
42.     wb.save('{} .csv'.format(file_name))
43.
44. def get_info(page,tag):
45.     ret=[]
46.     for item in page:
47.         row=[]
48.         for page_tag in tag:
49.             row.append(item[page_tag])
50.         ret.append(row)
51.     return ret
52. tag_name=['书名','作者','译者 1','译者 2','出版社','出版日期','价格']
53. fin_result=get_info(dd,tag_name)
54. file_name=input("爬取完成, 输入要保存数据的文件名: ")
55. save_excel(fin_result,tag_name,file_name)
56. print("数据爬取并保存成功! ")

```

输出:

```

爬取完成, 输入要保存数据的文件名: pachong_510
正在导出数据...
数据爬取并保存成功!

```

图 3 存储结果

书名	作者	译者1	译者2	出版社	出版日期	价格
骆驼祥子	老舍			人民文学出版社	1962-10-1	12.00元
黄金时代	王小波			花城出版社	1999-3	19.00元
人间草木	汪曾祺			江苏文艺出版社	2005-01	20.00元
苏菲的世界	[挪威] 乔斯坦·贾德	萧宝森		作家出版社	2017-8	38.00元
阿Q正传	鲁迅 著	丰子恺 绘		上海书店出版社	2003-7	14.50元
梦里花落知多少	三毛			北京十月文艺出版社	2007-6	28.00元
回归故里	[法] 迪迪埃·埃里蓬	王献		上海文化出版社	2020-7	48.00元
步履不停	[日] 是枝裕和	郑有杰		北京联合出版公司	2017-5	36.80元
动物园	[日] 乙一	张筱森		人民文学出版社	2016-8-1	49.80

图 4 爬取数据存储在表格中

3. 思考 1：爬取自编网页美国 2014-2015 年的失业率数据

代码：

```

1. ## 思考一
2. import requests
3. from bs4 import BeautifulSoup
4. from openpyxl import Workbook
5. with open("C:\\Users\\86185\\Desktop\\专业课\\大三上\\人工智能大数据\\
   实验\\实验四\\实验四\\实验四\\unrate.htm", 'r') as wb_data:
6.     soup=BeautifulSoup(wb_data,"html.parser")
7.     book_div=soup.find(attrs={"id":"unrate_4077"})
8.     a,b,dd=[],[],[]
9.     book_a=book_div.findAll(attrs={"class":"x1644077"})
10.    book_b=book_div.findAll(attrs={"class":"x1654077"})
11.    for book1 in book_a:
12.        a.append(book1.string)
13.    for book2 in book_b:
14.        b.append(book2.string)
15.    for i in range(len(b)):
16.        dd.append({'DATE':a[i], 'VALUE':b[i]})
17. def save_excel(fin_result,tag_name,file_name):
18.     print("正在导出数据...")
19.     wb=Workbook()
20.     ws=wb.active
21.     ws.append(tag_name)
22.     for row in fin_result:
23.         ws.append(row)
24.     wb.save('{} .csv'.format(file_name))
25. def get_info(page,tag):
26.     ret=[]
27.     for item in page:
28.         row=[]
29.         for page_tag in tag:
30.             row.append(item[page_tag])
31.         ret.append(row)
32.     return ret
33. tag_name=['DATE', 'VALUE']
34. fin_result=get_info(dd,tag_name)
35. file_name=input("爬取完成，输入要保存数据的文件名：")

```

```

36.save_excel(fin_result,tag_name,file_name)
37.print("数据爬取并保存成功!")
1. ## 作图
2. import pandas as pd
3. import matplotlib.pyplot as plt
4. plt.rcParams['font.sans-serif']=['SimHei']
5. plt.figure(figsize=(16,8))
6. unrate=pd.read_excel("C:\\Users\\86185\\Desktop\\专业课\\大三上\\人工智能大数据\\实验\\实验四\\SYL_510.csv")
7. first_twelve=unrate[0:12]
8. plt.plot(first_twelve['DATE'],first_twelve['VALUE'])
9. plt.xticks(rotation=45)
10.plt.xlabel('月份',fontsize=32)
11.plt.ylabel('失业率',fontsize=32)
12.plt.title('2014 年',fontsize=32)
13.plt.tick_params(labelsize=32)
14.plt.show()

```

输出:

DATE	VALUE
2014/1/1	6.6
2014/2/1	6.7
2014/3/1	6.7
2014/4/1	6.2
2014/5/1	6.2
2014/6/1	6.1
2014/7/1	6.2
2014/8/1	6.2
2014/9/1	6
2014/10/1	5.7
2014/11/1	5.8
2014/12/1	5.6
2015/1/1	5.7
2015/2/1	5.5
2015/3/1	5.5
2015/4/1	5.4
2015/5/1	5.5
2015/6/1	5.3
2015/7/1	5.3
2015/8/1	5.1
2015/9/1	5.1
2015/10/1	5
2015/11/1	5
2015/12/1	5

图 5 爬取失业率数据




图 6 失业率数据曲线

五、碰到的问题及解决办法

在处理网页数据提取时，我们根据网页来源选择方法。对于在线网页，用 HTTP 请求加请求头（如 UA 伪装）获取 HTML；对于本地网页，直接用 with open 读取。解析 HTML 后，根据属性（如 class="title"）提取数据，并循环输出。处理本地网页时，无需网络请求和请求头设置。

六、实验心得体会

本次实验让我认识到数据爬虫在大数据挖掘中的重要性，学会了网页读取、属性代码查看，以及使用 urllib、requests、BeautifulSoup 等工具进行爬虫的基本方法。