

实验四 Python 网络爬虫-大数据采集

一、实验基本原理

运用 Jupyter notebook 平台编写实例 Python 程序。

二、实验目的：

- 1、认识数据爬虫在大数据挖掘中的重要作用。
- 2、掌握使用 urllib、requests、BeautifulSoup 等方法进行爬虫。
- 3、了解 Python 中使用 Scrapy 框架进行网络爬虫的方法。

三、具体要求：

- 1、学习并掌握 python 在网络爬虫中常用类库的使用方法,如 requests、BeautifulSoup、urllib、openpyxl、Workbook、pandas、matplotlib 等,熟知这些库的作用及程序编写中的调用方法,理解大数据挖掘的基本思想。
- 2、结合之前实验内容所学方法,利用列表和字典等数据结构存储从网页中爬取下来的数据,通过切片操作分割字符串,利用文件操作保存爬取数据到文件中。

四、实验环境：

- 1、Windows 10 电脑一台。
- 2、Anaconda、Python、Jupyter notebook 平台。

五、实验内容：

实例 1：爬取豆瓣小说页面的相关信息。

爬取豆瓣小说主页 (<https://www.douban.com/tag/小说/?focus=book>) 的 9 部小说信息,包括小说的书名、作者、译者、出版社、出版日期和价格等公开信息数据,并在 jupyter notebook 中进行输出显示。

豆瓣小说主页页面如下所示：



输出示例（先输出所有小说名称，再单独输出每部小说的其余信息）：

远大前程
鱼猎
人类群星闪耀时
我的精神家园
黄金时代
俗女养成记
罗生门
您可疑的近况
美丽新世界

[英]狄更斯 / 王科一 / 上海译文出版社 / 2011-5-1 / 26.00元

史迈 / 湖南文艺出版社 / 2022-6 / 49.00元

[奥]斯蒂芬·茨威格 / 姜乙 / 上海文艺出版社 / 2019-7 / 49.00元

王小波 / 文化艺术出版社 / 1997 / 18.80元

王小波 / 北京十月文艺出版社 / 2017-4 / 35.00元

江鹤 / 北京日报出版社 / 2021-10 / 48.00元

[日]芥川龙之介 / 赵玉皎 / 云南人民出版社 / 2015-8-7 / 68.00元

(韩)金劲旭 / 安松元 / 南海出版公司 / 2022-8 / 49

[英] 奥尔德斯·赫胥黎 / 陈超 / 上海译文出版社 / 2017-1-31 / 28

实例 2：将上题网页中爬取的数据存储到文件中。

将上题从豆瓣小说主页所爬取到的 9 部小说信息进行简单的预处理，然后保存到文件 pachong_XYY.csv 中，其中 X 是你的 1 位班号（如 4 班为 4），YY 是你的后两位学号。

输入示例：

爬取完成, 输入要保存数据的文件名：

pachong_199

输出示例：

pachong_199 - Excel

文件 开始 新建选项卡 插入 绘图 页面布局 公式 数据 审阅 视图 开发工具 百度网盘 告诉我

H19

	A	B	C	D	E	F	G
1	书名	作者	译者1	译者2	出版社	出版日期	价格
2	远大前程	[英]狄更斯	王科一		上海译文出版社	2011-5-1	26.00元
3	鱼猎	史迈			湖南文艺出版社	2022-6	49.00元
4	人类群星闪耀时	[奥]斯蒂芬·茨威格	姜乙		上海文艺出版社	2019-7	49.00元
5	我的精神家园	王小波			文化艺术出版社	1997	18.80元
6	黄金时代	王小波			北京十月文艺出版社	2017-4	35.00元
7	俗女养成记	江鹅			北京日报出版社	2021-10	48.00元
8	罗生门	[日]芥川龙之介	赵玉皎		云南人民出版社	2015-8-7	68.00元
9	您可疑的近况	[韩]金劲旭	安松元		南海出版公司	2022-8	49
10	美丽新世界	[英]奥尔德斯·赫胥黎	陈超		上海译文出版社	2017-1-31	28

Sheet

就绪 辅助功能: 一切就绪

六：思考题

爬取自编网页美国 2014-2015 年的失业率数据，保存到.csv 文件中并将数据可视化。

爬取附件里自编网页 (unrate.htm) 中的美国 2014-2015 年失业率，将数据保存到 SYL_XYY.csv (X 为 1 位班号, YYY 为后 2 位学号) 文件中，然后读入文件中的数据，将其中美国 2014 年的失业率进行数据可视化, 先输出其 DATE 与 VALUE 的值, 然后绘制曲线图。

输出示例：

SYL_199 - Excel


文件 开始 新建选项卡 插入 绘图 页面布局 公式 数据 审阅 视图 开发工具 百度网盘 告诉我

F25

	A	B	C	D	E	F	G	H
1	DATE	VALUE						
2	2014/1/1	6.6						
3	2014/2/1	6.7						
4	2014/3/1	6.7						
5	2014/4/1	6.2						
6	2014/5/1	6.2						
7	2014/6/1	6.1						
8	2014/7/1	6.2						
9	2014/8/1	6.2						
10	2014/9/1	6						
11	2014/10/1	5.7						
12	2014/11/1	5.8						
13	2014/12/1	5.6						
14	2015/1/1	5.7						
15	2015/2/1	5.5						
16	2015/3/1	5.5						
17	2015/4/1	5.4						
18	2015/5/1	5.5						
19	2015/6/1	5.3						
20	2015/7/1	5.3						
21	2015/8/1	5.1						
22	2015/9/1	5.1						
23	2015/10/1	5						
24	2015/11/1	5						
25	2015/12/1	5						

SYL_199

就绪 辅助功能: 不可用



七：实验报告要求

按照实验报告模板，提交 PDF 实验报告，包括实验目的、实验原理、代码、输出结果和分析、遇到的困难和解决办法、心得体会等。