

第 5 章

判别分析和分类分析

Discriminant Analysis and
Classification Analysis

厦门大学经济学院统计系
王亚南经济研究院
刘婧媛



目录



判别分析和分类分析介绍 定义和应用

判别分析：分类规则 两群体Fisher线性判别分析
多群体Fisher线性判别分析

分类分析：分类结果 两群体Fisher分类
两群体贝叶斯分类
多群体分类



目录




判别分析和分类分析介绍 定义和应用



判别分析和分类分析概述

例子






- ✎ 对于银行来说，最重要的是判断申请者是否能够成功还款，即将申请者分到下面两类中的一类：“能成功偿还贷款”和“不能偿还贷款”
- ✎ 这个任务包含了两个步骤：
 - 1. 判别分析 (Discriminate analysis)**：利用**历史数据**，通过这两类人的一些有区别的特征（如年龄、收入等），找到一个“最优的”规则区分这两类人
 - 2. 分类分析 (Classification analysis)**：根据新申请人的特征，将该申请人分到可能的一类中



判别分析和分类分析概述

- ✎ **判别分析**在寻找一种“分类规则”：利用变量的函数（判别函数）来描述或者解释两组或多组群体之间的区别
- ✎ **分类分析**则更偏向于给出“分类结果”：**预测**一个新观测对象的类别，或者说是**将其分配**到一个类别，利用一些规则（分类函数）评估新观测对象的测量值向量，找到该对象最有可能属于的类别
- ✎ 判别分析和分类分析的目标经常重叠，特别是判别分析的最终目的通常是分类。
- ✎ 判别分析和分类分析中，所有个体都有既定标签，即有“标准答案”可供监督，故其属于**有监督学习 (Supervised learning)**。



大学招生委员会想将申请的学生分为“有望成功毕业”和“可能无法顺利毕业”两类。

可获取的变量有：高中时不同学科的成绩、高中的排名、预科课程的数量、参加的比赛、课外活动情况等等



判别分析和分类分析概述

应用案例



精神科医生通过一组诊断测试的结果判断病人所患的精神疾病种类



人们无法从视觉上区分非洲的杀人蜂和普通的家养蜜蜂，但可以利用基于色谱峰的十个变量来区分它们



目录



判别分析和分类分析介绍 定义和应用

判别分析：分组类则

两群体Fisher线性判别分析

多群体Fisher线性判别分析

分类分析：分类结果

两群体Fisher分类

两群体贝叶斯分类

多群体分类




- 比较在两个不同制轧温度下炼的钢铁样本： Y_1 代表钢铁击穿点 (yield point)， Y_2 代表钢铁强度 (ultimate strength)。

Temperature 1	Temperature 2
55.29	46.56
52.20	48.57
59.30	45.30
52.58	47.30
52.95	47.68
	48.05
	40.40



判别分析

例子





假设：

两个群体的均值向量 $\mu_1 \neq \mu_2$ ，但具有相同的协方差矩阵 Σ

随机样本（历史数据）：

第一个 p 维样本 $y_{11}, \dots, y_{1n_1}$ 的样本均值向量 $\bar{y}_1$

第二个 p 维样本 $y_{21}, \dots, y_{2n_2}$ 的样本均值向量 $\bar{y}_2$


Fisher线性判别分析 (Fisher's linear discriminant analysis, LDA):

用来寻找两个群体间“最好”的线性组合法则，来最大限度地区分两个群体



Fisher线性判别分析

两群体情形





- ✎ Fisher线性判别分析寻找一个 p 维变量的线性组合（投影方向 $\mathbf{a}$ ），使得两组间投影后的 $\mathbf{a}'\bar{\mathbf{y}}_1$ 和 $\mathbf{a}'\bar{\mathbf{y}}_2$ 的“标准化距离”最大



✎ Fisher线性判别分析在两样本 t 检验统计量

$$t(\mathbf{a}) = \frac{\mathbf{a}'\bar{\mathbf{y}}_1 - \mathbf{a}'\bar{\mathbf{y}}_2}{\sqrt{(1/n_1 + 1/n_2)\mathbf{a}'\mathbf{S}_{pl}\mathbf{a}}}$$

中，寻找 $\mathbf{a}$ 使得 $t^2(\mathbf{a})$ 最大


✎ 结果为 $\mathbf{a} = \mathbf{S}_{pl}^{-1}(\bar{\mathbf{y}}_1 - \bar{\mathbf{y}}_2)$ ，它被称为**判别函数系数**， $\mathbf{a}'\mathbf{y}$ 被称为**Fisher判别函数**



Fisher线性判别分析

两群体情形

例：对于两个二元正态群体：






Fisher线性判别分析

两群体情形：例子

回到前面钢铁的例子，





- 如果这些点投影到 y_1 或者 y_2 轴，会出现很大程度的重叠。事实上，两个单变量 t 检验在0.05显著性水平下都不显著，因为临界值 $t_{0.025}(10) = 2.23$ ：

$$\bar{\mathbf{y}}_1 = \begin{pmatrix} 36.4 \\ 62.6 \end{pmatrix}, \quad \bar{\mathbf{y}}_2 = \begin{pmatrix} 39.0 \\ 60.4 \end{pmatrix}, \quad \mathbf{S}_{\text{pl}} = \begin{pmatrix} 7.92 & 5.68 \\ 5.68 & 6.29 \end{pmatrix}.$$

$$t_1 = \frac{\bar{y}_{11} - \bar{y}_{21}}{\sqrt{s_{11}(1/n_1 + 1/n_2)}} = -1.58,$$

$$t_2 = \frac{\bar{y}_{12} - \bar{y}_{22}}{\sqrt{s_{22}(1/n_1 + 1/n_2)}} = 1.48.$$

- 然而很明显的，两个群体可以被很好地区别开



Fisher线性判别分析

两群体情形：例子

✎ 判别函数的系数为： $\mathbf{a} = \mathbf{S}_{pl}^{-1}(\bar{\mathbf{y}}_1 - \bar{\mathbf{y}}_2) = (-1.633, 1.820)'$

✎ 判别函数 $Z = \mathbf{a}'\mathbf{y} = -1.633Y_1 + 1.820Y_2$ ，因此投影点为：

温度1	温度2
55.29	46.56
52.20	48.57
59.30	45.30
52.58	47.30
52.95	47.68
	48.05
	40.40

✎ 两组群体的分别是很明显的，上式系数代表每个变量对区分规则的贡献

✎ 如果变量的量级差距较大，我们可以首先进行标准化处理再进行判别分析



目录



判别分析和分类分析介绍 定义和应用

判别分析：分类规则

两群体Fisher线性判别分析

多群体Fisher线性判别分析

分类分析：分类结果

两群体Fisher分类

两群体贝叶斯分类

多群体分类



Fisher线性判别分析

多群体情形

重新考虑两群体的情形：找到一个向量 $\mathbf{a}$ 以最大化

$$\frac{(\bar{z}_1 - \bar{z}_2)^2}{s_z^2} = \frac{[\mathbf{a}'(\bar{\mathbf{y}}_1 - \bar{\mathbf{y}}_2)]^2}{\mathbf{a}'\mathbf{S}_{pl}\mathbf{a}} = \frac{\mathbf{a}'(\bar{\mathbf{y}}_1 - \bar{\mathbf{y}}_2)(\bar{\mathbf{y}}_1 - \bar{\mathbf{y}}_2)'\mathbf{a}}{\mathbf{a}'\mathbf{S}_{pl}\mathbf{a}}$$

组间方差

组内方差



✎ 现有 g 个群体 (Group), 对于第 k 个组 G_k , $k = 1, \dots, g$, 样本记为 $y_{k1}, \dots, y_{kn_k}$, n_k 为样本容量, $\bar{y}_k$ 为第 k 个样本均值, $\bar{y} = 1/g \sum_{k=1}^g \bar{y}_k$

✎ 目标函数:

“组间方差” 和 “组内方差” 的比值现在为

$$\frac{\mathbf{a}'\mathbf{B}\mathbf{a}}{\mathbf{a}'\mathbf{W}\mathbf{a}} = \frac{\mathbf{a}' [\sum_{k=1}^g (\bar{\mathbf{y}}_k - \bar{\mathbf{y}})(\bar{\mathbf{y}}_k - \bar{\mathbf{y}})'] \mathbf{a}}{\mathbf{a}' [\sum_{k=1}^g \sum_{i=1}^{n_k} (\mathbf{y}_{ki} - \bar{\mathbf{y}}_k)(\mathbf{y}_{ki} - \bar{\mathbf{y}}_k)'] \mathbf{a}} \quad (1)$$

✎ 因此要找到一个 $\mathbf{a}$ 以最大化 (1)



定理（多群体Fisher 线性判别）

将矩阵 $\mathbf{W}^{-1}\mathbf{B}$ 非零特征值记为 $\lambda_1, \dots, \lambda_s > 0$, 其中 $s \leq \min(g-1, p)$, 对应的特征向量为 $\mathbf{e}_1, \dots, \mathbf{e}_s$. 能最大化 (1) 的系数向量 $\mathbf{a} = \mathbf{e}_1$, 对应最大值为 λ_1 . 线性组合 $\mathbf{e}_1' \mathbf{y}$ 被称为样本第一判别式, 线性组合 $\mathbf{e}_2' \mathbf{y}$ 被称为样本第二判别式, 以此类推.



- 科考人员从加利福尼亚的砂岩中收集了原油样本。这些原油分别来自三类地层中的一类：

G_1 : Wilhelm 砂岩

G_2 : 亚Mulinia砂岩

G_3 : 上层砂岩

- 现试图基于砂岩中五种化学成分含量，找到一种划分地层类别的方法

Y_1 = 钒(每灰分百分比)

Y_2 = $\sqrt{\text{铁(每灰分百分比)}}$

Y_3 = $\sqrt{\text{铍(每灰分百分比)}}$

Y_4 = $1/[\text{饱和烃(百分比)}]$

Y_5 = 芳香烃 (百分比)



Fisher线性判别分析

多群体情形：例子

	Y_1	Y_2	Y_3	Y_4	Y_5
G1	3.9	51.0	0.20	7.06	12.19
	2.7	49.0	0.07	7.14	12.23
	2.8	36.0	0.30	7.00	11.30
	3.1	45.0	0.08	7.20	13.01
	3.5	46.0	0.10	7.81	12.63
	3.9	43.0	0.07	6.25	10.42
	2.7	35.0	0.00	5.11	9.00
G2	5.0	47.0	0.07	7.06	6.10
	3.4	32.0	0.20	5.82	4.69
	1.2	12.0	0.00	5.54	3.15
	8.4	17.0	0.07	6.31	4.55
	4.2	36.0	0.50	9.25	4.95
	4.2	35.0	0.50	5.69	2.22
	3.9	41.0	0.10	5.63	2.94
	3.9	36.0	0.07	6.19	2.27
	7.3	32.0	0.30	8.02	12.92
	4.4	46.0	0.07	7.54	5.76
	3.0	30.0	0.00	5.12	10.77
G3	6.3	13.0	0.50	4.24	8.27
	1.7	5.6	1.00	5.69	4.64
	7.3	24.0	0.00	4.34	2.99
	7.8	18.0	0.50	3.92	6.09
	7.8	25.0	0.70	5.39	6.20
	7.8	26.0	1.00	5.02	2.50
	9.5	17.0	0.05	3.52	5.71
	7.7	14.0	0.30	4.65	8.63
	11.0	20.0	0.50	4.27	8.40



- 这里矩阵 $\mathbf{W}^{-1}\mathbf{B}$ 最多有 $s = \min(g - 1, p) = 2$ 个非零特征值，计算得 4.354 和 0.559。经过中心化的Fisher线性判别式为

$$\begin{aligned} Z_1 &= 0.312(Y_1 - 6.180) - 0.710(Y_2 - 5.081) + 2.764(Y_3 - 0.511) \\ &\quad + 11.809(Y_4 - 0.201) - 0.235(Y_5 - 6.434) \\ Z_2 &= 0.169(Y_1 - 6.180) - 0.245(Y_2 - 5.081) - 2.046(Y_3 - 0.511) \\ &\quad - 24.453(Y_4 - 0.201) - 0.378(Y_5 - 6.434) \end{aligned}$$





- ✎ 对于多样本情形，组内方差 $\mathbf{W}/(n_1 + \dots + n_g - g) = \mathbf{S}_{pl}$ 是 Σ 的估计
- ✎ 多群体Fisher 's LDA可以将多维特征通过线性组合（投影）降维至相对较少的维度，这能帮助我们可视化分组情况。
- ✎ Fisher 's LDA（不论是两群体还是多群体）对分布没有要求，但要求不同群体有相同的协方差矩阵
- ✎ Fisher 's LDA为一种线性判别方法，还有很多（非线性）判别函数的构造方式。