

第 6 章

主成分分析

Principal Component Analysis (PCA)

厦门大学经济学院统计系
王亚南经济研究院
刘婧媛



英超球员综合能力评价指标

变量：
出场/首发/射门/射正/进球/
助攻/传球/过人/抢断/点球/
拦截/解围/越位/犯规/红牌/
黄牌次数、出场时间等



基于车联网的驾驶行为分析


变量：
行驶/疲劳驾驶/早晚高峰/深
夜出行/极度拥堵/高速驾驶
时长、平均/最大速度、速度
标准差、加速度、行驶里程、
平均/最大引擎转速等

经典降维方法



变量太多
怎么办？

可否用少数几个变量来代替原有变量？



- ◆ 用少数几个变量代替原有的数目庞大的变量，把重复的信息合并起来，既可以降低现有变量的维度，又不会丢失掉重要信息的思想，就称为**降维**
- ◆ 经典降维方法包括主成分分析 (Principal component analysis, PCA) 和因子分析 (Factor analysis)
 - ◆ 主成分分析主要用于构造“综合指标”，以将原始数据最大程度地区分开
 - ◆ 因子分析旨在用一个变量（公因子）代替原始高度相关的某几个变量



总体主成分分析 总体主成分推导

基于标准化变量的总体主成分分析

样本主成分分析 样本主成分推导

主成分个数的选择

R语言应用实例



 例：下表记录了52位学生6门功课的考试分数的部分数据， Y_1 到 Y_6 依次表示数学、物理、化学、语文、历史、英语成绩：

1	Y1	Y2	Y3	Y4	Y5	Y6
2	65	61	72	84	81	79
3	77	77	76	64	70	55
4	67	63	49	65	67	57
5	78	84	75	62	71	64
6	66	71	67	52	65	57
7	83	100	79	41	67	50
8	86	94	97	51	63	55
9	67	84	53	58	66	56
10	69	56	67	75	94	80
11	77	90	80	68	66	60
12	84	67	75	60	70	63
13	62	67	83	71	85	77
14	91	74	97	62	71	66
15	82	70	83	68	77	85
16	66	61	77	62	73	64
17	90	78	78	59	72	66



主成分分析思想

理解

我们希望建立一个（或几个）度量学生考试表现的**综合指标**，让我们能**尽量明显地区分学生**。那么选什么指标合适呢？

平均数/总分？

我们可以尝试通过**给各科赋予不同的权数**，从而更好地区分学生。



- 主成分分析 (Principal component analysis, PCA) 就是在所有可能的 $Y_1, \dots, Y_6$ 的线性组合模式中, 寻找一个或几个 (通常小于6个) 可以最大程度区分学生的线性组合/加权平均。





**“降维”
VS
“减肥”**

**Reduce The
Fat In Your
Data**



PCA VS LDA

- ✎ 线性判别分析(LDA)是寻求最大化两个或多个群体之间距离的线性组合
- ✎ 然而在主成分分析(PCA)中，我们只有一个群体，目标是找到一个能使这个群体中个体差异达到最大的变量线性组合

目录



主成分分析引入 核心思路


总体主成分分析 总体主成分推导

基于标准化变量的总体主成分分析

样本主成分分析 样本主成分推导

主成分个数的选择

R语言应用实例





记原始变量 $\mathbf{y} = (Y_1, \dots, Y_p)'$ ，其协方差矩阵为 Σ

主成分分析试图定义一组**互不相关**的变量，称为 $Y_1, \dots, Y_p$ 的**主成分** (Principal components, PC)，记为 $Z_1, \dots, Z_p$ ，每一个主成分都是 $Y_1, \dots, Y_p$ 的**线性组合**：

$$Z_1 = \mathbf{a}'_1 \mathbf{y} = a_{11}Y_1 + a_{12}Y_2 + \dots + a_{1p}Y_p$$

$$Z_2 = \mathbf{a}'_2 \mathbf{y} = a_{21}Y_1 + a_{22}Y_2 + \dots + a_{2p}Y_p$$

$\vdots$

$$Z_p = \mathbf{a}'_p \mathbf{y} = a_{p1}Y_1 + a_{p2}Y_2 + \dots + a_{pp}Y_p$$

求解
主成分
 $Z_1, \dots, Z_p$

即求解
 $a_1, \dots, a_p$

则 $Z_1, \dots, Z_p$ 的方差与协方差为：

$$\text{var}(Z_j) = \mathbf{a}'_j \Sigma \mathbf{a}_j, \text{ cov}(Z_j, Z_k) = \mathbf{a}'_j \Sigma \mathbf{a}_k, \quad j, k = 1, \dots, p.$$



✎ 主成分 (PC) $Z_1, \dots, Z_p$ 按照 “方差贡献度” 依次导出：

✎ 第一主成分 $Z_1 = \mathbf{a}'_1 \mathbf{y}$ ：在满足限制 $\mathbf{a}'_1 \mathbf{a}_1 = 1$ 时，最大化方差 $\text{var}(\mathbf{a}'_1 \mathbf{y})$



✎ 主成分 (PC) $Z_1, \dots, Z_p$ 按照 “方差贡献度” 依次导出：

✎ 第一主成分 $Z_1 = \mathbf{a}'_1 \mathbf{y}$ ：在满足限制 $\mathbf{a}'_1 \mathbf{a}_1 = 1$ 时，最大化方差 $var(\mathbf{a}'_1 \mathbf{y})$

✎ 第二主成分 $Z_2 = \mathbf{a}'_2 \mathbf{y}$ ：在满足限制 $\mathbf{a}'_2 \mathbf{a}_2 = 1$ ，且 $cov(\mathbf{a}'_1 \mathbf{y}, \mathbf{a}'_2 \mathbf{y}) = 0$ 时，最大化方差 $var(\mathbf{a}'_2 \mathbf{y})$



✎ 主成分 (PC) $Z_1, \dots, Z_p$ 按照 “方差贡献度” 依次导出：

✎ 第一主成分 $Z_1 = \mathbf{a}'_1 \mathbf{y}$ ：在满足限制 $\mathbf{a}'_1 \mathbf{a}_1 = 1$ 时，最大化方差 $var(\mathbf{a}'_1 \mathbf{y})$

✎ 第二主成分 $Z_2 = \mathbf{a}'_2 \mathbf{y}$ ：在满足限制 $\mathbf{a}'_2 \mathbf{a}_2 = 1$ ，且 $cov(\mathbf{a}'_1 \mathbf{y}, \mathbf{a}'_2 \mathbf{y}) = 0$ 时，最大化方差 $var(\mathbf{a}'_2 \mathbf{y})$

.....

✎ 第 j 主成分 $Z_j = \mathbf{a}'_j \mathbf{y}$ ：在满足限制 $\mathbf{a}'_j \mathbf{a}_j = 1$ ，且 $cov(\mathbf{a}'_k \mathbf{y}, \mathbf{a}'_j \mathbf{y}) = 0, k < j$ 时，最大化方差 $var(\mathbf{a}'_j \mathbf{y})$



✎ 主成分 (PC) $Z_1, \dots, Z_p$ 按照 “方差贡献度” 依次导出：

✎ 第 p 主成分 $Z_j = \mathbf{a}'_j \mathbf{y}$ ：在满足限制 $\mathbf{a}'_p \mathbf{a}_p = 1$ 时，最小化方差 $\text{var}(\mathbf{a}'_p \mathbf{y})$



定理：

记 $(\lambda_1, \mathbf{e}_1), \dots, (\lambda_p, \mathbf{e}_p)$ 为协方差矩阵 Σ 的特征值-特征向量， $\lambda_1 \geq \dots \geq \lambda_p \geq 0$ 并且特征向量 $\mathbf{e}_1, \dots, \mathbf{e}_p$ 是正交化特征向量。

则变量 $Y_1, \dots, Y_p$ 的第 j 个主成分由下式给出：

$$Z_j = \mathbf{e}_j' \mathbf{y} = e_{j1}Y_1 + e_{j2}Y_2 + \dots + e_{jp}Y_p, j = 1, \dots, p,$$

这里有 $\text{var}(Z_j) = \mathbf{e}_j' \Sigma \mathbf{e}_j = \lambda_j$
并且有 $\text{cov}(Z_j, Z_k) = \mathbf{e}_j' \Sigma \mathbf{e}_k = 0$

进一步地，我们有：

$$\sum_{j=1}^p \text{var}(Z_j) = \sum_{j=1}^p \text{var}(Y_j)$$



如何理解主成分？


✎ 例如，如果 $\mathbf{y} \sim N_p(\mathbf{0}, \Sigma)$ ，那么密度等高曲线为：

$$\mathbf{y}'\Sigma^{-1}\mathbf{y} = c^2$$

✎ 用主成分可以表示为：

$$\frac{Z_1^2}{\lambda_1} + \frac{Z_2^2}{\lambda_2} + \dots + \frac{Z_p^2}{\lambda_p} = c^2.$$

✎ 所以主成分分析将原来 $\mathbf{y}$ 的坐标系，旋转至 $Y_1, \dots, Y_p$ 的密度等高曲线的轴的方向



- ✎ 第 k 个主成分贡献的方差，占总体方差的比例可表示如下：

$$\frac{\lambda_k}{\sum_{j=1}^p \lambda_j}, \quad k = 1, \dots, p.$$

- ✎ 如果前面几个主成分可贡献总体的大部分方差/信息（如80%），那么这些主成分能够以较少的信息损失来代替原始变量

