

## 基于标准化变量的总体主成分分析



- ✎ 如果变量  $\mathbf{y} = (Y_1, \dots, Y_p)'$  的数值（由于度量单位不同等原因）差距过大，直接由协方差矩阵  $\Sigma$  生成的主成分会由方差大的变量主导
- ✎ 在这种情况下，我们对每一个变量  $Y_j$  做标准化

$$W_j = (Y_j - \mu_j) / \sqrt{\sigma_{jj}} \quad j = 1, \dots, p$$

即  $\mathbf{w} = \mathbf{D}_s^{-1}(\mathbf{y} - \boldsymbol{\mu})$ , 这里  $\mathbf{w} = (W_1, \dots, W_p)'$ ,  $\mathbf{D}_s = \text{diag}(\sqrt{\sigma_{11}}, \dots, \sqrt{\sigma_{pp}})$



✎ 由于  $cov(\mathbf{w}) = \mathbf{P}$  , 即  $\mathbf{y}$  的相关系数矩阵 , 因此对  $W_1, \dots, W_p$  进行主成分分析 , 等价于基于原变量  $Y_1, \dots, Y_p$  的 **相关系数矩阵** 进行主成分分析。

定理 :

记  $(\tilde{\lambda}_1, \tilde{\mathbf{e}}_1), \dots, (\tilde{\lambda}_p, \tilde{\mathbf{e}}_p)$  为协方差矩阵  $\mathbf{P}$  的特征值-特征向量 , 这里  $\tilde{\lambda}_1 \geq \dots \geq \tilde{\lambda}_p \geq 0$  ,  $\tilde{\mathbf{e}}_1, \dots, \tilde{\mathbf{e}}_p$  是标准化的。

于是变量  $W_1, \dots, W_p$  的第  $j$  个主成分由下式给出 :

$$V_j = \tilde{\mathbf{e}}_j' \mathbf{w} = \tilde{e}_{j1} W_1 + \tilde{e}_{j2} W_2 + \dots + \tilde{e}_{jp} W_p, j = 1, \dots, p$$

这里我们有

$$\sum_{j=1}^p var(V_j) = \sum_{j=1}^p var(W_j) = p$$



- ✎ 基于相关系数矩阵  $\mathbf{P}$  的主成分分析不受度量单位影响。
- ✎  $\mathbf{P}$  与  $\Sigma$  的特征值、特征向量是不同的，因此两组主成分的数值和方向都是不同的。一组主成分并不是另一组主成分的简单变换。
- ✎ 如果变量数值差异很大，推荐进行标准化来获得一个较平衡的数据集。

## 样本主成分分析 样本主成分推导

-  回到考试分数的案例，与其说用简单的平均数，我们更希望用一个更好的  $Y_1, Y_2, \dots, Y_6$  线性组合区分学生
-  这就是样本层面的主成分分析 (Sample PCA)

| 1  | Y1 | Y2  | Y3 | Y4 | Y5 | Y6 |
|----|----|-----|----|----|----|----|
| 2  | 65 | 61  | 72 | 84 | 81 | 79 |
| 3  | 77 | 77  | 76 | 64 | 70 | 55 |
| 4  | 67 | 63  | 49 | 65 | 67 | 57 |
| 5  | 78 | 84  | 75 | 62 | 71 | 64 |
| 6  | 66 | 71  | 67 | 52 | 65 | 57 |
| 7  | 83 | 100 | 79 | 41 | 67 | 50 |
| 8  | 86 | 94  | 97 | 51 | 63 | 55 |
| 9  | 67 | 84  | 53 | 58 | 66 | 56 |
| 10 | 69 | 56  | 67 | 75 | 94 | 80 |
| 11 | 77 | 90  | 80 | 68 | 66 | 60 |
| 12 | 84 | 67  | 75 | 60 | 70 | 63 |
| 13 | 62 | 67  | 83 | 71 | 85 | 77 |
| 14 | 91 | 74  | 97 | 62 | 71 | 66 |
| 15 | 82 | 70  | 83 | 68 | 77 | 85 |
| 16 | 66 | 61  | 77 | 62 | 73 | 64 |
| 17 | 90 | 78  | 78 | 59 | 72 | 66 |



总体主成分分析

原始变量

$$Y_1, \dots, Y_p$$



主成分


$$Z_1, \dots, Z_p$$

样本主成分分析

原始数据矩阵

$$\begin{pmatrix} y_{11} & \cdots & y_{1j} & \cdots & y_{1p} \\ \vdots & & \vdots & & \vdots \\ y_{i1} & \cdots & y_{ij} & \cdots & y_{ip} \\ \vdots & & \vdots & & \vdots \\ y_{n1} & \cdots & y_{nj} & \cdots & y_{np} \end{pmatrix}$$

$$= \mathbf{y}_i'$$



主成分数据矩阵

$$\begin{pmatrix} z_{11} & \cdots & z_{1j} & \cdots & z_{1p} \\ \vdots & & \vdots & & \vdots \\ z_{i1} & \cdots & z_{ij} & \cdots & z_{ip} \\ \vdots & & \vdots & & \vdots \\ z_{n1} & \cdots & z_{nj} & \cdots & z_{np} \end{pmatrix}$$

- 用  $\mathbf{y}_1, \dots, \mathbf{y}_n$  表示  $n$  个独立同分布的  $p$  维随机向量样本,  $\mathbf{y}_i = (y_{i1}, \dots, y_{ip})'$  样本均值向量为  $\bar{\mathbf{y}}$ , 样本协方差矩阵为  $\mathbf{S}$ , 样本相关系数矩阵为  $\mathbf{R}$ .
- 对每个样本向量, 一个线性组合可以表示为  $z_i = \mathbf{a}'\mathbf{y}_i$ , 样本均值为  $\bar{z} = \mathbf{a}'\bar{\mathbf{y}}$ , 样本方差为  $s_z^2 = \mathbf{a}'\mathbf{S}\mathbf{a}$ . 对于两个线性组合  $z_{i1} = \mathbf{a}'_1\mathbf{y}_i$  和  $z_{i2} = \mathbf{a}'_2\mathbf{y}_i$ , 它们的样本协方差是  $s_{z_1 z_2} = \mathbf{a}'_1\mathbf{S}\mathbf{a}_2$



定理：

记  $(\hat{\lambda}_1, \hat{\mathbf{e}}_1), \dots, (\hat{\lambda}_p, \hat{\mathbf{e}}_p)$  为  $\mathbf{S}$  的特征值及对应的特征向量，  
其中  $\hat{\lambda}_1 \geq \dots \geq \hat{\lambda}_p \geq 0$ ， $\hat{\mathbf{e}}_1, \dots, \hat{\mathbf{e}}_p$  经过了标准化

那么由第  $i$  个样本得到的第  $j$  个主成分为

$$z_{ij} = \hat{\mathbf{e}}_j' \mathbf{y}_i = \hat{e}_{j1} y_{i1} + \hat{e}_{j2} y_{i2} + \dots + \hat{e}_{jp} y_{ip}, j = 1, \dots, p, i = 1, \dots, n,$$

其中  $s_{z_j}^2 = \hat{\mathbf{e}}_j' \mathbf{S} \hat{\mathbf{e}}_j = \hat{\lambda}_j$ ， $s_{z_j z_k} = \hat{\mathbf{e}}_j' \mathbf{S} \hat{\mathbf{e}}_k = 0, j, k = 1, \dots, p, j \neq k$


更进一步，记  $s_{jj}$  为  $\mathbf{S}$  的第  $j$  个对角元，那么有

$$\text{样本总方差} = \sum_{j=1}^p s_{jj} = \sum_{j=1}^p \hat{\lambda}_j.$$




- ✎ 总体主成分分析中，关于利用协方差矩阵或者相关系数矩阵构造主成分的结论可类似地推广到样本主成分分析
- ✎ 观察值  $y_i$  有时用经过中心化的  $y_i - \bar{y}$  代替。这并不会对样本协方差矩阵或者相关系数矩阵有影响，所以不会改变最后得到的系数向量  $\hat{e}_j$

# 样本主成分几何解释



(a)  $\hat{\lambda}_1 > \hat{\lambda}_2$



(b)  $\hat{\lambda}_1 = \hat{\lambda}_2$

经过中心化的一系列主成分  $z_{ij} = \hat{\mathbf{e}}'_j(\mathbf{y}_i - \bar{\mathbf{y}})$ ,  $j = 1, \dots, p$ ,  $i = 1, \dots, n$  看作将原来坐标系的原点平移到  $\bar{\mathbf{y}}$ ，然后旋转坐标轴，使得坐标轴与数据最大方差方向一致

 来自25个家庭的婴儿头部测量的部分数据 (Frets 1921)

| Head<br>Length | Head<br>Breadth |
|----------------|-----------------|
| $y_1$          | $y_2$           |
| 191            | 155             |
| 195            | 149             |
| 181            | 148             |
| 183            | 153             |
| 176            | 144             |
| 208            | 157             |
| 189            | 150             |
| 197            | 159             |
| 188            | 152             |
| 192            | 150             |
| 179            | 158             |
| 183            | 147             |
| 174            | 150             |
| 190            | 159             |

$$\bar{\mathbf{y}} = \begin{pmatrix} 185.7 \\ 151.1 \end{pmatrix}, \quad \mathbf{S} = \begin{pmatrix} 95.29 & 52.87 \\ 52.87 & 54.36 \end{pmatrix}.$$

S的特征值和特征向量为：

$$\begin{aligned} \hat{\lambda}_1 &= 131.52, \quad \hat{\mathbf{e}}_1 = (0.825, 0.565)', \\ \hat{\lambda}_2 &= 18.14, \quad \hat{\mathbf{e}}_2 = (-0.565, 0.825)'. \end{aligned}$$

之所以  $\hat{\mathbf{e}}_1$  和  $\hat{\mathbf{e}}_2$  会呈现对称结构，是因为它们的正交性： $\hat{\mathbf{e}}_1' \hat{\mathbf{e}}_2 = 0$

所以经过中心化的主成分是

$$z_1 = 0.825(y_1 - 185.7) + 0.565(y_2 - 151.1)$$

$$z_2 = -0.565(y_1 - 185.7) + 0.825(y_2 - 151.1).$$


样本主成分的坐标轴可以通过令  $z_1$  和  $z_2$  为零而得到

 长轴：令  $z_2 = 0$

$$y_2 - 151.1 = \frac{0.565}{0.825}(y_1 - 185.7)$$

 短轴：令  $z_1 = 0$

$$y_2 - 151.1 = -\frac{0.825}{0.565}(y_1 - 185.7)$$



## 样本主成分分析

### 主成分个数的选择

# 主成分个数的选择



在主成分分析中，为了有效地归纳数据、达到降维目的，应该使用多少个主成分？



✎ **百分比截点法 (Percentage cutoff)** : 使用足够多的主成分来反映一定百分比 (比如80%) 的总方差



应该选比较高的百分比，这样损失的信息会少一点

但是选得太高的话，可能会高度依赖样本信息







- ✎ **平均截点 (Average cutoff)**：使用特征值大于平均特征值  $\sum_{j=1}^p \lambda_j / p$  的主成分；对使用相关矩阵做的主成分分析来说，这个平均值为1
- ✎ 平均截点准则广为使用，是很多软件包的默认准则
- ✎ 当数据能够在相对较小的维度下被很好地归纳时，特征值可以明显地分为“大特征值”和“小特征值”

# 主成分个数的选择

 **碎石图 (Scree graph)**：画出  $\lambda_j$  关于  $j$  的图像，从图上寻找能区分“大特征值”和“小特征值”的分界点





- ✎ 到现在为止，我们一直关注的是如何使用靠前面的主成分来降维和简化数据
- ✎ 然而，靠在最后的几个主成分在某些应用下也可能包含着有用的信息
- ✎ 假如最后的特征值几乎为零，那则意味着存在共线性的现象

# 样本主成分分析

 回到测试成绩的那个例子，数据包含52名学生6个学科的成绩

| 1  | Y1 | Y2  | Y3 | Y4 | Y5 | Y6 |
|----|----|-----|----|----|----|----|
| 2  | 65 | 61  | 72 | 84 | 81 | 79 |
| 3  | 77 | 77  | 76 | 64 | 70 | 55 |
| 4  | 67 | 63  | 49 | 65 | 67 | 57 |
| 5  | 78 | 84  | 75 | 62 | 71 | 64 |
| 6  | 66 | 71  | 67 | 52 | 65 | 57 |
| 7  | 83 | 100 | 79 | 41 | 67 | 50 |
| 8  | 86 | 94  | 97 | 51 | 63 | 55 |
| 9  | 67 | 84  | 53 | 58 | 66 | 56 |
| 10 | 69 | 56  | 67 | 75 | 94 | 80 |
| 11 | 77 | 90  | 80 | 68 | 66 | 60 |
| 12 | 84 | 67  | 75 | 60 | 70 | 63 |
| 13 | 62 | 67  | 83 | 71 | 85 | 77 |
| 14 | 91 | 74  | 97 | 62 | 71 | 66 |
| 15 | 82 | 70  | 83 | 68 | 77 | 85 |
| 16 | 66 | 61  | 77 | 62 | 73 | 64 |
| 17 | 90 | 78  | 78 | 59 | 72 | 66 |

 原始6个变量的样本相关系数矩阵：

```
> test<-read.table("/Users/jingyuan/快盘/Teaching/Multivariate  
Analysis/R code/Chap7/test_score.csv", sep=";", header=T)  
> (R<-round(cor(test), 3)) # sample correlation matrix
```

|    | Y1     | Y2     | Y3     | Y4     | Y5     | Y6     |
|----|--------|--------|--------|--------|--------|--------|
| Y1 | 1.000  | 0.647  | 0.696  | -0.561 | -0.456 | -0.439 |
| Y2 | 0.647  | 1.000  | 0.573  | -0.503 | -0.351 | -0.458 |
| Y3 | 0.696  | 0.573  | 1.000  | -0.380 | -0.274 | -0.244 |
| Y4 | -0.561 | -0.503 | -0.380 | 1.000  | 0.813  | 0.835  |
| Y5 | -0.456 | -0.351 | -0.274 | 0.813  | 1.000  | 0.819  |
| Y6 | -0.439 | -0.458 | -0.244 | 0.835  | 0.819  | 1.000  |



✎ 基于标准化变量（相关系数矩阵）进行主成分分析：

```
> test_PCA<-princomp(test, cor=T) # sample PCA
```

```
> summary(test_PCA, loadings=T)
```

Importance of components:

|                        | Comp.1    | Comp.2    | Comp.3     | Comp.4     | Comp.5     | Comp.6     |
|------------------------|-----------|-----------|------------|------------|------------|------------|
| Standard deviation     | 1.9261112 | 1.1236019 | 0.66395522 | 0.52009785 | 0.41172308 | 0.38309295 |
| Proportion of Variance | 0.6183174 | 0.2104135 | 0.07347275 | 0.04508363 | 0.02825265 | 0.02446003 |
| Cumulative Proportion  | 0.6183174 | 0.8287309 | 0.90220369 | 0.94728732 | 0.97553997 | 1.00000000 |

Loadings:

|    | Comp.1 | Comp.2 | Comp.3 | Comp.4 | Comp.5 | Comp.6 |
|----|--------|--------|--------|--------|--------|--------|
| Y1 | -0.412 | -0.376 | 0.216  | 0.788  |        | 0.145  |
| Y2 | -0.381 | -0.357 | -0.806 | -0.118 | 0.212  | -0.141 |
| Y3 | -0.332 | -0.563 | 0.467  | -0.588 |        |        |
| Y4 | 0.461  | -0.279 |        |        | 0.599  | 0.590  |
| Y5 | 0.421  | -0.415 | -0.250 |        | -0.738 | 0.205  |
| Y6 | 0.430  | -0.407 | 0.146  | 0.134  | 0.222  | -0.749 |

$$\sqrt{\hat{\lambda}_j}$$

$$\tilde{\lambda}_j/p$$



✎ **“loadings”**（载荷）表示主成分的载荷矩阵，由矩阵 **R** 正交的特征向量组成。每一列对应一个特征向量，即为主成分的系数。例如在这个例子中主成分可以表示为

偏科情况

$$z_1 = -0.412y_1 - 0.381y_2 - 0.332y_3 + 0.461y_4 + 0.421y_5 + 0.430y_6$$

$$z_2 = -0.376y_1 - 0.357y_2 - 0.563y_3 - 0.279y_4 - 0.415y_5 - 0.407y_6$$

均衡表现

数学

物理

化学

语文

历史

英语



- ✎ 在  $(Y_1, Y_2, Y_3)$  和  $(Y_4, Y_5, Y_6)$  两组中,  $z_1$  包含相反的符号和相似的量级, 反映了文理科的偏科现象。典型学生为6,7,45,30,49号

```
> test[c(6,7,45,30,49),]  
      Y1  Y2  Y3  Y4  Y5  Y6  
6   83 100  79  41  67  50  
7   86  94  97  51  63  55  
45  99 100  99  53  63  60  
30  64  61  49 100  99  95  
49  52  62  65 100  96 100
```

- ✎ 在  $z_2$  中, 所有变量的符号相同, 反映了文理科的均衡表现。典型学生为26,33,8号

```
> test[c(26,33,8),]  
      Y1  Y2  Y3  Y4  Y5  Y6  
26  87  84 100  74  81  76  
33  86  78  92  87  87  77  
8   67  84  53  58  66  56
```



✎ 我们可以进一步探索这些典型学生的样本主成分取值/得分：

```
> # sample principal components of the typical students  
> samplePC<-(round(test_PCA$scores,3))[c(6,7,45,30,49,26,33,8),]  
> rownames(samplePC)<-c(6,7,45,30,49,26,33,8)  
> samplePC
```

理科 > 文科

文科 > 理科

|    | Comp.1 | Comp.2 | Comp.3 | Comp.4 | Comp.5 | Comp.6 |
|----|--------|--------|--------|--------|--------|--------|
| 6  | -3.518 | 0.820  | -1.072 | -0.156 | -0.763 | -0.166 |
| 7  | -3.516 | -0.104 | 0.101  | -0.574 | -0.011 | 0.080  |
| 45 | -3.975 | -1.054 | 0.147  | 0.349  | 0.252  | -0.049 |
| 30 | 4.490  | -0.693 | -0.620 | 0.832  | -0.054 | 0.029  |
| 49 | 4.622  | -0.997 | -0.236 | -0.724 | 0.289  | -0.465 |
| 26 | -0.841 | -2.117 | 0.544  | -0.156 | -0.070 | 0.192  |
| 33 | 0.345  | -2.187 | 0.414  | 0.225  | 0.018  | 0.854  |
| 8  | -0.982 | 2.326  | -1.292 | -0.017 | 0.093  | -0.052 |

总成绩高


总成绩低



✎ 上述的主成分得分也可以通过预测现有的样本数据获得：

```
> # another way to obtain the sample principal components  
> samplePC2<-round(predict(test_PCA),3) [c(6,7,45,30,49,26,33,8),]  
> rownames(samplePC2)<-c(6,7,45,30,49,26,33,8)  
> samplePC2
```

|    | Comp.1 | Comp.2 | Comp.3 | Comp.4 | Comp.5 | Comp.6 |
|----|--------|--------|--------|--------|--------|--------|
| 6  | -3.518 | 0.820  | -1.072 | -0.156 | -0.763 | -0.166 |
| 7  | -3.516 | -0.104 | 0.101  | -0.574 | -0.011 | 0.080  |
| 45 | -3.975 | -1.054 | 0.147  | 0.349  | 0.252  | -0.049 |
| 30 | 4.490  | -0.693 | -0.620 | 0.832  | -0.054 | 0.029  |
| 49 | 4.622  | -0.997 | -0.236 | -0.724 | 0.289  | -0.465 |
| 26 | -0.841 | -2.117 | 0.544  | -0.156 | -0.070 | 0.192  |
| 33 | 0.345  | -2.187 | 0.414  | 0.225  | 0.018  | 0.854  |
| 8  | -0.982 | 2.326  | -1.292 | -0.017 | 0.093  | -0.052 |





- ✎ **构建综合指标**：主成分分析主要用于构建综合指标来区分目标群体，例如构建顾客各种消费行为的综合指标来进行客户分级
- ✎ **数据降维**：通常我们会用少于原始变量数的主成分来描述尽可能多的数据差异，特别是当原始变量维度很高时，可达到降维目的
- ✎ **数据可视化**：当原始变量维度很高时，可采用第一、第二主成分散点图来直观表述数据特征，例如数据聚类信息等
- ✎ **变量压缩、重构**：由“重要的”主成分重构原始变量，可以去除原始数据中冗余的噪音，突出数据的特征，例如人脸识别。

# 总结和课后思考



- ✎ 主成分分析的目的是什么？
- ✎ 如何推导总体和样本主成分？
- ✎ 如何在几何层面解释主成分？
- ✎ 通过协方差矩阵和相关系数矩阵计算得出的主成分有什么不同点？