

第 8 章

聚类分析

Cluster Analysis

厦门大学经济学院统计系
王亚南经济研究院
刘婧媛



目录



聚类分析概述

直观理解

相似度的度量

层次聚类

简介

不同层次聚类方法

族群个数的选择

R语言示例

k-均值聚类

方法介绍

R语言示例



目录



聚类分析概述

直观理解

相似程度的度量

层次聚类

简介

不同层次聚类方法

族群个数的选择

R语言示例

k-均值聚类

方法介绍

R语言示例



聚类分析的直观理解



An intelligent being cannot treat every object it sees as a unique entity unlike anything else in the universe. It has to put objects in categories so that it may apply its hard-won knowledge about similar objects in the past to the object at hand.

— Pinker 1997

wù yǐ lèi jù
物以类聚，
rén yǐ qún fēn
人以群分

“智者观物，固非以一物视之，别之以类，格而致知，推而及其他者也。”




聚类分析的直观理解


- ✎ 在科学研究、社会调查、甚至是日常生活中，我们有时需要通过观察个体的特征，将群体中的个体归为不同的族群/簇（Cluster）
 - ✎ 在市场营销中，基于历史交易信息、消费者背景等对顾客进行划分，从而对不同类型的消费者实施不同的营销策略
 - ✎ 在金融领域，为获得较为平衡的投资组合，需要首先基于一系列金融表现变量（如回报率、波动率、市场资本等）对投资产品（如股票）进行归类
 - ✎ 同样的归类思想也可以应用于天文学、考古学、医学、化学、教育学、心理学、语言学和社会学等
- ✎ 以上的归类过程均称为**聚类分析（Cluster analysis）**



聚类 vs 分类



精准营销：聚类



银行征信：分类



聚类 vs 分类

- ✎ 在分类分析中，个体的类别标签固有存在，只是对于新观测个体暂时未知，分类过程旨在根据其特征预测预测类别，后续可知是否预测准确，故属于**有监督学习(supervised learning)**
- ✎ 在聚类分析中，类别的个数及个体标签本身并不存在，只是根据个体特征的相似性形成“合理”的聚集，并无“正确答案”参考，故其属于**无监督学习(unsupervised learning)**



目录



聚类分析概述

直观理解

相似程度的度量

层次聚类

简介

不同层次聚类方法

族群个数的选择

R语言示例

k-均值聚类


方法介绍

R语言示例



聚类分析 vs 相似度

- 合理的聚类方式应使得同一族群内的观测尽可能地“相似”，但不同族群之间有明显区分
- 如何刻画“相似度”？



“距离”越
小越相似



相似度的度量——距离

回顾两个 p 维观测个体 $\mathbf{x} = (x_1, \dots, x_p)'$ 和 $\mathbf{y} = (y_1, \dots, y_p)'$, 它们之间的距离可以由以下几种常用方式度量

欧式距离 (Euclidean distance) : $d(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})'(\mathbf{x} - \mathbf{y})} = \sqrt{\sum_j (x_j - y_j)^2}$

~~马氏距离 (Mahalanobis distance) : $d(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})' \mathbf{S}^{-1} (\mathbf{x} - \mathbf{y})}$~~

Minkowski测度 (Minkowski metric) : $d(\mathbf{x}, \mathbf{y}) = \left(\sum_j |x_j - y_j|^m \right)^{1/m}$

Canberra测度 (Canberra metric) : $d(\mathbf{x}, \mathbf{y}) = \sum_j |x_j - y_j| / (x_j + y_j)$

对于 n 个样本观测 $\mathbf{y}_1, \dots, \mathbf{y}_n$, 可计算**距离矩阵 (Distance/Proximity matrix)**, $\mathbf{D} = (d_{ij})$, 这里 $d_{ij} = d(\mathbf{y}_i, \mathbf{y}_j)$



相似度的度量——距离

距离矩阵：例子

例：20位志愿者的三围数据：

```
> library(HSAUR2)
> measure
      chest waist hips gender
1       34    30   32   male
2       37    32   37   male
3       38    30   36   male
4       36    33   39   male
5       38    29   33   male
6       43    32   38   male
7       40    33   42   male
8       38    30   40   male
9       40    30   37   male
10      41    32   39   male
11      36    24   35 female
12      36    25   37 female
13      34    24   37 female
14      33    22   34 female
15      36    26   38 female
16      37    26   37 female
17      34    25   38 female
18      36    26   37 female
19      38    28   40 female
20      35    23   35 female
```




相似度的度量——距离

距离矩阵：例子

```
> dm <- dist(measure[, c("chest", "waist", "hips")])  
> round(dm, 2)
```

	1	2	3	4	5	6	7	8	9	10	11	12
2	6.16											
3	5.66	2.45										
4	7.87	2.45	4.69									
5	4.24	5.10	3.16	7.48								
6	11.00	6.08	5.74	7.14	7.68							
7	12.04	5.92	7.00	5.00	10.05	5.10						
8	8.94	3.74	4.00	3.74	7.07	5.74	4.12					
9	7.81	3.61	2.24	5.39	4.58	3.74	5.83	3.61				
10	10.10	4.47	4.69	5.10	7.35	2.24	3.32	3.74	3.00			
11	7.00	8.31	6.40	9.85	5.74	11.05	12.08	8.06	7.48	10.25		
12	7.35	7.07	5.48	8.25	6.00	9.95	10.25	6.16	6.40	8.83	2.24	
13	7.81	8.54	7.28	9.43	7.55	12.08	11.92	7.81	8.49	10.82	2.83	2.24
14	8.31	11.18	9.64	12.45	8.66	14.70	15.30	11.18	11.05	13.75	3.74	5.20
15	7.48	6.16	4.90	7.07	6.16	9.22	9.00	4.90	5.74	7.87	3.61	1.41
16	7.07	6.00	4.24	7.35	5.10	8.54	9.11	5.10	5.00	7.48	3.00	1.41
17	7.81	7.68	6.71	8.31	7.55	11.40	10.77	6.71	7.87	9.95	3.74	2.24
18	6.71	6.08	4.58	7.28	5.39	9.27	9.49	5.39	5.66	8.06	2.83	1.00
19	9.17	5.10	4.47	5.48	7.07	6.71	5.74	2.00	4.12	5.10	6.71	4.69
20	7.68	9.43	7.68	10.82	7.00	12.41	13.19	9.11	8.83	11.53	1.41	3.00



目录



聚类分析概述

直观理解

相似程度的度量

层次聚类

简介

不同层次聚类方法

族群个数的选择

R语言示例

k-均值聚类

方法介绍

R语言示例



层次聚类



- 定义了距离之后，怎样找到“合理”的规则，使相似的/距离小的个体聚成一个族群？
- 考虑所有的群组组合显然在计算上很难实现，所以一种常用的聚类方法为**层次聚类/系统聚类（hierarchical clustering）**



✎ 层次聚类有两个方向：

- **凝聚法 (Agglomerative clustering)**：由单个个体开始，逐步将最“相似”的个体连结起来，直到所有个体都合并为一个族群
- **分离层次法 (Divisive clustering)**：凝聚法的相反方向





✎ 我们主要讨论凝聚法



层次聚类

系统树图

✎ 层次聚类过程的结果可以利用图表展示为**系统树图 (Dendrogram)**



系统树图显示了层次聚类的每一个步骤及其结果，包括合并族群带来的距离的变化