

# 1. 《数据分析基础》习题 2.1

---

2.1 写出下列回归模型的矩阵形式

$$(1) y_i = \beta_1 x_{i1} + \beta_2 x_{i1}^2 + \varepsilon_i, i = 1, 2, \dots, n;$$


$$(2) \sqrt{y_i} = \beta_0 + \beta_1 \ln x_{i1} + \beta_2 x_{i2} + \beta_3 (x_{i1} + \sin x_{i2}) + \varepsilon_i, i = 1, 2, \dots, n.$$



解:  $Y = X\beta + \varepsilon$

$$(1) \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12}^2 \\ x_{21} & x_{22}^2 \\ \vdots & \vdots \\ x_{n1} & x_{n2}^2 \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

$$(2) \begin{bmatrix} \sqrt{y_1} \\ \sqrt{y_2} \\ \vdots \\ \sqrt{y_n} \end{bmatrix} = \begin{bmatrix} 1 & \ln x_{11} & x_{12} & x_{11} + \sin x_{12} \\ 1 & \ln x_{21} & x_{22} & x_{21} + \sin x_{22} \\ 1 & \vdots & \vdots & \vdots \\ 1 & \ln x_{n1} & x_{n2} & x_{n1} + \sin x_{n2} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$



## 2. 《数据分析基础》习题 2.2 (1)

1. 对于过原点的简单线性回归模型

$$y_i = \beta x_i + \varepsilon_i, \quad i = 1, 2, \dots, n$$

设  $\varepsilon_i (i = 1, 2, \dots, n)$  相互独立且服从  $N(0, \sigma^2)$  的分布。

(1) 求  $\beta$  的最小二乘估计。

(2) 该估计是否为  $\beta$  的无偏估计？

解：(1)  $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$

模型的矩阵形式为：

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \beta + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$



残差平方和：
$$S(\beta) = \sum_{i=1}^n (\varepsilon_i)^2 = \sum_{i=1}^n (y_i - \beta x_i)^2$$

$$\frac{\partial S(\beta)}{\partial \beta} = -2 \sum_{i=1}^n (y_i - \beta x_i) x_i = 0$$

$$\beta \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2} = \frac{X^T Y}{X^T X} = \frac{X^T (X\beta + \varepsilon)}{X^T X} = \beta + \frac{X^T \varepsilon}{X^T X}$$

因此， $\beta$  的最小二乘估计为  $\hat{\beta} = \beta + \frac{X^T \varepsilon}{X^T X}$ 。

$$(2) \quad E(\hat{\beta}) = E\left(\beta + \frac{X^T \varepsilon}{X^T X}\right) = E(\beta) + E\left(\frac{X^T \varepsilon}{X^T X}\right) = \beta + E\left(\frac{X^T}{X^T X}\right) E(\varepsilon) = \beta$$

因此， $\hat{\beta}$  是  $\beta$  的无偏估计。

### 3. 《数据分析基础》求主成分

---

求总体协方差矩阵为  $A = \begin{vmatrix} 3 & -1 \\ -1 & 3 \end{vmatrix}$  的主成分 & 贡献率？



# 主成分分析的实质

---

□ 就是要求出方差—协方差矩阵的**特征向量**及其对应的**特征值**，即要找出方差—协方差矩阵所确定的**椭圆的主轴**，并确定其**长度**。



# 特征向量 & 特征值 求解

定义1: 设  $A$  是  $n$  阶方阵, 若存在数  $\lambda$  和非零向量  $x$ ,

$$\text{使得 } Ax = \lambda x \ (x \neq 0)$$

则称  $\lambda$  是  $A$  的一个特征值,

$x$  为  $A$  的对应于特征值  $\lambda$  的特征向量。

$$\text{或 } (\lambda E - A)x = 0$$

$$\text{由 } Ax = \lambda x$$

$$\text{行列式 } |\lambda E - A| = 0$$

$$\Rightarrow (A - \lambda E)x = 0$$

$$(*_{\lambda})$$

而  $x \neq 0$ , 即齐次线性方程组  $(*_{\lambda})$  有非零解

$$\Leftrightarrow |A - \lambda E| = 0$$

求  $A$  的特征值  $\lambda$  就是求  $|A - \lambda I| = 0$  的根  $\lambda$ ,

求  $A$  的相应于  $\lambda$  的特征向量就是求  $|A - \lambda I|x = 0$

的非零解向量.

例 求  $A = \begin{pmatrix} 3 & -1 \\ -1 & 3 \end{pmatrix}$  的特征值和特征向量

解  $A$  的特征多项式为

$$\begin{vmatrix} 3-\lambda & -1 \\ -1 & 3-\lambda \end{vmatrix} = (3-\lambda)^2 - 1 \\ = 8 - 6\lambda + \lambda^2 = (4-\lambda)(2-\lambda)$$

所以  $A$  的特征值为  $\lambda_1=4, \lambda_2=2$

当  $\lambda_2=2$  , 对应的特征向量应满足

$$\begin{pmatrix} 3-2 & -1 \\ -1 & 3-2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$



单位向量  
求解

即 
$$\begin{cases} x_1 - x_2 = 0, \\ -x_1 + x_2 = 0. \end{cases}$$

解得  $x_1 = x_2$ , 所以对应的特征向量可取为  $p_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ .

单位向量:  $e_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$

故相应于  $\lambda_2 = 2$  全体特征向量为  $k * e_1 (k \neq 0)$

当  $\lambda_1 = 4$  由

$$\begin{pmatrix} 3-4 & -1 \\ -1 & 3-4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \text{即} \begin{pmatrix} -1 & -1 \\ -1 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

解得  $x_1 = -x_2$ , 所以对应的特征向量可取为  $p_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$ .

单位向量:  $e_2 = \begin{pmatrix} \frac{-1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$

故相应于  $\lambda_1 = 4$  的全体特征向量为  $k * e_2 (k \neq 0)$

贡献率: 第1主成分  $= \frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{2}{3}$

贡献率: 第2主成分  $= \frac{\lambda_2}{\lambda_1 + \lambda_2} = \frac{1}{3}$

## 4. 《数据分析基础》习题 4.1

---

设总体  $\mathbf{X} = (X_1, X_2, X_3)^T$  的协方差矩阵为

$$\Sigma = \begin{bmatrix} \sigma^2 & \sigma^2 \rho & 0 \\ \sigma^2 \rho & \sigma^2 & \sigma^2 \rho \\ 0 & \sigma^2 \rho & \sigma^2 \end{bmatrix}, \quad |\rho| < \frac{1}{2}$$

- (1) 求  $\mathbf{X}$  的主成分。
- (2) 求各主成分的贡献率。

设总体  $\mathbf{X} = (X_1, X_2, X_3)^T$  的协方差矩阵为

$$\Sigma = \begin{bmatrix} \sigma^2 & \sigma^2 \rho & 0 \\ \sigma^2 \rho & \sigma^2 & \sigma^2 \rho \\ 0 & \sigma^2 \rho & \sigma^2 \end{bmatrix}, \quad |\rho| < \frac{1}{\sqrt{2}}$$

- (1) 求  $\mathbf{X}$  的主成分。
- (2) 求各主成分的贡献率。

解：

$$\begin{aligned} |\lambda E - \Sigma| &= \begin{vmatrix} \lambda - \sigma^2 & -\sigma^2 \rho & 0 \\ -\sigma^2 \rho & \lambda - \sigma^2 & -\sigma^2 \rho \\ 0 & -\sigma^2 \rho & \lambda - \sigma^2 \end{vmatrix} \\ &\stackrel{c_1 - c_3}{=} \begin{vmatrix} \lambda - \sigma^2 & -\sigma^2 \rho & 0 \\ 0 & \lambda - \sigma^2 & -\sigma^2 \rho \\ -\lambda + \sigma^2 & -\sigma^2 \rho & \lambda - \sigma^2 \end{vmatrix} \stackrel{r_1 + r_3}{=} \begin{vmatrix} 0 & -2\sigma^2 \rho & \lambda - \sigma^2 \\ 0 & \lambda - \sigma^2 & -\sigma^2 \rho \\ -\lambda + \sigma^2 & -\sigma^2 \rho & \lambda - \sigma^2 \end{vmatrix} \\ &= (-\lambda + \sigma^2) \begin{vmatrix} -2\sigma^2 \rho & \lambda - \sigma^2 \\ \lambda - \sigma^2 & -\sigma^2 \rho \end{vmatrix} = (-\lambda + \sigma^2) [2\sigma^4 \rho^2 - (\lambda - \sigma^2)^2] \end{aligned}$$

令  $\det(\lambda E - \Sigma) = |\lambda E - \Sigma| = 0$ ，有

$$(-\lambda + \sigma^2) [2\sigma^4 \rho^2 - (\lambda - \sigma^2)^2] = 0$$

可求解得从大到小排序后的特征值，

$$\lambda_1 = (1 + \sqrt{2}\rho)\sigma^2, \quad \lambda_2 = \sigma^2, \quad \lambda_3 = (1 - \sqrt{2}\rho)\sigma^2$$

$\lambda_1$

对于  $\lambda_1 = (1 + \sqrt{2}\rho)\sigma^2$ , 解  $(\lambda_1 E - \Sigma)X = 0$ , 得

$$\begin{pmatrix} \sqrt{2}\rho\sigma^2 & -\sigma^2\rho & 0 \\ -\sigma^2\rho & \sqrt{2}\rho\sigma^2 & -\sigma^2\rho \\ 0 & -\sigma^2\rho & \sqrt{2}\rho\sigma^2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = 0$$

$$\Leftrightarrow \begin{cases} \sqrt{2}\rho\sigma^2 x_1 - \sigma^2\rho x_2 = 0 \\ -\sigma^2\rho x_1 + \sqrt{2}\rho\sigma^2 x_2 - \sigma^2\rho x_3 = 0 \\ -\sigma^2\rho x_2 + \sqrt{2}\rho\sigma^2 x_3 = 0 \end{cases}$$

解上面的方程可得:

$$\xi_1 = \begin{bmatrix} 1 \\ \sqrt{2} \\ 1 \end{bmatrix}, \quad e_1 = \begin{bmatrix} \frac{1}{2} \\ \frac{1}{\sqrt{2}} \\ \frac{1}{2} \end{bmatrix}$$

$\lambda_2$

对于  $\lambda_2 = \sigma^2$ , 解  $(\lambda_2 E - \Sigma)X = 0$ , 得

$$\xi_2 = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, \quad e_2 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ 0 \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$$

对于  $\lambda_3 = (1 - \sqrt{2}\rho)\sigma^2$ , 解  $(\lambda_3 E - \Sigma)X = 0$ , 得

$\lambda_3$

$$\xi_3 = \begin{bmatrix} 1 \\ \sqrt{2} \\ 1 \end{bmatrix}, \quad e_3 = \begin{bmatrix} \frac{1}{2} \\ \frac{1}{\sqrt{2}} \\ \frac{1}{2} \end{bmatrix}$$

根据上面求解到的特征值和特征向量，主成分及相应的贡献率为，

$$\text{第一主成分: } Y_2 = \frac{1}{2}X_1 + \frac{1}{\sqrt{2}}X_2 + \frac{1}{2}X_3 \quad \text{贡献率: } \frac{(1+\sqrt{2}\rho)\sigma^2}{3\sigma^2} = \frac{(1+\sqrt{2}\rho)}{3}$$

$$\text{第二主成分: } Y_1 = \frac{1}{\sqrt{2}}X_1 - \frac{1}{\sqrt{2}}X_3 \quad \text{贡献率: } \frac{\sigma^2}{3\sigma^2} = \frac{1}{3}$$

$$\text{第三主成分: } Y_3 = \frac{1}{2}X_1 - \frac{1}{\sqrt{2}}X_2 + \frac{1}{2}X_3 \quad \text{贡献率: } \frac{(1-\sqrt{2}\rho)\sigma^2}{3\sigma^2} = \frac{(1-\sqrt{2}\rho)}{3}$$

## 5. 《数据分析基础》习题 4.2 (1)

---

设总体  $\mathbf{X} = (X_1, X_2, X_3)^T$  的相关系数矩阵为

$$\rho = \begin{bmatrix} 1 & \rho & \rho \\ \rho & 1 & \rho \\ \rho & \rho & 1 \end{bmatrix}, \quad \rho > 0$$

- (1) 求  $\mathbf{X}$  的标准化变量的主成分。
- (2) 求标准化后各主成分的贡献率。



设总体  $\mathbf{X} = (X_1, X_2, X_3)^T$  的相关系数矩阵为

$$\rho = \begin{bmatrix} 1 & \rho & \rho \\ \rho & 1 & \rho \\ \rho & \rho & 1 \end{bmatrix}, \quad \rho > 0$$

(1) 求  $\mathbf{X}$  的标准化变量的主成分。

(2) 求标准化后各主成分的贡献率。

解：令  $\det(\lambda E - \Sigma) = |\lambda E - \Sigma| = |\Sigma - \lambda E| = 0$ ;

求特征值，

行列式中一行(or列) 所有元素乘以一个数后加到另一行(or列)，行列式值不变

$$\begin{aligned} \begin{vmatrix} 1-\lambda & \rho & \rho \\ \rho & 1-\lambda & \rho \\ \rho & \rho & 1-\lambda \end{vmatrix} &= \begin{vmatrix} 1-\lambda & \rho & \rho \\ \rho & 1-\lambda & \rho \\ 0 & \rho - (1-\lambda) & 1-\lambda-\rho \end{vmatrix} = \begin{vmatrix} 1-\lambda & 2\rho & \rho \\ \rho & 1-\lambda+\rho & \rho \\ 0 & 0 & 1-\lambda-\rho \end{vmatrix} \\ &= (1-\lambda-\rho) \begin{vmatrix} 1-\lambda & 2\rho \\ \rho & 1-\lambda+\rho \end{vmatrix} = (1-\lambda-\rho)((1-\lambda)(1-\lambda+\rho) - 2\rho^2) \\ &= (1-\lambda-\rho)(\lambda^2 - (2+\rho)\lambda - 2\rho^2 + \rho + 1) = (1-\lambda-\rho)(1-\lambda+2\rho)(1-\lambda-\rho), \end{aligned}$$

可以得到：

$$\lambda_1 = 1 + 2\rho, \quad \lambda_2 = \lambda_3 = 1 - \rho;$$

行列式等于其任意某行（或某列）的各元素与其对应代数余子式乘积之和。代数余子式如下：

$$A_{ij} = (-1)^{i+j} M_{ij}$$



设总体  $\mathbf{X} = (X_1, X_2, X_3)^T$  的相关系数矩阵为

$$\boldsymbol{\rho} = \begin{bmatrix} 1 & \rho & \rho \\ \rho & 1 & \rho \\ \rho & \rho & 1 \end{bmatrix}, \quad \rho > 0$$

- (1) 求  $\mathbf{X}$  的标准化变量的主成分。
- (2) 求标准化后各主成分的贡献率。

解：令  $\det(\lambda E - \Sigma) = |\lambda E - \Sigma| = 0$

可求解得特征值，

$$\lambda_1 = 1 + 2\rho, \quad \lambda_2 = \lambda_3 = 1 - \rho$$

对于  $\lambda_1 = 1 + 2\rho$ ，解  $|\lambda_1 E - \Sigma| = 0$ ，得



$$\xi_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \quad e_1 = \begin{bmatrix} 0.5774 \\ 0.5774 \\ 0.5774 \end{bmatrix}$$

对于  $\lambda_2 = \lambda_3 = 1 - \rho$ ，分别解  $|\lambda_2 E - \Sigma| = 0$  和  $|\lambda_3 E - \Sigma| = 0$ ，得

$\xi_2$  &  $\xi_3$  非正交向量

$$\xi_2 = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}, \quad \xi_3 = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

是否正交向量  
=> 判断内积=0 (?)

施密特  
(Schmidt)  
正交化公式

正交化得， $\eta_2 = \xi_2$ ， $\eta_3 = \xi_3 - \frac{(\xi_3, \eta_2)}{(\eta_2, \eta_2)} \eta_2 = \begin{bmatrix} \frac{1}{2} \\ \frac{1}{2} \\ -1 \end{bmatrix}$

标准化得,  $e_2 = \begin{bmatrix} 0.7071 \\ -0.7071 \\ 0 \end{bmatrix}$ ,  $e_3 = \begin{bmatrix} 0.4082 \\ 0.4082 \\ -0.8165 \end{bmatrix}$

主成分:

$$Y_1 = e_1^T X = 0.5774X_1 + 0.5774X_2 + 0.5774X_3$$

$$Y_2 = e_2^T X = 0.7071X_1 - 0.7071X_2$$

$$Y_3 = e_3^T X = 0.4082X_1 + 0.4082X_2 - 0.8165X_3$$

(2) 根据上面求解到的主成分, 对应的贡献率分别为,

第一主成分贡献率:  $\frac{1+2\rho}{3}$

第二主成分贡献率:  $\frac{1-\rho}{3}$

第三主成分贡献率:  $\frac{1-\rho}{3}$

## 6. 《数据分析基础》判别分析

设有两个正态总体  $G_1$  和  $G_2$ ，已知：

$$\mu^{(1)} = \begin{bmatrix} 10 \\ 15 \end{bmatrix}, \quad \mu^{(2)} = \begin{bmatrix} 20 \\ 25 \end{bmatrix}, \quad \Sigma_1 = \begin{pmatrix} 18 & 12 \\ 12 & 32 \end{pmatrix}, \quad \Sigma_2 = \begin{pmatrix} 20 & -7 \\ -7 & 5 \end{pmatrix},$$

试用距离判别法判断：样品：  $X = \begin{bmatrix} 20 \\ 20 \end{bmatrix}$ ，应归属于哪一类？



设有两个正态总体  $G_1$  和  $G_2$ ，已知：

$$\mu^{(1)} = \begin{bmatrix} 10 \\ 15 \end{bmatrix}, \quad \mu^{(2)} = \begin{bmatrix} 20 \\ 25 \end{bmatrix}, \quad \Sigma_1 = \begin{pmatrix} 18 & 12 \\ 12 & 32 \end{pmatrix}, \quad \Sigma_2 = \begin{pmatrix} 20 & -7 \\ -7 & 5 \end{pmatrix},$$

试用距离判别法判断：样品：  $X = \begin{bmatrix} 20 \\ 20 \end{bmatrix}$ ，应归属于哪一类？

解：比较样品  $X$  到两总体的马氏距离的大小：

$$\begin{aligned} & D^2(X, G_1) - D^2(X, G_2) \\ &= (X - \mu_1)' \Sigma_1^{-1} (X - \mu_1) - (X - \mu_2)' \Sigma_2^{-1} (X - \mu_2) \\ &= (10, 5) \frac{1}{432} \begin{pmatrix} 32 & -12 \\ -12 & 18 \end{pmatrix} \begin{pmatrix} 10 \\ 5 \end{pmatrix} - (0, -5) \frac{1}{51} \begin{pmatrix} 5 & 7 \\ 7 & 20 \end{pmatrix} \begin{pmatrix} 0 \\ -5 \end{pmatrix} \\ &= \frac{25}{432} (2, 1) \begin{pmatrix} 32 & -12 \\ -12 & 18 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} - \frac{1}{51} (0, -5) \begin{pmatrix} 5 & 7 \\ 7 & 20 \end{pmatrix} \begin{pmatrix} 0 \\ -5 \end{pmatrix} \\ &= \frac{25}{432} \times 98 - \frac{500}{51} < 0 \end{aligned}$$

所以  $X$  属于正态总体  $G_1$ 。

定义：设  $A$  是  $n$  阶矩阵，若存在  $n$  阶矩阵  $B$  使

$$AB = BA = E$$

则称  $A$  是可逆的，并称  $B$  是  $A$  的逆矩阵，

$$\text{当 } A \text{ 可逆时, } A^{-1} = \frac{1}{|A|} A^*$$

例如，设  $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$ ，当  $|A| = ad - bc \neq 0$  时，有

$$A^{-1} = \frac{1}{|A|} A^* = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

**伴随矩阵  $A^*$ ：** 矩阵元素所对应的代数余子式所构成的矩阵，转置后得到的新矩阵为伴随矩阵。

## 7. 《数据分析基础》 聚类-谱系聚类图

根据距离法的聚类过程，画谱系图

| 类的数目 | 新聚类集    | 新类中的变量数 | 最长距离    |
|------|---------|---------|---------|
| 7    | X2 X3   | 2       | 0.119 0 |
| 6    | X1 X4   | 2       | 0.141 0 |
| 5    | CL6 CL7 | 4       | 0.199 0 |
| 4    | X5 X6   | 2       | 0.238 0 |
| 3    | CL4 X7  | 3       | 0.417 0 |
| 2    | CL3 X8  | 4       | 0.461 0 |
| 1    | CL5 CL2 | 8       | 0.763 0 |



| 类的数目 | 新聚类集    | 新类中的变量数 | 最长距离    |
|------|---------|---------|---------|
| 7    | X2 X3   | 2       | 0.119 0 |
| 6    | X1 X4   | 2       | 0.141 0 |
| 5    | CL6 CL7 | 4       | 0.199 0 |
| 4    | X5 X6   | 2       | 0.238 0 |
| 3    | CL4 X7  | 3       | 0.417 0 |
| 2    | CL3 X8  | 4       | 0.461 0 |
| 1    | CL5 CL2 | 8       | 0.763 0 |




图 6.8 8 个体型指标类平均距离法谱系图

## 8. 《数据分析基础》均值与协方差矩阵

假设随机向量  $\mathbf{y} = (Y_1, Y_2, Y_3, Y_4)$ , 均值向量为  $\boldsymbol{\mu} = (4, 3, 2, 1)'$ , 协方差矩阵为

$$\boldsymbol{\Sigma} = \begin{bmatrix} 3 & 0 & 2 & 2 \\ 0 & 1 & 1 & 0 \\ 2 & 1 & 9 & -2 \\ 2 & 0 & -2 & 4 \end{bmatrix}$$

将  $\mathbf{y}$  分为  $\mathbf{y}^{(1)} = (Y_1, Y_2)'$  和  $\mathbf{y}^{(2)} = (Y_3, Y_4)'$ . 进一步, 设矩阵

$$\mathbf{A} = [1, 2], \mathbf{B} = \begin{bmatrix} 1 & -2 \\ 2 & -1 \end{bmatrix}$$

考虑线性组合  $\mathbf{A}\mathbf{y}^{(1)}$  和  $\mathbf{B}\mathbf{y}^{(2)}$ . 求:

- (a)  $E(\mathbf{y}^{(1)})$
- (b)  $E(\mathbf{A}\mathbf{y}^{(1)})$
- (c)  $COV(\mathbf{y}^{(1)})$
- (d)  $COV(\mathbf{A}\mathbf{y}^{(1)})$
- (e)  $E(\mathbf{B}\mathbf{y}^{(2)})$
- (f)  $COV(\mathbf{B}\mathbf{y}^{(2)})$
- (g)  $COV(\mathbf{y}^{(1)}, \mathbf{y}^{(2)})$
- (h)  $COV(\mathbf{A}\mathbf{y}^{(1)}, \mathbf{B}\mathbf{y}^{(2)})$

假设随机向量  $\mathbf{y} = (Y_1, Y_2, Y_3, Y_4)$ , 均值向量为  $\boldsymbol{\mu} = (4, 3, 2, 1)'$ , 协方差矩阵为

$$\boldsymbol{\Sigma} = \begin{bmatrix} 3 & 0 & 2 & 2 \\ 0 & 1 & 1 & 0 \\ 2 & 1 & 9 & -2 \\ 2 & 0 & -2 & 4 \end{bmatrix}$$

将  $\mathbf{y}$  分为  $\mathbf{y}^{(1)} = (Y_1, Y_2)'$  和  $\mathbf{y}^{(2)} = (Y_3, Y_4)'$ . 进一步, 设矩阵

$$\mathbf{A} = [1, 2], \mathbf{B} = \begin{bmatrix} 1 & -2 \\ 2 & -1 \end{bmatrix}$$

$$(a) E(\mathbf{y}^{(1)}) = \begin{pmatrix} 4 \\ 3 \end{pmatrix}$$

$$(b) E(\mathbf{A}\mathbf{y}^{(1)}) = \mathbf{A}E(\mathbf{y}^{(1)}) = (1, 2) \begin{pmatrix} 4 \\ 3 \end{pmatrix} = 10$$

$$(c) Cov(\mathbf{y}^{(1)}) = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}$$



假设随机向量  $\mathbf{y} = (Y_1, Y_2, Y_3, Y_4)$ , 均值向量为  $\boldsymbol{\mu} = (4, 3, 2, 1)'$ , 协方差矩阵为

$$\boldsymbol{\Sigma} = \begin{bmatrix} 3 & 0 & 2 & 2 \\ 0 & 1 & 1 & 0 \\ 2 & 1 & 9 & -2 \\ 2 & 0 & -2 & 4 \end{bmatrix}$$

将  $\mathbf{y}$  分为  $\mathbf{y}^{(1)} = (Y_1, Y_2)'$  和  $\mathbf{y}^{(2)} = (Y_3, Y_4)'$ . 进一步, 设矩阵

$$\mathbf{A} = [1, 2], \mathbf{B} = \begin{bmatrix} 1 & -2 \\ 2 & -1 \end{bmatrix}$$

$$(d) \text{Cov}(\mathbf{A}\mathbf{y}^{(1)}) = \mathbf{A}\boldsymbol{\Sigma}_{11}\mathbf{A}' = (1, 2) \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = 7$$

$$(e) E(\mathbf{B}\mathbf{y}^{(2)}) = \mathbf{B} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 & -2 \\ 2 & -1 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 3 \end{pmatrix}$$

$$(f) \text{Cov}(\mathbf{B}\mathbf{y}^{(2)}) = \mathbf{B}\boldsymbol{\Sigma}_{22}\mathbf{B}' = \begin{pmatrix} 1 & -2 \\ 2 & -1 \end{pmatrix} \begin{pmatrix} 9 & -2 \\ -2 & 4 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ -2 & -1 \end{pmatrix} = \begin{pmatrix} 33 & 36 \\ 36 & 48 \end{pmatrix}$$

$$(g) \text{Cov}(\mathbf{y}^{(1)}, \mathbf{y}^{(2)}) = \boldsymbol{\Sigma}_{12} = \begin{pmatrix} 2 & 2 \\ 1 & 0 \end{pmatrix}$$

$$(h) \text{Cov}(\mathbf{A}\mathbf{y}^{(1)}, \mathbf{B}\mathbf{y}^{(2)}) = \mathbf{A}\boldsymbol{\Sigma}_{12}\mathbf{B}' = (1, 2) \begin{pmatrix} 2 & 2 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ -2 & -1 \end{pmatrix} = (0, 6)$$

# 多元数据的一些性质

$$V = \text{Diag}(\sqrt{\sigma_{11}}, \sqrt{\sigma_{22}}, \dots, \sqrt{\sigma_{pp}}) = \text{Diag}(\sigma_1, \sigma_2, \dots, \sigma_p)$$

则

$$\rho = V^{-1} \Sigma V^{-1} \quad (1.43)$$

为了阐述样本数据的协方差矩阵、相关矩阵与总体的协方差矩阵、相关矩阵的关系,先介绍以下关于随机向量的性质.

设  $X = (X_1, X_2, \dots, X_p)^T, Y = (Y_1, Y_2, \dots, Y_q)^T$  各为  $p$  维,  $q$  维随机向量, 则有

(1) 设  $A$  为  $r \times p$  阶常量矩阵, 则

$$E(AX) = AE(X) = A\mu, \text{Cov}(AX) = ACov(X)A^T = A\Sigma A^T$$

特别, 记  $c = (c_1, c_2, \dots, c_p)^T$  是常向量, 有

$$E(c^T X) = c^T E(X) = c^T \mu, \text{Var}(c^T X) = c^T \Sigma c$$

(2) 设  $B$  为  $s \times q$  常量矩阵, 则

$$\text{Cov}(AX, BY) = ACov(X, Y)B^T$$

其中  $\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))^T]$ . 特别, 当  $c = (c_1, c_2, \dots, c_p)^T$ ,  $d = (d_1, d_2, \dots, d_q)^T$  是常向量时,

$$\text{Cov}(c^T X, d^T Y) = c^T \text{Cov}(X, Y) d$$

在多维数据分析中, 样本数据的均值向量  $\bar{x}$ 、协方差矩阵  $S$  及相关矩阵  $R$  分别是总体的均值向量  $\mu$ 、协方差矩阵  $\Sigma$  及相关矩阵  $\rho$  的相合估计. 因此, 当  $n$  充分大时, 有

$$\mu \approx \bar{x}, \quad \Sigma \approx S, \quad \rho \approx R$$

利用(1.30)式的  $p$  维总体  $(X_1, X_2, \dots, X_p)^T$  的观测数据矩阵, 可得每个分量

$X_j$  的观测值 (即数据矩阵的每一列) 的中位数  $M_{(j)} = 1, 2, \dots, p$  型

# 多元数据的一些性质

多维正态分布有下列性质:

(1) 设  $X \sim N_p(\mu, \Sigma)$ , 又  $Y = AX + b$ , 其中  $b$  是  $p$  维常向量,  $A$  是  $l \times p$  矩阵,  $\text{rank}(A) = l$ . 则

$$Y \sim N_l(A\mu + b, A\Sigma A^T)$$

即  $Y$  服从以  $A\mu + b$  为均值,  $A\Sigma A^T$  为协方差矩阵的  $l$  维正态分布.

数据的分割

(2) 设  $X \sim N_p(\mu, \Sigma)$ , 将  $X$  作如下划分

$$X = \begin{bmatrix} X^{(1)} \\ X^{(2)} \end{bmatrix}$$

其中  $X^{(1)}, X^{(2)}$  各为  $p_1, p_2$  维随机向量, 且  $p_1 + p_2 = p$ . 对均值向量  $\mu$ 、协方差矩阵  $\Sigma$  作相应划分:

$$\mu = \begin{bmatrix} \mu^{(1)} \\ \mu^{(2)} \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}$$

其中  $\mu^{(1)}, \mu^{(2)}$  分别为  $p_1$  维和  $p_2$  维向量,  $\Sigma_{11}, \Sigma_{12}, \Sigma_{21}, \Sigma_{22}$  各为  $p_1 \times p_1, p_1 \times p_2, p_2 \times p_1, p_2 \times p_2$  矩阵 (注意  $\Sigma_{21} = \Sigma_{12}^T$ ), 则

$$X^{(1)} \sim N_{p_1}(\mu^{(1)}, \Sigma_{11}), \quad X^{(2)} \sim N_{p_2}(\mu^{(2)}, \Sigma_{22})$$

即  $p$  维正态向量  $X$  的分向量  $X^{(1)}, X^{(2)}$  各服从  $p_1, p_2$  维正态分布.

## 9. 《数据分析基础》证明无偏估计

设  $X_{(1)}, \dots, X_{(n)}$  是来自  $N_p(\mu, \Sigma)$  的随机样本,  $C_i \geq 0 (i=1, \dots, n)$ ,  $\sum_{i=1}^n c_i = 1$ , 令

$$Z = \sum_{i=1}^n c_i X_{(i)}, \text{ 试证明:}$$

1)  $Z$  是  $\mu$  的无偏估计;

2)  $Z \sim N_p(\mu, c^T c \Sigma)$ , 其中  $c = (c_1, \dots, c_n)^T$ 。



解: (1) 
$$E(Z) = E\left(\sum_{i=0}^n c_i X_{(i)}\right) = \sum_{i=0}^n E(c_i X_{(i)}) = \sum_{i=0}^n c_i E(X_{(i)}) = \sum_{i=0}^n c_i \mu = \mu \sum_{i=0}^n c_i = \mu$$

$Z$  是  $\mu$  的无偏估计量。

(2)  $X_1, \dots, X_n$  独立同分布于  $N_p(\mu, \Sigma)$

$$D(Z) = D\left(\sum_{i=0}^n c_i X_{(i)}\right) = \sum_{i=0}^n D(c_i X_{(i)}) = \sum_{i=0}^n c_i^2 D(X_{(i)}) = \sum_{i=0}^n c_i^2 \Sigma = c^T c \Sigma$$

由 (1) 中结论可知  $E(Z) = \mu$

所以,  $Z \sim N_p(\mu, c^T c \Sigma)$ , 其中  $c = (c_1, \dots, c_n)^T$  成立。