

《数据分析基础》课程测试答案

一、单选题（本大题共 10 小题，每小题 3 分，共 30 分）

1. 为了实现对字符型变量的数字化编码，在 SPSS 中常用的方法是（ B ）。
A. 利用 IF 函数进行分类赋值
B. 利用菜单“转换—重新编码为不同变量”功能
C. 利用菜单“数据—分类汇总”功能
D. 利用 CountIF 函数
2. 在 SPSS 操作中，绘制（ C ）可以很好地呈现出数据的分布特征。
A. 雷达图 B. 双轴图 C. 散点图 D. 气泡图
3. 在差异显著性检验过程中，一般来说，若检验概略 P 值低于（ B ），就认为差异效果是明显的，反正则认为差异效果不显著。
A. 1% B. 5% C. 8% D. 10%
4. 下列说法正确的是（ A ）。
A. T 检验的 Sig 值 >0.05 ，表示两列数据无显著性差异
B. 利用非参数检验的方法，可以判断两列数据的均值差异性
C. 为了对不符合正态分布的定距数据进行差异显著性检验，经常先计算这些数据的方差值
D. 在非参数检验中，K 个独立样本是指参与分析的数据具有一一对应关系
5. 在执行配对样本 T 检验时，如果发现 Sig=0.013，则意味着这两个样本的值之间（ B ）。
A. 两组样本之间不存在差异
B. 两组样本之间存在显著性差异
C. 这个数据不能说明样本之间的差异性关系
D. 这两组数据之间显著相关
6. 在独立样本 T 检验中，作为分组的变量，其取值应该满足（ A ）
A. 只能划分为 2 种情形 B. 只能划分为 4 种情形
C. 必须是字符型的定类变量 D. 必须是数值型的定距变量
7. 在线性回归分析中，对结果表格中 R 值、Sig 值和 F 值之间的关系，正确的描述是（ B ）。
A. 若 R 值较大，则 F 值和 Sig 值都较大 B. 若 F 值较大，则 R 值较大，Sig 值较小
C. 若 F 值较大，则 R 值和 Sig 值都较大 D. 若 Sig 值较大，则 F 值较小，R 值较大
8. 在相关性分析中，其零假设是（ A ）。
A. 变量之间不存在相关性 B. 变量之间存在着相关性
C. 变量之间存在着差异性 D. 变量之间有同步控制关系
9. 在判别分析中，生成判别函数的个数由（ A ）决定。
A. 分类类别数和预测因子数 B. 参与分析的自变量个数

- C. 参与分析的因变量个数
D. 判别分析只能是 2 维的, 因此只能生成 2 个判别函数
10. 在层次聚类中, 通常相似性较大 (距离较小) 的两个元素 (C)。
- A. 最后聚合 B. 中期聚合 C. 最先聚合 D. 不好说

二、综合应用和计算题 (本大题共 4 小题, 共 70 分)

1. 写出下列回归模型的矩阵形式。 (共 20 分)

(1) $y_i = \beta_0 + \beta_1 x_{i1}^2 + \beta_2 x_{i2}^2 + \varepsilon_i, i = 1, 2, \dots, n$ (10 分)

(2) $\sqrt{y_i} = \beta_1 \ln x_{i1} + \beta_2 x_{i2} + \beta_3 (x_{i1} + \sin x_{i2}) + \varepsilon_i, i = 1, 2, \dots, n$ (10 分)

解: $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$

$$(1) \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & x_{12}^2 \\ 1 & x_{21} & x_{22}^2 \\ \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2}^2 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

$$(2) \begin{bmatrix} \sqrt{y_1} \\ \sqrt{y_2} \\ \vdots \\ \sqrt{y_n} \end{bmatrix} = \begin{bmatrix} \ln x_{11} & x_{12} & x_{11} + \sin x_{12} \\ \ln x_{21} & x_{22} & x_{21} + \sin x_{22} \\ \vdots & \vdots & \vdots \\ \ln x_{n1} & x_{n2} & x_{n1} + \sin x_{n2} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

2. 设 $\mathbf{X} = (X_1, X_2)^T$ 的协方差矩阵为

$$\boldsymbol{\Sigma} = \begin{bmatrix} 1 & 4 \\ 4 & 100 \end{bmatrix} \quad (\text{共 15 分})$$

(1) 求 $\mathbf{X}$ 的各主成分。 (10 分)

(2) 求各主成分的贡献率。 (5 分)

解: 令 $\det(\lambda E - \boldsymbol{\Sigma}) = |\lambda E - \boldsymbol{\Sigma}| = 0$

可求得特征值及相应的正交单位化特征向量为,

$$\lambda_1 = 100.16, \quad e_1 = (0.040, 0.999)^T$$

$$\lambda_2 = 0.84, \quad e_2 = (0.999, -0.040)^T$$

相应的:

$$\text{第一主成分: } Y_1 = 0.040X_1 + 0.999X_2 \quad \text{贡献率: } \frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{100.16}{101} = 99.2\%$$

第二主成分: $Y_2 = 0.999X_1 - 0.040X_2$ 贡献率: $\frac{\lambda_2}{\lambda_1 + \lambda_2} = \frac{0.84}{101} = 0.8\%$

3. 设总体 $\mathbf{X} = (X_1, X_2, X_3)^T$ 的相关系数矩阵为

$$\rho = \begin{bmatrix} 1 & \rho & \rho \\ \rho & 1 & \rho \\ \rho & \rho & 1 \end{bmatrix}, \quad \rho > 0 \quad (\text{共 20 分})$$

(1) 求 $\mathbf{X}$ 的标准化变量的主成分。 (10 分)

(2) 求标准化后各主成分的贡献率。 (10 分)

解: 令 $\det(\lambda E - \Sigma) = |\lambda E - \Sigma| = 0$

可求解得特征值,

$$\lambda_1 = 1 + 2\rho, \quad \lambda_2 = \lambda_3 = 1 - \rho$$

对于 $\lambda_1 = 1 + 2\rho$, 解 $|\lambda_1 E - \Sigma| = 0$, 得

$$\xi_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \quad e_1 = \begin{bmatrix} 0.5774 \\ 0.5774 \\ 0.5774 \end{bmatrix}$$

对于 $\lambda_2 = \lambda_3 = 1 - \rho$, 分别解 $|\lambda_2 E - \Sigma| = 0$ 和 $|\lambda_3 E - \Sigma| = 0$, 得

$$\xi_2 = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}, \quad \xi_3 = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

$$\text{正交化得, } \eta_2 = \xi_2, \quad \eta_3 = \xi_3 - \frac{(\xi_3, \eta_2)}{(\eta_2, \eta_2)} \eta_2 = \begin{bmatrix} \frac{1}{2} \\ \frac{1}{2} \\ -1 \end{bmatrix}$$

$$\text{标准化得, } e_2 = \begin{bmatrix} 0.7071 \\ -0.7071 \\ 0 \end{bmatrix}, \quad e_3 = \begin{bmatrix} 0.4082 \\ 0.4082 \\ -0.8165 \end{bmatrix}$$

主成分:

$$Y_1 = e_1^T X = 0.5774X_1 + 0.5774X_2 + 0.5774X_3$$

$$Y_2 = e_2^T X = 0.7071X_1 - 0.7071X_2$$

$$Y_3 = e_3^T X = 0.4082X_1 + 0.4082X_2 - 0.8165X_3$$

(2) 根据上面求解到的主成分，对应的贡献率分别为，

$$\text{第一主成分贡献率: } \frac{1+2\rho}{3}$$

$$\text{第二主成分贡献率: } \frac{1-\rho}{3}$$

$$\text{第三主成分贡献率: } \frac{1-\rho}{3}$$

4. 假设某一数据集内有 8 个变量，对其数值化编码为 (1, 2, 3, 4, 5, 6, 7, 8)。利用 IBM SPSS Statistics 软件对该数据集进行分层聚类分析，得到的聚类表如下图所示，请根据聚类表画出生成的树状图（谱系图）。（共 15 分）

凝聚计划						
阶段	组合的集群		系数	首次出现阶段集群		下一个阶段
	集群 1	集群 2		集群 1	集群 2	
1	6	7	285.550	0	0	5
2	2	8	884.000	0	0	4
3	1	4	2997.000	0	0	4
4	1	2	3893.000	3	2	6
5	5	6	5369.441	0	1	7
6	1	3	7115.250	4	0	7
7	1	5	13898.232	6	5	0

解：根据分层聚类的原理，首先把每个元素都看成一个集群，选择距离最近的两个集群聚合在一起，形成一个新的集群。然后从新的集群中，再次寻找距离最近的两个集群合并，反复循环，直到所有的集群都被聚集到一个类中。

根据题目中给出的聚类表，其对应的树状图如下图所示：

