

第1章 数据统计分析的概念

1.单选题（参考答案）

1.C	2.D	3.A	4.D	5.A
6.	7.	8.	9.	10.

2.思考题

(1) 什么是计算思维？计算思维思想对人才培养产生了什么影响？

计算机科学与技术与其他学科最大的不同就是突破了学科范式的限制，渗透到了各个学科乃至推向其前沿，形成了一套有效的思维模式——计算思维，促使学科走向范式多元化，因此，没有哪个学科有如此广泛的研究领域和实践范畴，学生的计算思维能力水平将对他们从事科研的能力、适应社会的能力具有重要影响。

由于学科知识体系的有机关联，计算思维在理论和实践上的成果带来了相关学科的活跃与繁荣。尤其是其方法论意义对各个学科的启发和促进作用异乎寻常。首先，随着人类对自然科学和人文社会科学研究的广泛、深入，科学研究中直观性的程度在减少，抽象化的程度在提高，逻辑思维方法高度发展。其次，科学的进一步分化和综合产生了一些新兴学科和边缘学科，促使科学研究的整体性和综合性增强，系统理论等具有方法论意义的新学科也不断产生。再者，现代科学发现了一系列原有科学理论体系不能解释和说明的新的事实，出现了一些悖论，破坏了科学体系已有原则和思维前后逻辑的一贯性和严密性，产生了现代科学范畴体系的许多带有根本性的变化，同时也促使思维模式、逻辑方法向前发展。总之，计算思维改变了很多学科的发展模式，促使学科向更高的抽象化、更强的计算化方向发展。

(2) 什么是大数据时代？为什么说大数据时代对人才培养提出很多新的要求？

随着信息化的普及和各类信息系统的应用，各类信息系统中都积累了大量的原始数据，分析这些数据内部所蕴含的规律、预测相关系统的运行趋势，已经成为当代信息处理的主要任务。大数据处理就是应时代需求出现而发展起来的，大数据知识服务是为适应信息服务业智慧化、协作化、绿色化、先觉化和泛在化的发展趋势而衍生的一种基于网络的，用以解决结构化、半结构化及非结构化数据多维度处理的信息服务新模式，是嵌入式协作化知识服务模式的一种新发展，是现代信息服务理念的具体体现。

(1)大数据时代对数据分析与处理技术提出了迫切要求

管理信息化、教育信息化、企业现代化的快速发展，促使各行各业在近十年都出现了极大的、极快的数据积累。不论在商业贸易领域，还是在经济建设领域、教育领域，都积累了海量数据。如何充分地利用这些数据，从中总结出规律，以便为下一步的决策提供依据，或者依据数据分析实现智能化的数据推送，已经成为社会科学的重要研究领域。基于这一需求而快速发展的数据建模技术、数据挖掘技术已经成长为计算机科学的重要应用领域，也是计算思维的重要应用之一。

(2)各类实证性研究的开展都必须借助数据分析工具或模型

在人文科学的研究中，传统的研究以质性研究法为主，基于数据开展的量化研究则需要以统计学、数据分析的理论为基础，通过大量的数据计算，分析数据之间的相关性、差异性，甚至包括归因分析、聚类分析（降维分析）等。在计算机科学真正地普及以前，基于大量的调查数据开展统计与分析是一项计算量非常巨大的工作，而且要求研究者精确地掌握统计学、分析法中的每个计算方法。因此，对定量研究者的要求非常高。

(3) 数据分析能力的提升能够极大地提升科研人员的计算思维能力

尽管对多数从事人文科学研究的科研人员来讲，SPSS 和 SAS 中的各类数据分析工具就像一个只有“输入”和“输出”的“黑匣子”，只需精确地掌握输入数据和各项参数，并了解输出结果所代表的具体含义，就能够使用它们。然而，研究发现：很多从事人文科学研究的人员在多次利用定量分析工具开展实证性分析后，其思维习惯和解决问题的方法都有了很大变化，在论证的严谨性、对数据的应用方法等层面，都比以前有了很大的提高，反应了数据分析工具对人们思维方式所产生的重要影响。

(3) 在数据分析过程中，常见的技术主要可分为哪两大类？

在数据分析的发展过程中，始终伴随着两条思路。其一，面向静态数据的数据分析；其二是面向动态数据的实时数据挖掘。

所谓面向静态数据的数据分析，是指把通过社会调查获得的数据，或者从信息系统导出的针对某一时间点的数据，借助数据分析专业软件，对已有数据进行分析。这种分析没有考虑数据的动态性、变化性，往往是针对某一时间点状态的数据分析。

所谓面向动态数据的实时挖掘，是指在信息系统中集成数据挖掘算法，以便信息系统能够随时针对动态数据开展分析。这种技术强化时间序列特点、依托数据仓技术，对用户具有很高的要求，已经成为主流数据库系统的重要组成部分。

(4) 在数据分析过程中，对数据序列集中性描述的变量有哪些？各有什么特点？

在数据分析过程中，人们通常需要了解数据序列集中于哪一个数据点周围。常见的描述量主要有均值、众数和中位数。

均值（Mean），即平均值，是对整个序列求和后再除以数据个数所得到的结果。

众数（Mode），即个数最多的数，它指在整个序列中，那个出现次数最多的数值。简单的说，就是一组数据中占比例最多的那个数。它是在统计分布上具有明显集中趋势点的数值，代表数据的一般水平（众数可以不存在或多于一个）。

中位数（Median），即对数据序列排序后位于正中间的那个数值，它可将数值集合划分为相等的上下两部分。需要注意的是：如果原序列中数据的个数为偶数个，则中位数为正中间两个数值的平均值。

(5) 在数据分析中，对数据序列离散性描述的变量有哪些？各有什么适应性？

在数据分析中，人们通常需要了解数据序列的波动情况，即数据的离散性。对于数据序列来讲，数据在均值附近的波动性大小是序列的重要属性之一，对于未来的统计分析有重要价值。衡量数据序列离散性的描述量主要有方差、标准差。

方差（Variance），即数据序列中 n 个离差（当前数值与均值的差）的平方和与数据个数 n 的比值。在概率论和数理统计中，方差用来度量随机变量和其数学期望（即均值）之间的偏离程度。

标准差（Standard Deviation）是方差的平方根，也是描述数据离散性的量，中文环境中又常称均方差。

(6) 在数据分析中，常见的数据分析技术有什么？简述其特点。

计算机科学的发展，促成了许多数据统计分析软件，诸如 SPSS、SAS，就连最简单的 Excel，也提供了数据分析功能等。而且，随着定量研究法的普及，许多定量分析算法已经被集成到了常规的办公软件中，使定量研究所需的数据分析算法不再神秘，诸如相关性分析、差异性检验（T-检验与方差分析）、归因分析、聚类分析（降维分析）、信度效度检验等算法已经成为科学研究中的基本方法。

①**相关性分析**。相关性分析是指对两个或多个具备相关性的变量元素进行分析，从而衡量两个变量因素的相关密切程度。相关性的元素之间需要存在一定的联系或者概率才可以进行相关性分析。②**差异性检验**。差异性检验也叫差异显著性检验，用于判断两个数据序列是

否存在显著的差异。对于数据序列的差异性检验，分为均值差异性和分布差异性两种形式。对于具有相同分布形态的两列连续型数据，通常可检验其均值差异性，而对不明形态的数据，则常常检查其分布差异性。③**降维分析**。在数据统计分析过程中，常常从多个视角制作调查或评价指标，从而能够全面地反应调查对象的属性和特点。然而，在调查完成后，常常发现以下问题：多个指标项的语义有重叠，需要获得凝练的分析结论。④**聚类分析**。在数据统计与分析过程中，常常需要把成千上万的个案分成若干类，以便于操作。例如，可以把学生分为男生、女生，还可以把学生按照综合表现分为优等生、良好生、普通生和差生。这种依据某些因素，对个案分类的过程就是聚类分析，也叫分类。所以，分类分析就是对收集到的数据分析其内在规律和特点，把相似的数据归结为一类的过程。

(7) 在数据分析中，常见的静态数据分析软件有哪些？各有什么特点？

在数据分析中，针对静态数据的专业化的数据统计分析软件有：SPSS、SAS 和 Systat；另外还有非专业化的数据统计分析软件 Excel 等。

特点（略）。

(8) 在数据分析中，针对后台数据库的数据挖掘技术有哪些？

目前，数据挖掘技术已经被广泛地应用在各种大型信息系统之中，各类网站提供的“猜你喜欢”、“向您推荐”等功能都是这方面的典范。各大搜索引擎的“网络爬虫”模块也大量借助了文本分析和数据挖掘的技术。

微软公司在其 SQL Server 数据库管理系统中提供的 Business Intelligence Development Studio 模块中，就向用户提供了利用 Analysis Services 工具开展不同种类的数据挖掘功能。在这一领域，IBM 也有一些非常成熟的产品。

(9) 在 Excel2010/2013 中，如何启动“分析工具库”？

首先，选择顶级选项卡【文件】，然后从右下角单击按钮【选项】，以便打开“Excel 选项”面板。

其次，在“Excel 选项”面板左侧选择“加载项”，进入“加载项”管理面板。

第三，此时在面板底部找到【管理 A Excel 加载项 转到】标记，单击其中的【转到】按钮，打开“加载宏”对话框。

第三，在“加载宏”对话框中，把“分析工具库”复选框设置为有效。

最后，单击【确定】按钮。

(10) 在 SPSS 中，有哪两种类型的数据分析方式？各有什么特点？

在 SPSS 中，也提供了 2 种形态的数据分析技术：其一是基于系统菜单和对话框配置的数据分析技术；其二是基于 SPSS 命令语句的数据分析技术。SPSS 提供的这 2 种类型的数据分析环境，各有特色并适用于不同的用户群。分析这两种类型的分析环境，需要注意以下 3 点。

①基于菜单项的数据分析方法，以菜单项启动数据分析命令，以对话框提供人机交互界面，允许用户借助对话框设置详细的配置参数，能够准确、有效、便捷地完成数据分析任务。它适应于 SPSS 的初学者或者对 SPSS 命令行不熟悉的用户。其唯一缺点是：在需要重复性地处理大量相似的分析任务时，需要用户机械地、重复性调用系统菜单并配置分析参数，导致系统的分析效率不高。

②基于命令行的数据分析方法，它运行在“语法”窗口中，允许用户直接撰写 SPSS 的命令行实施数据操作。由于运行在“语法”窗口中的命令语句可以被复制，也可以作为语法文件（*.SPS）被保存起来，以供下次使用。因此，它具有执行效率高，便于批量处理等优点。但是，这种方式要求用户掌握 SPSS 的命令行，并能准确地使用 SPSS 命令语句的参数配置，对用户有较高的要求。

第2章 数据梳理与统计描述

1. 单选题（参考答案）

1.B	2.B	3.B	4.B	5.C
6.C	7.A	8.A	9.C	10.B

2. 思考题

(1) 在数据分析中，针对总体数据的方差与针对样本数据的方差，有什么不同的描述形式？

对于总体数据，方差是指所有数据离差之平方和的平均值，也有的文献中称之为均方差。在统计学中，人们用 S^2 代表方差。如公式（2-5）和公式（2-6）所示。

$$S^2 = \frac{1}{n} \sum_{i=1}^n \Delta_i^2 \quad \text{公式（2-5）}$$

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - X)^2 \quad \text{公式（2-6）}$$

基于样本数据估算总体方差，需要以离差平方和除以自由度。这就是统计学中常见的样本方差的概念。

由于方差的计算需要以均值为起点，所以在计算方差时，其自由度为 $n-1$ 。所以样本方差的计算公式如公式（2-8）所示。

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - X)^2 \quad \text{公式（2-8）}$$

(2) 常见的数据分布形态有哪些？有什么特点？

所谓数据的分布形态，是指待分析的数据满足一种什么样的分布形式，是否在均值附近的数据个数最多，还是呈现两端数量最多的情形。

在数据分析中，数据的分布形态对分析方法、分析结果的衡量都具有重要意义。常见的数据分布形态有正态分布、均匀分布、指数分布、泊松分布等形态，而在数据分析中价值最大的分布形态就是正态分布。

(3) 什么是正态分布？正态分布数据有哪些特殊性？什么是标准正态分布？

正态分布，是一种理想化的分布形态，其分布形态呈现为钟形，围绕均值两侧的数据密度较高，远离均值的区域数据密度较低。正态分布也叫高斯分布。

在数据分析中，若大规模的样本的分布形态符合正态分布，那么全部样本的均值就是随机函数的 μ 值（ μ 值即钟形图片的对称轴与水平坐标轴的交点横坐标），而样本的标准差 σ 值反应钟形的高度。

对于正态分布函数，如果其分布形态满足 $\mu=0$ 、 $\sigma=1$ ，则整个公式简化为标准正态分布。这种正态分布是以坐标系的垂直坐标轴为对称轴，尺寸大小为 1 的完全对称的钟形图形。

(4) 在数据分析中，常见的分析思路与评价策略是什么？

数据分析的常见策略主要包括数据统计描述、数据差异性检验、相关性分析、回归分析、聚类分析、降维分析等内容。这些操作可以分为两个不同的类别，其一是对数据的描述与检验，其二是基于数据建模并依据模型对未来数据实施判定或评价。在上述数据处理过程中，主要有以下两种重要思路。

① 预设假设并检验假设

在数据检验前，先预设一种假设，然后按照特定的算法对假设进行检验，最后根据检验概率判定假设成立的可能性。

例如，在数据的差异性检验过程中，人们通常预先假设两列数据不存在显著性差异，然后依据 SPSS 或 Excel 内置的算法判定假设成立的概率值（即假设成功的可能性）。若假设成立的概率值大于 5%，则表示原假设是成立的，两列数据之间是不存在显著性差异的；若假设成立的概率值小于 5%，则表示原假设是很难成立的，即两列数据没有显著差异的可能性很低，两列数据之间是存在显著差别的。同理，针对两列的数据的相关性分析，也借助于这一思路。

②基于“关注值/偏差值”比值的评价策略

在数据分析中，人们通常利用“关注值/偏差值”的比值来判定数据的稳定性或有效程度，这一思路贯穿了数据分析的各个过程，并在不同的模块中呈现为不同的具体形态。

在数据描述模块中，数据序列的均值 $\bar{X}$ 是人们的关注值，而数据序列的标准误差 SE 反映了数据的波动程度。这里的比值 $\bar{X}/SE$ 直接反映了数据的集中性水平。若这个比值很大，则表示数据序列比较稳定，波动程度较小。

(5) SPSS 的数据编辑界面有什么特点？“变量视图”界面中的“标签”、“值”和“度量”项的设置各有什么作用？

启动 SPSS 之后，系统默认停靠在“数据视图”界面，即“数据编辑主界面”。这是一个与 Excel 工作表相似的界面，由标准化的二维表结构构成，其每一行为记录（也叫个案），每一列为属性，也叫字段。

在 SPSS 的变量视图下，标签是对变量名称的补充说明，可以使用带有汉字的长字符串，完整地描述变量的含义。①标签的内容主要用在显示统计分析结果时。在 SPSS 显示数据的分析结果时，如果被统计的变量带有标签，则会在图表的关键位置显示出标签内容，将有助于用户阅读输出结果。②由于 SPSS 的很多分析算法都要求参与运算的变量为数值型，所以性别、院系单位、专业、民族等信息常常被数值化编码。然而，在完成数值化编码之后，人们发现尽管已经可以正常地进行数据分析运算，但完全数码化的输出结果往往难以理解。为此，人们希望能够在统计分析结果中仍以文字化的形式说明统计结论。于是，SPSS 给出了对数字化编码后的每一取值进行文字说明的要求。③对于数值型量，为了适应不同的分析算法，在统计分析过程中，具有更加细节的划分。人们通常把数值型变量划分为“度量型”（即定距型）、“序号型”（即定序型）和“名义型”（即定类型）。正确地划分数值型量的子类型，对于统计分析的正确运行非常重要。

(6) 在 SPSS 中，要实现对字符型变量的数值化编码，通常采用什么方法？

在 SPSS 中，对字符型变量的重编码是通过【转换】—【重新编码为不同变量】来实现的。

(7) 在 SPSS 中，要实现对定距型变量的离散化编码，通常采用什么方法？

在 SPSS 中，对数据表内定距变量的离散化编码也可以通过【转换】—【重新编码为不同变量】来实现。

除了基于数据重编码的方式实现定距数据的离散化之外，SPSS 还提供聊“可视离散化”的方式对定距数据（连续变量）实现离散化编码。

(8) 在 Excel 中，要实现对字符型变量的数值化编码，通常采用什么方法？

在 Excel 中，对数据表内字符串变量的重编码主要是通过 IF 函数来实现的。IF 函数的一般格式是：if(条件式，式子 1，式子 2)，其作用是根据条件式的取值决定函数结果值，若条件式为真，则函数取“式子 1”的值作为最终结果；若条件式为假，则取“式子 2”的值作为最终结果。

(9) 在 SPSS 中，如何判定一个数据序列的分布形态？

常见的数据分布形态有正态分布、随机分布（均匀分布）、泊松分布、指数分布等，但在数据分析中，最重要的分布形态是正态分布，很多数据分析操作都是面向正态分布的定距变量或者高测度的定序变量的。

在 SPSS 中，判定数据的分布形态有多种，常见的策略有：①绘制带正态曲线的直方图，通过对比直方图与正态曲线的拟合程度，判定数据序列的分布形态是否接近正态分布。②利用 SPSS 的“描述统计”中的 Q-Q 图或 P-P 图判断数据序列是否接近正态分布。③利用 SPSS 的单变量 K-S 检验判断数据序列是否接近正态分布。

(10) 什么是 Z 分数？在数据处理中有什么价值？

对于基本满足正态分布的数据序列，假设其均值为 μ ，第 i 个个案的取值为 X_i ，由那么公式： $Z_i = \frac{X_i - \mu}{\sigma}$ 得到的序列就被称为 Z 分布，其中的每一个数值就是针对相应原始数据的标准分，也叫 Z 分数。

从公式可以看出，第 i 个案的标准分等于其个案值减去均值之后，其差与标准差的比值。即个案值与均值之差等于多少倍的标准差。

在数据处理中，①利用 Z 分数，可以把满足普通正态分布的数据序列转化为标准正态分布形态。②利用 Z 分数，可以把全距值相差很大的两个数据序列转化为同一量级水平。③尽管 Z 分数的概念从正态分布而来，但求取 Z 分数的操作并不局限于满足正态分布的定距变量。对于其他分布形态的定距变量也可以求取其 Z 分数。另外，把原始数据转化为 Z 分数，并不能把非正态分布序列变成正态分布。

(11) 什么是箱体图？在箱体图中是如何标记出奇异值和极端值的？

箱体图，也简称为箱图，即用一个箱状矩形来描述变量分布形态的图形。它以一个内部带有一条横线的矩形代表箱体，在箱体两端有伸出的一段触手，在部分图形触手之外的区域还有一些散点。距离箱体很远的被标记为“*”号，距离箱体较近的标记为“o”号。

箱体图是对数据序列的四分位数的直观描述。其箱体部分即四分位的 Q3 和 Q1。因此，四分位间距即 Q3-Q1 的值，也就是箱体图中的箱体部分。

箱体图直观明了地识别数据批中的异常值，利用箱线图可以判断数据批的偏态和尾重。

(12) 什么是交叉表？在数据描述中，交叉表用于主要解决哪种数据的描述问题？

交叉表，是基于“分类计算频数并分析各类个案在频数之间是否存在关联性”的思路而构造的二维频数表。它的基本方法是：先选择一个变量作为行变量，再选择另外一个变量作为列变量，由行变量的各个取值和列变量的各个取值构成二维的交叉表格，然后分别计算处于交叉维度的个案数目。

基于分类交叉计数思想的交叉表是数据分析中处理低测度数据的重要手段，在数据分析中具有重要作用。对于交叉表的内容特作如下补充。

第3章 数据的差异显著性检验

1. 单选题（参考答案）

1.B	2.B	3.A	4.B	5.B
6.A	7.A	8.D	9.C	10.C

2. 思考题

(1) 数据的差异性检验有多种，哪些检验是均值差异性检验？

所谓差异显著性检验，是面向两组或多组数据的一种数据分析方式，其目的是对两组数据之间是否存在显著的差异进行判断。

在数据分析领域，基于均值的差异显著性检验分为 T 检验和方差分析两类。这两类检验都建立在均值和方差的基础上，而且要求数据的分布形态接近于正态分布。

(2) 什么是 T 检验？T 检验对于待检测的数据有哪些要求？

T 检验是数据分析中针对基本满足正态分布的高测度数据所采取的一种基于均值差异性检验方法，T 检验在数据分析中具有广泛而且重要的应用。

参与 T 检验的数据只有 2 组，可以是一一对应的配对数据，也可以是非配对数据。

(3) 在 T 检验中，如果参与检验的两组独立样本的方差不齐性，应该如何做？

在 Excel 中，人们可以使用 FTEST 函数检查两列数据是否方差齐性，然后再实施 T 检验。而在 SPSS 中，在系统实施 T 检验时，系统会自动地同时进行 F 检验，判断其方差是否齐性。

(4) 什么是方差分析？对参与方差分析的数据有哪些要求？

方差分析，是针对满足正态分布的高测度变量按照某种规则分组，并针对各个分组比较其均值差异性的一种分析策略。在这种分析中，除了要考虑分组的两两组合之内的关系外，还经常需要考虑多个分组之间的相互关系。

由于方差分析的目标是：检验针对来源于同一总体的多个分组在某变量上是否有均值差异性。所以，从本质上讲，方差分析的根本仍是均值差异性。

(5) 在进行方差分析时，如果作为分组变量的变量是字符串型，应该如何做？

在以 SPSS 进行方差分析时，如果作为分组变量的变量为字符串类型，则需要借助 SPSS 的“重编码为不同变量”功能对字符串变量进行数值化编码，以新生成的数值型变量作为分组变量。

在以 Excel 进行方差分析时，则需要先按照分组变量对全体记录排序；然后依次把每个组别的数据拷贝到另外的独立区域中，每个组别的数据独立占据一列。最终构成一个支持方差分析的二维表。

(6) 在进行方差分析时，在输出结果中，如果 F 值小于 1，说明什么？此时的 Sig 值会有什么表现？

在进行方差分析时，如果输出结果的 F 值小于 1，说明组间的差异小于组内个案之间的差异，此时的 Sig 值一定会大于 0.05，表示不同分组的个案没有显著性差异。

(7) 什么是曼-惠特尼非参数检验？有什么适应性？

Wilcoxon W(威尔克逊)等级和检验，也叫曼-惠特尼 U 检验。它是针对两独立样本实施非参数检验的一种方法。

曼-惠特尼检验的基本思路是：把全部样本混在一起求秩，然后根据两组样本的平均秩

分情况判断是否存在差异。曼-惠特尼 U 检验本质上是一种检验平均秩的检验。本算法适应于定距数据和定序数据。

(8) 在众多的非参数检验方法中，负责处理二分变量之间关联样本差异性的检验是什么技术？

在众多非参数检验方法中，变化显著性检验，仅适用于两个变量均为二分数据的情况。变化显著性检验，是基于两次测量差值情况的检验方法。即把样本的两次观测值相减，记录差值，然后通过校验公式处理后，求取卡方值。然后，基于卡方检验决定其差异性。

(9) 什么是卡方检验？它主要用于解决什么问题？

卡方检验的目标就是检查观测值的频数与期望频数之间的差异性水平。由于卡方检验要求便于对个案进行分类计算频数，因此卡方检验通常基于定类数据或低测度定序数据，并基于它们分类计算个案的实际频数，然后通过实际频数与期望频数的距离，来判定实际频数是否与预期目标存在差异。

在 SPSS 中，卡方检验有两种基本应用。其一，检验期望分布与实际观测值的差异性。其二，基于交叉表检验两个低测度变量在不同因素水平上的差异性。

(10) 什么是游程检验？它有哪些作用？

所谓游程检验，是指依据某种规则对数据序列中的个案分组，并记录每个个案的组号；然后，对数据序列按照升序排序，把得到的组号排列起来就构成一个游程序列。对于一个数据序列，如果游程个数达到一定的规模，就认为序列的分布是随机分布。游程检验的目标是检验两种样本的分布是否具有随机性，游程判定的就是分布规律的随机程度。

(11) 什么是协方差分析？有什么用途？

在数据的均值差异性分析中，影响结果的因素可能非常多。在这些因素中，有的因素是我们关注的、是区分度较高的可控因素；有的因素是我们不关注的，有的因素是一些随机变量，区分度低，对结果的影响不可控。

为了及时发现被关注因素的作用，需要在方差分析过程中，屏蔽掉这些不受关注的、区分度低的因素对结果变量的影响。这种不可控的、需要被屏蔽的因素被称为协变量。

基于协变量所开展的方差分析被称为“协方差”分析。

(12) 什么是二项分布检验，主要能解决什么问题？

SPSS 的二项分布检验正是通过检查样本数据的形态来验证总体数据是否服从二项分布，其零假设是样本来自的总体与指定的二项分布没有显著差异。

二项分布检验主要用于判断某种观点是否正确，通常用在基于样品的产品总体合格率检验、对基于部分学生成绩估算出全体学生及格百分比实施判断。

一般说来，在二项分布检验中，如果零假设不成立，则不能获得准确的研究结论。

第 4 章 数据的相关性与回归分析

1. 单选题（参考答案）

1.A	2.C	3.C	4.B	5.C
6.A	7.B	8.C	9.D	10.B

2. 思考题

(1) Pearson 相关的工作原理是什么？能够解决哪种数据的相关性判断问题？

Pearson 相关利用积矩相关系数判定数据之间的线性相关性，其基本思路是以两列数据的协方差与每列数据的方差之比反映相关性水平。

Pearson 相关（皮尔逊相关）是针对两列满足正态分布的定距型变量之间的相关性水平。即只有待检验的两列数据都满足正态分布而且是高测度数据才可以直接使用 Pearson 相关性检验。

对于使用 Pearson 检验的两列数据，其自变量应等间距或等比例，两序列内的数据序列应一一对应。参与 Pearson 相关性检验的数据序列通常来自对同一组样本的多次测量或者不同视角的测量。

(2) Spearman 相关的工作原理是什么？能够解决哪种数据的相关性判断问题？

Spearman 相关分析实质上是一种基于秩分的等级相关。由于待分析的数据不满足正态分布，不能直接使用 Pearson 积矩相关系数。为此，在相关分析中人们引入了秩分，借助秩分实现 Pearson 相关性检验。即先分别计算两个序列的秩分，然后以秩分值代替原始数据参与 Pearson 相关性分析。

Spearman 相关（斯皮尔曼相关）的最初设计意图是解决定序变量的相关性检验问题，它采用了基于秩分的等级相关技术。事实上，它除了可检验两列不明分布的定序变量之间的相关性水平之外，也能检验不明分布的定距变量的相关性。即对于各类不明分布的定距或定序数据都可以使用 Spearman 相关性检验。

(3) Kendall 相关的工作原理是什么？能够解决哪种数据的相关性判断问题？

由于待分析的数据不满足正态分布、甚至数据的自变量都是不等间距的，所以不能直接使用 Pearson 相关性检验计算相关系数。为此，在相关分析中人们引入了一致对概念，借助一致对在总数对中的比例分析其相关性水平。

Kendall τ 相关（也简称为肯德尔相关，Kendall 相关）用于判断两列不明分布的定序变量之间的相关性水平。即对于各类不明分布的数据可以使用 Kendall τ 相关性检验。

对于使用 Kendall 相关技术检验的两列数据，其自变量可以是顺序、不等间距或不等比例的数据，待检验数据可为非正态分布或分布形态不明的数据。

(4) 对于低测度数据，判断其相关性水平的主要方法是什么？

在针对低测度数据的相关性分析中，涉及到的变量既可能是定类变量，也可能是低测度的定序变量，对于这些变量之间的关联性，通常无法直接使用 Pearson 相关、Spearman 相关或 Kendall 相关的方法直接进行判断。人们通常采用基于交叉表的频数和卡方检验来判断两个低测度变量的相关性水平。

(5) 什么是回归分析？回归分析获得的回归方程有什么价值？

回归分析就是分析变量之间隐藏的内在规律，并建立变量之间函数变化关系的一种分析方法。回归分析的目标是建立由一个结果变量和若干自变量构成的回归方程式，使变量之间的相互控制关系通过这个方程式描述出来。

回归方程式不仅能够揭示现有个案内部隐藏的规律，明确各个自变量对结果变量的作用程度。而且，基于有效的回归方程，还能形成更有意义的数学方面的预测关系。因此，回归分析是一种关联性分析，同时还是一种分析因素变量对结果变量作用强度的归因分析，它还是预测分析的重要基础。

(6) 什么是 R 方值？有什么价值？

为了能够比较客观地评价回归方程的质量，人们引入了判定系数(R 方，即 R^2)的概念。

$$\text{判定系数}(R^2) = \frac{\sum \text{回归值}_i^2}{\sum \text{回归值}_i^2 + \sum \text{残差}_i^2} \quad \text{公式(4-11)}$$

在公式 4-11 中，判定系数 (R^2) 反映了回归值的平方和在回归分析中所占的比例。判

定系数的值在 0~1 之间，其值越接近 1，表示回归方程越能贴近观测值，更能体现观测数据的内在规律。

在回归分析中，判定系数是“回归值（即预测值）的平方和”与“回归值平方和+残差平方和”的比值，反映的是回归方程与观测值的贴近程度，即回归方程的质量。在一般的应用中，回归方程的判定系数应该大于 0.6，表示回归方程有较好的质量。但在医药、医疗等研究领域中，由于其他因素的影响较大，优质回归方程的判定系数也有可能取值较小，甚至小于 0.1。

(7) 如何判断一个回归方程的质量？T 值、F 值和 Sig 值在评价回归方程质量时起什么作用？

在回归分析中，判定系数是“回归值（即预测值）的平方和”与“回归值平方和+残差平方和”的比值，反映的是回归方程与观测值的贴近程度，即回归方程的质量。在一般的应用中，回归方程的判定系数应该大于 0.6，表示回归方程有较好的质量。但在医药、医疗等研究领域中，由于其他因素的影响较大，优质回归方程的判定系数也有可能取值较小，甚至小于 0.1。

在回归分析中，F 值等于“回归值均方和”与“残差均方和”的比值，反应回归方程对观测数据的吻合程度，T 值反应的是方程中的某个自变量对整个观测值的影响力水平。F 值和 T 值越大越好。Sig 值是 F 值和 T 值的检验概率，一般以小于 0.05 为宜。

(8) 在多元线性回归中，对自变量的筛选有哪些方式？借助什么标准判断自变量的去留？

在多元线性回归分析中，对自变量的筛选主要从两个方面考虑。

①系统按照什么规则决定自变量的去留？

在多元线性回归中，“自变量能否进入到方程中”、“自变量凭什么就能留在方程中”是多元线性回归分析成败的基本问题。其一，基于方差分析的检验概率实施自变量筛选；其二，基于方差分析的 F 值实施自变量筛选。

②自变量按照什么样的顺序进入到方程中？ 主要方法有：强行全体进入（Enter）、正向进入（Forward）、反向剔除（Backward）、逐步进入（Stepwise）、强行剔除（Remove）。

(9) 在曲线回归分析中，幂函数的回归方程的一般格式是什么？如何安置回归分析之后获取的回归系数？

在曲线回归分析中，幂函数的回归方程的一般格式是 $Y=b_0 \cdot X^{b_1}$ 。

在完成了基于曲线估计的回归分析之后，对于获得了两个系数 B_0 和 B_1 ，按照幂函数回归方程的一般格式直接填入方程式即可。

(10) 在曲线回归分析中，为什么主张先做散点图？有什么价值？

由于在具体的回归分析中，可能的曲线类型种类繁多，为了减少曲线估计的盲目性，通常先用散点图观察自变量与果变量之间的关系，判定因变量与自变量是否存在清晰的逻辑关系。

如果散点图中的散点向曲线附近集中，比较接近于一条曲线，则初步判断可以做曲线回归分析，否则无法做曲线估计。

对于可做曲线估计的数据，先认真观察曲线的形状，判定大概属于哪类曲线，是抛物线、还是对数曲线、指数曲线？多数情况下，单凭散点图并不能准确地确定曲线的类型，可大致确定 2~3 种曲线类型。

(11) 与多元线性回归分析相比，二元 Logistic 回归分析有哪些新的特点？

二元 Logistic 回归分析的目标是找到能够影响结果变量取值的因素，并构造出回归方程。然后可以借助回归方程对新个案进行运算，判定个案的最终选择。

在二元 Logistic 回归分析中，被解释的结果变量为二元变量，只有 0 和 1 两个取值。而

作为因素的自变量可以是定序变量、定类变量，甚至低测度定距量。

由于二元 Logistic 回归分析的结果变量为二元变量，取值范围只有两种状态，不便于直接计算其残差值；

在二元 Logistic 回归分析中，由于无法对结果变量计算均值，也就不能采用传统的方差分析和 F 值来判断方程的质量。

(12) 在多元线性回归分析中，F 值、R 方值、回归平方和、回归均方和以及自由度之间是什么关系？

在多元线性回归分析中，基本技术数值有四个，依次为回归值的平方和、残差值的平方和，回归值的自由度和残差值的自由度。其他数值都是基于上述四个数据的计算结果。

$R^2 = \text{回归值平方和} / (\text{回归值平方和} + \text{残差值平方和})$ ；

$\text{回归均方和} = \text{回归值平方和} / \text{回归自由度}$ ；

$\text{残差均方和} = \text{残差平方和} / \text{残差自由度}$ ；

$F \text{ 值} = \text{回归均方和} / \text{残差均方和}$ 。

第 5 章 数据的降维与聚类分析

1. 单选题（参考答案）

1.B	2.C	3.D	4.B	5.C
6.C	7.A	8.D	9.A	10.D

2. 思考题

(1) 什么是系统聚类分析？有人说利用系统聚类分析，可以实现变量的聚类，这种说法正确吗？

分层聚类是 SPSS 中的基本聚类方式，默认为系统聚类，有时也叫层次聚类。其主导思路是：首先制定衡量元素之间距离的规则，接着先把距离最近的若干元素归类，形成新元素点，再从新元素点中挑选距离最近的元素进一步聚类，直到所有元素都被聚集为同一类。分层聚类是一种没有预设条件的聚类模式，它既不需要预先设置类中心，也不需要指定聚成几类。分层聚类采取采用逐层、逐级聚类模式，最终得到一个聚类树。

在 SPSS 中，对于变量的分层聚类叫 R 聚类，其功能是分析多个变量之间的距离关系，实现相似变量的合并，从而实现降维的目标。

(2) 什么是 Q 聚类？有什么特点？

从系统聚类的具体应用的视角看，如果自动分层聚类是以个案作为元素的，那么这种聚类就是分类分析；如果自动分层聚类是以变量作为元素的，那么这种聚类就是降维分析。

面向个案的分层聚类（也叫系统聚类），被称为 Q 聚类，是分类分析中非常重要的操作。

(3) 在 K-Means 聚类中，如何使用已经提供的类别中心点？

根据快速聚类的定义，在执行快速聚类时应该提供待分析的原始数据、聚类数目值和初始的类中心。类中心信息可由指定的数据集或数据文件提供。如果没有提供初始类中心，则需要选择“迭代与分类”模式由系统自动产生类中心。

在 SPSS 的“K-均值聚类分析”主对话框中，把左下角的【读取初始聚类中心】复选框选中，并设置类中心的存储位置为【打开数据集】，为本次聚类指定存储了类中心的数据集名称。

在所有设置完毕，启动 K-快速聚类操作。

(4) 在 K-Means 聚类中，如何才能把每个个案所在的类别号标记每个个案的后边？

在“K-均值聚类分析”的主对话框中，单击右上角的【保存】按钮，打开“K-Means 群集聚类：保存”对话框，如图 5-28 所示。在此对话框中，把【聚类成员】和【与聚类中心的距离】两个复选框选中。

此时，就会在原始数据表中增加了 2 列“QCL_1”和“QCL_2”。

(5) 什么是判别分析？判别分析主要解决哪种问题？

为此，需要根据已被正确分类的样本及其属性，进行数据分析，找出影响样本归类的关键因素，甚至获得一个判定函数；然后依据判定函数，对未来样本进行判别。这就是判别分析。

判别分析的价值主要体现在两个方面：①对未来个案的自动归类或预测；②修正当前已归类个案中的不严谨结论。

(6) 在判别分析中，有两种不同的判别函数式，分别是什么？有什么特点？

在 SPSS 中，判别分析的实现共有 2 种思路，分别是 Fisher 判别和 Bayes 判别。

①Fisher 判别法

所谓 Fisher 判别法，是一种基于多维坐标系的判定方式。如果待研究个案被分为 K 类，那么系统可创建一个 K-1 维的坐标系，每个类别的中心都是坐标系中的一个点，被称之为组质心。Fisher 判别法的目标就是创建 K-1 判别函数式，然后可把待归类个案的各属性取值带入到 K-1 个判别函数式中，最终得到一个由 K-1 个数值构成的坐标点。这个坐标点距离哪个组质心更近，就归类到哪个类别之中。

②Bayes 判别法

Bayes 判别法，也叫分类判别法。它的基本思路是：直接为个案的每个类别产生一个判别函数式，即根据个案的分类类别数直接产生对应数目的判别函数式。如果原始个案被分为 K 类，则直接产生 K 的函数式。对于待判定类别的个案，直接把该个案各属性的取值带入到每个判别函数式中，哪个函数式的值最大，该个案就被划归到哪个类别中。

(7) 在 Fisher 判别法中，如何利用 Fisher 非标准化判别函数式判定某个个案的类别归属呢？

Fisher 判别法的目标就是创建 K-1 判别函数式，然后可把待归类个案的各属性取值带入到 K-1 个判别函数式中，最终得到一个由 K-1 个数值构成的坐标点。这个坐标点距离哪个组质心更近，就归类到哪个类别之中。

假设某个案集的个案被分为 3 类，如果采用 Fisher 判别法就需要构成一个二维的平面直角坐标系，在这个坐标系中由 3 个质心点。在执行 Fisher 判别分析后，系统应该创建两个函数式，分别可以计算出每个个案对应点的 X 坐标和 Y 坐标，然后通过计算这个点与各个质心的距离，找到与当前点距离最小的质心点，从而确定当前个案的归属。

(8) 在 Bayes 分类判别法中，如何利用分类判别函数式判定某个个案的类别归属呢？

Bayes 判别法，也叫分类判别法。它的基本思路是：直接为个案的每个类别产生一个判别函数式，即根据个案的分类类别数直接产生对应数目的判别函数式。如果原始个案被分为 K 类，则直接产生 K 个函数式。对于待判定类别的个案，直接把该个案各属性的取值带入到每个判别函数式中，哪个函数式的值最大，该个案就被划归到哪个类别中。

例如，某原始个案集被分为 4 类，则分别产生了 Y1、Y2、Y3 和 Y4 四个函数式。对于待分类的个案 H，可以把 H 的各个属性值分别带入到函数式 Y1、Y2、Y3 和 Y4 中，然后比较 4 个数值的大小。假设最终结果是 Y3 最大，那么这个个案就属于第 3 类。

(9) 什么是因子分析？主要有什么用途？

基于对样本的观测数据，从中抽取出现潜属性（又称为公共因素）的技术就是因子分析。

在因子分析过程中,需要从多个变量描述中抽取出能够更准确地反应事物性质的若干个潜属性,而且要注意潜属性(公共因素)应该是相对独立的,尽可能是互不相交的。

从本质上,因子分析是一种降维的思想,尽可能使用较少的独立因子表示原有变量中的绝大多数信息。而从其实用应用的视角看,因子分析产生的结果是形成测量变量对因素的描述,从而实现了测量性质准确性和测量结果正确性的描述,因此,因子分析还具有检验数据的结构效度的功能。

(10) 在因子分析中,为什么要进行成份矩阵的旋转?常见的旋转方法是什么?

在因子分析中,理想的情况是:某一主因子仅在某几个观测变量上有较强的载荷,而在其他观测变量上的载荷值很低,这样就可以直接使用这几个观测变量的综合语义来描述该主因子。

然而,在某些情况下,主因子在各个观测变量上的载荷是均衡的,很难直接从观测变量中抽取出主因子的语义。在这种情况下,为了使观测变量对主因子的描述更为集中,可以通过坐标轴的空间变换来改变“主因子”,使得每个主因子都可以对应各自的一组描述变量,这种变换使几何空间上的数据点更加贴近新的坐标轴,从而使观测变量因不同的主因子而被区分开来。这就是旋转变换的概念。

在 SPSS 中,对载荷矩阵实施旋转变换的方法主要有以下几种。①方差最大旋转法。②四次方最大正交旋转。③平均正交旋转。④斜交旋转。⑤直接斜交旋转。

(11) 在因子分析中,可否自行指定要提取的公因子的个数?应该如何做?

在因子分析时,默认的公因子抽取方式是基于“主成份”方法,并且只抽取特征值大于 1 的因子。

如果需要指定被抽取的公因子的个数,则可在“因子分析:抽取”对话框中,利用其左侧中部的“抽取”区域,可以设置新的提取标准。例如限定特征值为 0.8,或者明确规定就要抽取若干个公因子。

(12) 什么是对应分析?能够解决现实生活中的什么问题?

对应分析以两变量的交叉表作为研究对象,通过“降维”的方法,利用图示化的方式,直观地解释变量的不同类别之间的联系,适合于多分类品质型变量的研究。

对应分析是一种视觉化的数据分析方法,它能够将几组看不出任何联系的数据,通过视觉上可以接受的定位图展现出来。主要应用在市场细分、产品定位、地质研究以及计算机工程等领域中。

第 6 章 信度与效度检验

1.单选题 (参考答案)

1.D	2.A	3.A	4.C	5.A
6.	7.	8.	9.	10.

2. 思考题

(1) 什么是信度检验?主要有哪些技术手段?

信度是调研数据与项目评价数据的可靠性中的重要指标,主要指数据的可信程度。信度反应的是调研数据的客观性,即针对收集到的数据,要检验这些数据是否反应客观现象,不是被试随意填报的。信度不检查调研指标体系的科学性,只负责检查调研数据能否真正地反

应被试的意愿，在填报过程中没有随意性。

对于调研所获得的数据，主要可以通过以下几种方法，检验数据的信度。①重测信度；②复本信度；③折半信度；④克朗巴哈系数（ α 系数）。

(2) 什么是克朗巴哈系数？在数据分析中主要有什么作用？

对于反映相同特质的若干个测量项，其测量结果之间应该存在真实的相关性。因此，可以通过检验反应相同特质的若干个测量项之间的一致性水平，来判断调研数据的信度水平。这个测试指标就是克朗巴哈系数（简称为信度 α 系数）。

在数据的信度分析中，常常用于对已有的大量观测数据，评价其一致性水平，从而判断数据的信度水平。

(3) 在 SPSS 中，如何检验多次测量数据的重测信度系数？

在 SPSS 中，对重测信度和复本信度，只需将样本二次测验的数据合并到同一个数据文件，然后利用“相关性”之下的“双变量”求其相关系数，即为重测或复本信度；而评分者信度检验则可以通过 Spearman 等级相关及 Kendall 和谐系数进行验证。

(4) 在 SPSS 中，KMO 和 Bartlett 在信度和效度检验过程中起什么作用？

人们还常常借助因子分析和 Bartlett 的球形检验来对全体测量项的整体结构进行检验，获取评价数据的结构效度。

对于 KMO 的输出结果，普遍认为其度量值在 0.7 以上才开始具有结构效度，在一般程度上支持因子分析，而在 0.8 以上则比较适合因子分析，具有较好的结构效度；在 0.9 以上则非常适合做因子分析。而对于 Bartlett 球形检验，则主要通过其检验概率 Sig 值进行判定，当检验概率 Sig 值 <0.05 时，表示参与检验的变量集具有较好的结构效度。

(5) 什么是专家结构效度？什么是德尔菲方法？

在构造有效的调查（评价）指标体系的过程中，邀请行业专家参与调查指标体系的建设是保证其结构效度的重要手段。基于行业专家所形成的效度，就是专家结构效度。

基于行业专家对调查（评价）指标体系的区分度和覆盖度进行评价和完善，从而保证最终指标体系的科学性和完备性。这种方法就是德尔菲方法。

(6) 在邀请专家参与项目工作并审查调查指标体系的过程中，应该注意哪些问题？

为了能使自己的研究工作顺利开展，并能获得被邀请专家的支持，需要注意以下几个方面的问题。①慎重选择专家，保证专家质量。②尊重专家的地位，严禁群发邮件。③向专家提供清晰的研究目标和研究问题。④以诚恳、积极、严肃的态度请求专家的指导。⑤答谢与回复。