

第4章：主成分分析与典型相关分析

主成分分析

- ❖ 主成分分析的基本原理
- ❖ 主成分分析的解法
- ❖ 主成分分析方法应用实例


问题的提出

- ❖ 地理系统是**多要素的复杂系统**。在地理学研究中，多变量问题是经常会遇到的。**变量太多**，无疑会增加分析问题的难度与复杂性，而且在许多实际问题中，**多个变量之间是具有一定的相关关系的**。
- ❖ 能否在相关分析的基础上，用**较少的新变量**代替原来较多的旧变量，而且使这些较少的新变量**尽可能多地保留原来变量所反映的信息**？
- ❖ **主成分分析方法**就是综合处理这种问题的一种强有力的工具。主成分分析是把原来多个变量**划为少数几个综合指标**的一种统计分析方法。从数学角度来看，这是一种**降维处理技术**。

❖ 多个指标的问题:

❖ 1、指标与指标可能存在相关关系


信息重叠，分析偏误



❖ 2、指标太多，增加问题的复杂性和分析难度



如何避免？



主成分分析的基本思想

一项十分著名的工作是美国统计学家斯通(stone)在1947年关于国民经济的研究。他曾利用美国1929—1938年各年的数据，得到了17个反映国民收入与支出的变量要素，例如雇主补贴、消费资料和生产资料、纯公共支出、净增库存、股息、利息外贸平衡等等。

在进行主成分分析后，竟以97.4%的精度，用三个新变量就取代了原17个变量。根据经济学知识，斯通给这三个新变量分别命名为总收入F1、总收入变化率F2和经济发展或衰退的趋势F3。

主成分分析：将原来具有相关关系的多个指标简化为少数几个新的综合指标的多元统计方法。

主成分：由原始指标综合形成的几个新指标。依据主成分所含信息量的大小成为第一主成分，第二主成分等等。

主成分与原始变量之间的关系：

- (1) 主成分保留了原始变量绝大多数信息。
- (2) 主成分的个数大大少于原始变量的数目。
- (3) 各个主成分之间互不相关。
- (4) 每个主成分都是原始变量的线性组合。

例，成绩数据

- ❖ 100个学生的数学、物理、化学、语文、历史、英语的成绩如下表（部分）。


学生代码	数学	物理	化学	语文	历史	英语
1	65	61	72	84	81	79
2	77	77	76	64	70	55
3	67	63	49	65	67	57
4	80	69	75	74	74	63
5	74	70	80	84	81	74
6	78	84	75	62	71	64
7	66	71	67	52	65	57
8	77	71	57	72	86	71
9	83	100	79	41	67	50
...	...	...	...	...	...	...

从本例可能提出的问题

- ❖ 目前的问题是，能不能把这个数据的6个变量用**一两个综合变量**来表示呢？
- ❖ 这一两个综合变量包含**有多少原来的信息**呢？
- ❖ 能不能利用找到的综合变量来对学生**排序**呢？
这一类数据所涉及的问题可以推广到对企业，对学校进行**分析、排序、判别和分类**等问题。

- ❖ 例中的数据点是**六维**的；也就是说，每个观测值是6维空间中的一个点。我们希望把6维空间用**低维空间**表示。
- ❖ 先假定只有**二维**，即只有两个变量，它们由**横坐标和纵坐标**所代表；因此每个观测值都有相应于这两个坐标轴的两个坐标值；如果这些数据形成一个**椭圆形状**的点阵（这在变量的二维正态的假定下是可能的）。
- ❖ 那么这个椭圆有一个**长轴**和一个**短轴**。在**短轴**方向上，数据变化很少；在极端的情况，短轴如果**退化**成一点，那只有在**长轴**的方向才能够**解释**这些点的变化了；这样，由二维到**一维**的**降维**就自然完成了。

- ❖ 当坐标轴和椭圆的长短轴平行，那么代表长轴的变量就描述了数据的主要变化，而代表短轴的变量就描述了数据的次要变化。
- ❖ 但是，坐标轴通常并不和椭圆的长短轴平行。因此，需要寻找椭圆的长短轴，并进行变换，使得新变量和椭圆的长短轴平行。
- ❖ 如果长轴变量代表了数据包含的大部分信息，就用该变量代替原先的两个变量（舍去次要的一维），降维就完成了。
- ❖ 椭圆（球）的长短轴相差得越大，降维也越有道理。



对于多维变量的情况

- ❖ 对于多维变量的情况和二维类似，也有高维的椭球，只不过无法直观地看见。
- ❖ 首先把高维椭球的主轴找出来，再用代表大多数数据信息的最长的几个轴作为新变量；这样，主成分分析就基本完成。
- ❖ 注意，和二维情况类似，高维椭球的主轴也是互相垂直的。这些互相正交的新变量是原先变量的线性组合，叫做主成分。

- ❖ 正如二维椭圆有两个主轴，三维椭球有三个主轴一样，有几个变量，就有几个主成分。
- ❖ 选择越少的主成分，降维就越好。什么是标准呢？那就是这些被选的主成分所代表的主轴的长度之和占了主轴长度总和的大部分。有些文献建议，所选的主轴总长度占有所有主轴长度之和的大约85%即可，其实，这只是一个大体的说法；具体选几个，要看实际情况而定。

一、主成分分析方法的基本原理

假定有 n 个样本，每个样本共有 p 个变量，构成一个 $n \times p$ 阶的数据矩阵。

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$


- ❖ 当 p 较大时，在 p 维空间中考察问题比较麻烦。为了克服这一困难，就需要进行降维处理，即用较少的几个综合指标代替原来较多的变量指标，而且使这些较少的综合指标既能尽量多地反映原来较多变量指标所反映的信息，同时它们之间又是彼此独立的。

（一）主成分分析的几何解释


❖ 主成分分析的几何意义

∞ 主成分分析的过程就是坐标系旋转的过程，各主成分就是新坐标与原坐标的转换关系，在新坐标系中，各坐标轴的方向就是原始数据变差最大的方向。

- ❖ N个样品无论沿 X_1 轴方向还是沿 X_2 轴方向均有较大的**离散性**，其离散程度可以分别用观测变量 X_1 的**方差**和 X_2 的方差定量地表示
- ❖ 显然，若只考虑 X_1 和 X_2 中的任何一个，原始数据中的信息均会有较大的损失。



$$\left. \begin{aligned} z_{1j} &= x_{1j} \cos \theta + x_{2j} \sin \theta \\ z_{2j} &= x_{1j} (-\sin \theta) + x_{2j} \cos \theta \end{aligned} \right\} (j = 1, 2, \dots, n)$$




（二）特征值、特征向量与方差—协方差矩阵的联系 （主成分的数学解释）

- ❖ 主成分分析的实质就是要求出方差—协方差矩阵的特征向量及其对应的特征值，即要找出方差—协方差矩阵所确定的椭圆的主轴，并确定其长度。
- ❖ 方差—协方差阵的特征向量表示主轴的方向，而其对应的特征值表示主轴的长度。

❖ 例如6个样方（样本）、2个种的多维度数据是：

样本号	1	2	3	4	5	6
物种X ₁	5	6	4	6	0	3
物种X ₂	11	8	7	6	2	2




数据的中心化

$$\bar{x}_1 = \frac{1}{6}(5 + 6 + 4 + 6 + 0 + 3) = 4$$



$$\bar{x}_2 = \frac{1}{6}(11 + 8 + 7 + 6 + 2 + 2) = 6$$

样方	1	2	3	4	5	6	总和
物种X ₁	1	2	0	2	-4	-1	0
物种X ₂	5	2	1	0	-4	-4	0




中心化后的原始数据矩阵

$$X = \begin{bmatrix} 1 & 2 & 0 & 2 & -4 & -1 \\ 5 & 2 & 1 & 0 & -4 & -4 \end{bmatrix}$$



❖ 把坐标轴 X_1 、 X_2 刚性地旋转一个角度，得到图中虚线表示的**新坐标轴 Y_1 和 Y_2** 。



❖ 6个样方点在新坐标系中位置的数据为：

$$Y = \begin{bmatrix} y_{11} & y_{12} & y_{13} & y_{14} & y_{15} & y_{16} \\ y_{21} & y_{22} & y_{23} & y_{24} & y_{25} & y_{26} \end{bmatrix}$$

❖ 与中心化后数据与原始数据有如下关系：

$$\left. \begin{aligned} y_{1j} &= x_{1j} \cos \theta + x_{2j} \sin \theta \\ y_{2j} &= x_{1j} (-\sin \theta) + x_{2j} \cos \theta \end{aligned} \right\} (j = 1, 2, \dots, 6)$$

❖ 写成矩阵的形式有：

$$\begin{aligned} Y &= \begin{bmatrix} y_{11} & y_{12} & y_{13} & y_{14} & y_{15} & y_{16} \\ y_{21} & y_{22} & y_{23} & y_{24} & y_{25} & y_{26} \end{bmatrix} \\ &= \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix} \times \begin{bmatrix} x_{11} & x_{12} & x_{13} & x_{14} & x_{15} & x_{16} \\ x_{21} & x_{22} & x_{23} & x_{24} & x_{25} & x_{26} \end{bmatrix} \\ &= UX \end{aligned}$$

❖ **U是坐标旋转的变换矩阵**，它是正交矩阵，有 $U^T=U^{-1}$ ，即 $UU^T=I$ （I为单位矩阵）

☞ 希望 Y_1 轴就是要找的直线：6个点在该线上垂足的离差平方和最大（即畸变最小）

中心化以后的数据,
相当于对原始数据
的离差求和

$$\sum_{j=1}^6 x_{1j} = \sum_{j=1}^6 x_{2j} = 0$$

$$\left. \begin{aligned} y_{1j} &= x_{1j} \cos \theta + x_{2j} \sin \theta \\ y_{2j} &= x_{1j} (-\sin \theta) + x_{2j} \cos \theta \end{aligned} \right\} (j = 1, 2, \dots, 6)$$

$$\sum_{j=1}^6 y_{1j} = \cos \theta \sum_{j=1}^6 x_{1j} + \sin \theta \sum_{j=1}^6 x_{2j} = 0$$

$$\sum_{j=1}^6 y_{2j} = -\sin \theta \sum_{j=1}^6 x_{1j} + \cos \theta \sum_{j=1}^6 x_{2j} = 0$$

❖ 对刚性旋转后的新轴而言，坐标原点仍在形心
($\bar{Y}_1, \bar{Y}_2$)。于是6个点在 Y_1 轴上垂足的离差平方
和就是它们在 Y_1 轴上坐标之平方和 $\sum_{j=1}^6 y_{1j}^2$ 。

❖ 由
$$\sum_{j=1}^6 y_{1j}^2 = \cos^2 \theta \sum_{j=1}^6 x_{1j}^2 + \sin^2 \theta \sum_{j=1}^6 x_{2j}^2 + 2 \sin \theta \cos \theta \sum_{j=1}^6 x_{1j} x_{2j}$$

❖ 它的取值只依赖于坐标轴旋转角度一个变量，
取极大值的必要条件是对 θ 的导数为0。即

方差最大

$$\frac{d\left(\sum_{j=1}^6 y_{1j}^2\right)}{d\theta} = 2 \cos \theta \sin \theta \left(-\sum_{i=1}^6 x_{1j}^2 + \sum_{j=1}^6 x_{2j}^2 \right) + 2 \cos 2\theta \sum_{j=1}^6 x_{1j} x_{2j}$$

=0

||

$$\sum_{j=1}^6 y_{1j} y_{2j} = \cos \theta \sin \theta \left(-\sum_{j=1}^6 x_{1j}^2 + \sum_{j=1}^6 x_{2j}^2 \right) + \cos 2\theta \sum_{j=1}^6 x_{1j} x_{2j}$$

=0

有前面的公式计算可知

协方差为0

协方差为0

❖ 上述条件等同于 $5Cov(Y_1, Y_2) = \sum_{j=1}^6 y_{1j} y_{2j} = 0$

❖ 因此，如果原坐标旋转后的 Y_1 轴是我们要求的使 $Var(Y_1)$ 最大的直线的话，则必然有 $Var(Y_2)$ 最小，

且 $Cov(Y_1, Y_2) = 0$ 这说明6个样方点对新坐标的离差矩阵应为

方差—协方差
矩阵

$$YY^T = 5 \begin{pmatrix} Var(Y_1) & Cov(Y_1, Y_2) \\ Cov(Y_1, Y_2) & Var(Y_2) \end{pmatrix} = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} = \Lambda$$

协方差矩阵
求解公式

Λ 是对角矩阵，并且 $\lambda_1 \geq \lambda_2$

$$Y = \begin{bmatrix} y_{11} & y_{12} & y_{13} & y_{14} & y_{15} & y_{16} \\ y_{21} & y_{22} & y_{23} & y_{24} & y_{25} & y_{26} \end{bmatrix}$$

$$= UX \quad \longrightarrow \quad Y^T = X^T U^T$$

$$\therefore YY^T = UXX^T U^T = \Lambda$$

其中 XX^T 是已中心化数据的离差矩阵 S ，它是对称的。又因 U 是正交矩阵 $U^T=U^{-1}$ ，则上式可写为： $USU^{-1}=A$

$$XX^T = \begin{bmatrix} 1 & 2 & 0 & 2 & -4 & -1 \\ 5 & 2 & 1 & 0 & -4 & -4 \end{bmatrix} \begin{bmatrix} 1 & 5 \\ 2 & 2 \\ 0 & 1 \\ 2 & 0 \\ -4 & -4 \\ -1 & -4 \end{bmatrix}$$

$$= \begin{bmatrix} 25 & 29 \\ 29 & 62 \end{bmatrix}$$

$$USU^{-1} = \Lambda$$



$$US = \Lambda U = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} U$$

- ❖ λ_1 和 λ_2 是对称离差矩阵 S 的两个特征根
($\lambda_1 \geq \lambda_2$) , 而 U 的每一行是相应的特征向量。

定义：记 $x_1, x_2, \dots, x_p$ 为原变量指标， $z_1, z_2, \dots, z_m$ ($m \leq p$) 为新变量指标

$$\begin{cases} z_1 = l_{11}x_1 + l_{12}x_2 + \dots + l_{1p}x_p \\ z_2 = l_{21}x_1 + l_{22}x_2 + \dots + l_{2p}x_p \\ \vdots \\ z_m = l_{m1}x_1 + l_{m2}x_2 + \dots + l_{mp}x_p \end{cases}$$

特征向量 l_i

❖ 系数 l_{ij} 的确定原则

单位向量 l_i

∞ $l_{i1}^2 + l_{i2}^2 + \cdots + l_{ip}^2 = 1, (i = 1, 2, \cdots, m)$


∞ z_i 与 z_j ($i \neq j; i, j = 1, 2, \cdots, m$) 相互无关。

∞ z_1 是 $x_1, x_2, \cdots, x_p$ 的一切线性组合中方差最大者， z_2 是与 z_1 不相关的 $x_1, x_2, \cdots, x_p$ 的所有线性组合中方差最大者；…… z_m 是与 $z_1, z_2, \cdots, z_{m-1}$ 都不相关的 $x_1, x_2, \cdots, x_p$ 的所有线性组合中方差最大者。则新变量指标 $z_1, z_2, \cdots, z_m$ 分别称为原变量指标 $x_1, x_2, \cdots, x_p$ 的第一，第二， $\cdots$ ，第 m 主成分。

二、主成分分析的解法

(一) 用方差—协方差矩阵求解主成分例

- ❖ 例:设有一组古生物腕足动物贝壳标本的两个变量:长度和宽度.所测量的数据列于表中.



X_1	X_2	X_1	X_2
3	2	12	10
4	10	12	11
6	5	13	6
6	8	13	14
6	10	13	15
7	2	13	17
7	13	14	7
8	9	15	13
9	5	17	13
9	8	17	17
9	14	18	19
10	7	20	20
11	12		

1、方差—协方差的计算

$$\sigma_{x_1}^2 = \frac{1}{n-1} \left(\sum_{i=1}^{25} x_{i1}^2 - \frac{1}{n} \left(\sum_{i=1}^{25} x_{i1} \right)^2 \right)$$

$$= \frac{1}{24} \left(3446 - \frac{1}{25} 73984 \right) = 20.28$$

$$\sigma_{x_2}^2 = 24.06$$

$$\text{Cov} (X_1, X_2) = \text{Cov} (X_2, X_1)$$

$$= \frac{1}{n-1} \left(\sum_{i=1}^{25} x_{i1} x_{i2} - \frac{1}{n} \left(\sum_{i=1}^{25} x_{i1} \cdot \sum_{i=1}^{25} x_{i2} \right) \right)$$

$$= \frac{1}{24} \left(3279 - \frac{1}{25} (272 \times 267) \right)$$

$$= 15.58$$

2、主成分分析的实质

- ❖ 就是要求出方差—协方差矩阵的**特征向量**及其对应的**特征值**，即要找出方差—协方差矩阵所确定的**椭圆的主轴**，并确定其**长度**。

定义1: 设 A 是 n 阶方阵, 若存在数 λ 和非零向量 x ,
使得 $Ax = \lambda x$ ($x \neq 0$)
则称 λ 是 A 的一个特征值,
 x 为 A 的对应于特征值 λ 的特征向量。

$$\begin{aligned} & \text{由 } Ax = \lambda x && \text{或 } (\lambda E - A)x = 0 \\ & \Rightarrow (A - \lambda E)x = 0 && \text{行列式 } |\lambda E - A| = 0 \\ & && (*_{\lambda}) \end{aligned}$$

而 $x \neq 0$, 即齐次线性方程组 $(*_\lambda)$ 有非零解

$$\Leftrightarrow |A - \lambda E| = 0$$

求 A 的特征值 λ 就是求 $|A - \lambda I| = 0$ 的根 λ ,
求 A 的相应于 λ 的特征向量就是求 $|A - \lambda I|x = 0$
的非零解向量.

例 求 $A = \begin{pmatrix} 3 & -1 \\ -1 & 3 \end{pmatrix}$ 的特征值和特征向量

解 A 的特征多项式为

$$\begin{aligned} \begin{vmatrix} 3-\lambda & -1 \\ -1 & 3-\lambda \end{vmatrix} &= (3-\lambda)^2 - 1 \\ &= 8 - 6\lambda + \lambda^2 = (4-\lambda)(2-\lambda) \end{aligned}$$

所以 A 的特征值为 $\lambda_1 = 2, \lambda_2 = 4$.

当 $\lambda_1 = 2$ 时, 对应的特征向量应满足

$$\begin{pmatrix} 3-2 & -1 \\ -1 & 3-2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

即
$$\begin{cases} x_1 - x_2 = 0, \\ -x_1 + x_2 = 0. \end{cases}$$

解得 $x_1 = x_2$, 所以对应的特征向量可取为 $p_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$.


故相应于 $\lambda_1 = 2$ 的全体特征向量为 $kp_1 (k \neq 0)$

当 $\lambda_2 = 4$ 时, 由

$$\begin{pmatrix} 3-4 & -1 \\ -1 & 3-4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \text{ 即 } \begin{pmatrix} -1 & -1 \\ -1 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

解得 $x_1 = -x_2$, 所以对应的特征向量可取为 $p_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$.

故相应于 $\lambda_1 = 4$ 的全体特征向量为 $kp_2 (k \neq 0)$



X_1	X_2	X_1	X_2
3	2	12	10
4	10	12	11
6	5	13	6
6	8	13	14
6	10	13	15
7	2	13	17
7	13	14	7
8	9	15	13
9	5	17	13
9	8	17	17
9	14	18	19
10	7	20	20
11	12		

❖ 由例：

❖ 方差—协方差矩阵为 $\begin{bmatrix} 20.3 & 15.6 \\ 15.6 & 24.1 \end{bmatrix}$

求特征值

$$\therefore \begin{vmatrix} 20.3 - \lambda & 15.6 \\ 15.6 & 24.1 - \lambda \end{vmatrix} \\ = (20.3 - \lambda)(24.1 - \lambda) - 15.6 \times 15.6 = 0$$

$$\therefore \lambda^2 - 44.4\lambda + 245.87 = 0$$

$$\lambda_1 = 37.9, \lambda_2 = 6.5$$

❖ 特征向量的求解

❖ 当 $\lambda_1 = 37.9$ 时,

$$\begin{bmatrix} 20.3 - 37.9 & 15.6 \\ 15.6 & 24.1 - 37.9 \end{bmatrix} \begin{bmatrix} l_{11} \\ l_{12} \end{bmatrix} = 0$$

❖ 化为联立方程

$$\begin{cases} -17.6l_{11} + 15.6l_{12} = 0 \\ 15.6l_{11} - 13.8l_{12} = 0 \end{cases}$$

❖ 求得

$$l_{11} = 0.66, l_{12} = 0.75 \quad \Rightarrow \quad I = \begin{bmatrix} 0.66 \\ 0.75 \end{bmatrix}$$

$$l_{11}^2 + l_{12}^2 = 1$$

❖ 同理求得 $\lambda_2 = 6.5$ 时的特征向量

$$II = \begin{bmatrix} 0.75 \\ -0.66 \end{bmatrix}$$

❖ 算出

∞ 第一主成分I：特征值为37.9，特征向量为

$$I = \begin{bmatrix} 0.66 \\ 0.75 \end{bmatrix}$$

∞ 第二主成分II：特征值为6.5，特征向量为

$$II = \begin{bmatrix} 0.75 \\ -0.66 \end{bmatrix}$$

原数据

- ❖ 特征向量的方向由I、II中包括的两个数字控制。
- ❖ 矩阵的**总方差**为 $20.3+24.1=44.4$ ，变量 X_1 所占的比重为 $20.3/44.4$ ，占总方差的46%， X_2 占总方差的54%。由矩阵代数可知，两个特征值分别为两个特征向量所组成的椭圆的两个主轴的长度，而主轴长度之和可用来表示数据组的总方差。

主成分

- ❖ 第一**主成分** Z_1 的方差为37.9，第二主成分 Z_2 的方差为6.5。两者之和恰为 X_1 和 X_2 的总方差44.4。可见，两个**主成分** Z_1 、 Z_2 所代表的信息分别为86%和14%。如果用 Z_1 代表原来的数据，则仅**损失信息14%**。
- ❖ $\Leftrightarrow$ 用 X_1 和 X_2 来代表原来的数据，则将**损失信息46%或54%**。

3、主成分得分的计算

❖ 根据 (8-3) 式，得到主成分的表达式为

$$Z_1 = 0.66x_1 + 0.75x_2$$

$$Z_2 = 0.75x_1 - 0.66x_2$$

原始数据的主成分得分

$$Z_1 = 0.66x_1 + 0.75x_2$$

$$Z_2 = 0.75x_1 - 0.66x_2$$

Z_1	Z_2	Z_1	Z_2
3.48	0.93	15.42	2.4
10.14	-3.6	16.17	1.74
7.71	1.2	13.08	5.79
9.96	-0.78	19.08	0.51
11.46	-2.1	19.83	-0.15
6.12	3.93	21.33	-1.47
14.37	-3.33	14.49	5.88
12.03	0.06	19.65	2.67
9.69	3.45	20.97	4.17
11.94	1.47	23.97	1.53
16.44	-2.49	26.13	0.96
11.85	2.88	28.2	1.8
16.26	0.33		

（二）用相关系数矩阵做主成分分析的步骤

❖ 对原始数据

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

标准化变量的主成分

❖ 进行标准化处理（标准差标准化），即

$$x_{\alpha j}^* = \frac{x_{\alpha j} - \bar{x}_j}{\sigma_j}$$

❖ 其中 $\bar{x}_j = \frac{1}{N} \sum_{\alpha} x_{\alpha j}$

$$\sigma_j^2 = \frac{1}{N} \sum_{\alpha} (x_{\alpha j} - \bar{x}_j)^2$$

❖ 计算相关系数矩阵R

协方差

$$r_{ij} = \frac{\frac{1}{N} \sum_{\alpha} (x_{\alpha i} - \bar{x}_i)(x_{\alpha j} - \bar{x}_j)}{\sigma_i \sigma_j} = \frac{1}{N} \sum_{\alpha} x_{\alpha i}^* x_{\alpha j}^*$$

标准差

❖ 计算特征值和特征向量

∞ 根据特征方程 $|R - \lambda I| = 0$ 计算特征值，即解

$$r_n \lambda^P + r_{n-1} \lambda^{P-1} + \cdots + r_1 \lambda + r_0 = 0$$

的特征多项式，求 $\lambda_1, \lambda_2, \cdots, \lambda_P$ 并使特征值按从大到小的顺序排列，即

列出关于每个特征值的特征向量 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_P \geq 0$

$$e_k = [e_{k1}, e_{k2}, \cdots, e_{kp}]^T$$

$$\sum_{j=1}^p e_{kj}^2 = 1, (k = 1, 2, \cdots, m)$$

$$R\alpha_k = \lambda\alpha_k \Rightarrow (R - \lambda E)\alpha_k = 0$$

❁ 计算主成分贡献率及累计贡献率

▲ 贡献率:
$$\frac{\lambda_i}{\sum_{k=1}^p \lambda_k} \quad (i = 1, 2, \dots, p)$$

▲ 累计贡献率:
$$\frac{\sum_{k=1}^i \lambda_k}{\sum_{k=1}^p \lambda_k} \quad (i = 1, 2, \dots, p)$$

一般取累计贡献率达85—95%的特征值 $\lambda_1, \lambda_2, \dots, \lambda_m$ 所对应的第一、第二、…、第m ($m \leq p$) 个主成分

第4章：主成分分析

最终结论是：

- 求X的主成分等价于求它的协方差的所有特征值，以及相应的正交单位化特征向量。
- 然后按照特征值由大到小排列，相应的正交化单位特征向量为组合系数的 $X_1, X_2, \dots, X_p$ 的线性组合分别为X的第一，第二，直至第 p 个主成分。
- 各主成分的方差等于相应的特征值。

例4.4

例 4.4 对十家上市公司的获利能力和经营发展能力, 选取如下 6 个指标进行分析。

X_1 : 每股净收益;	X_2 : 净资产收益率;
X_3 : 主营业务收益率;	X_4 : 主营业务增长率;
X_5 : 净资产增长率;	X_6 : 总资产增长率.

下表为前 3 年关于 6 个指标的加权平均, 对其做主成分分析, 并按第一主成份得分对这些公司排序。

例4.4

公司编号	x_1	x_2	x_3	x_4	x_5	x_6
1	0.021	26.806	57.311	-39.819	-39.819	8.819
2	-0.142	-7.179	16.335	-11.359	-4.766	-4.626
3	-0.737	-62.417	7.359	-18.378	-19.165	12.289

解：调用 SPSS 过程，求得

$$S = \begin{bmatrix} 0.1159 & & & & & \\ 7.0381 & 574.0725 & & & & \\ 1.4696 & 227.7623 & 225.3553 & & & \\ 6.6069 & 181.9627 & -112.9742 & 853.5283 & & \\ 7.1765 & 202.1297 & -161.1813 & 653.3790 & 1896.1390 & \\ 3.8325 & 127.4554 & 15.0992 & 323.8963 & 972.8524 & 673.1718 \end{bmatrix}$$

可见样本方差很大，因此从样本相关系数阵分析。

由 SPSS 过程求得相关系数阵 R ：

例4.4

$$R = \begin{bmatrix} 1.000 & 0 & & & & \\ 0.863 & 0 & 1.000 & & & \\ 0.287 & 6 & 0.6332 & 1.000 & & \\ 0.664 & 4 & 0.260 & 0 & -0.257 & 6 & 1.000 & 0 \\ 0.484 & 2 & 0.193 & 7 & -0.246 & 6 & 0.513 & 6 & 1.000 & 0 \\ 0.434 & 0 & 0.205 & 0 & 0.038 & 8 & 0.427 & 3 & 0.861 & 1 & 1.000 & 0 \end{bmatrix}$$

和。

表 4.4 R 的特征值、各主成分贡献率及累计贡献率

k	λ_k^*	贡献率(%)	累计贡献率(%)
1	3.011 1	50.18	50.18
2	1.807 8	30.13	80.31
3	0.834 6	13.91	94.22
4	0.280 2	4.67	98.90
5	0.052 3	0.87	99.77
6	0.014 1	0.23	100.00

例4.4

取前 2 个主成份:

$$y_1^* = 0.5228x_1^* + 0.3968x_2^* + 0.1003x_3^* + 0.4168x_4^* + 0.4440x_5^* + 0.4339x_6^*$$

$$y_2^* = 0.2138x_1^* + 0.5087x_2^* + 0.6553x_3^* - 0.2437x_4^* - 0.3765x_5^* - 0.2549x_6^*$$

表 4.5 λ_1^* 和 λ_2^* 的正交单位化特征向量

标准化指标值	$\hat{e}_1^*$	$\hat{e}_2^*$
x_1^*	0.5228	0.2138
x_2^*	0.3968	0.5087
x_3^*	0.1003	0.6553
x_4^*	0.4168	-0.2437
x_5^*	0.4440	-0.3765
x_6^*	0.4339	-0.2549

y2:
获利能力 - 发展能力

y1: 各指标的综合加权

x1~x3: 获利能力;
x4~x6: 发展能力;

X_1 : 每股净收益; X_2 : 净资产收益率;
 X_3 : 主营业务收益率; X_4 : 主营业务增长率;
 X_5 : 净资产增长率; X_6 : 总资产增长率.

下表为前 3 年关于 6 个指标的加权平均, 对其做主成分分析, 并按第一主成份得分对这些公司排序.

例4.4

y_1^* 获利和发展的综合力; y_2^* 获利与发展能力之差值

公司编号	y_1 的得分	排 名
7	2.470 1	1
10	1.323 4	2
4	1.299 1	3
5	1.026 4	4
9	0.545 9	5
6	0.481 0	6
1	- 0.864 0	7
2	- 1.412 3	8
8	- 1.604 6	9
3	- 3.265 1	10

主成分分析

主成分分析往往不是最终目的，通常是利用主成分分析综合原始数据的信息，达到降低原始数据维数的目的，进而利用少数几个主成分的得分（将样本观测值 x_i 代入各主成分计算公式中，就可以得到各主成分的观测值 y_{ik} ，即各主成分的得分），进行基于主成分的回归分析、聚类分析等。

思考：

1.主成分分析的核心是什么？

2.为什么要标准化变量的主成分？

补充：主成分分析方法应用实例

例, 根据表1中给出的数据，对某农业生态经济系统做主成分分析

表1 某农业生态经济系统各区域单元的有关数据

样本 序号	x ₁ : 人 口密度 (人/km ²)	x ₂ : 人均 耕地面积 (ha)	x ₃ : 森林 覆盖率 (%)	x ₄ : 农民 人均纯收 入(元/人)	x ₅ : 人均 粮食产量 (kg/人)	x ₆ : 经济 作物占农 作物播面 比例(%)	x ₇ : 耕地 占土地面 积比率(%)	x ₈ : 果 园与林 地面积 之比(%)	x ₉ : 灌溉 田占耕地 面积之比 (%)
1	363.912	0.352	16.101	192.11	295.34	26.724	18.492	2.231	26.262
2	141.503	1.684	24.301	1752.35	452.26	32.314	14.464	1.455	27.066
3	100.695	1.067	65.601	1181.54	270.12	18.266	0.162	7.474	12.489
4	143.739	1.336	33.205	1436.12	354.26	17.486	11.805	1.892	17.534
5	131.412	1.623	16.607	1405.09	586.59	40.683	14.401	0.303	22.932

6	68.337	2.032	76.204	1540.29	216.39	8.128	4.065	0.011	4.861
7	95.416	0.801	71.106	926.35	291.52	8.135	4.063	0.012	4.862
8	62.901	1.652	73.307	1501.24	225.25	18.352	2.645	0.034	3.201
9	86.624	0.841	68.904	897.36	196.37	16.861	5.176	0.055	6.167
10	91.394	0.812	66.502	911.24	226.51	18.279	5.643	0.076	4.477
11	76.912	0.858	50.302	103.52	217.09	19.793	4.881	0.001	6.165
12	51.274	1.041	64.609	968.33	181.38	4.005	4.066	0.015	5.402
13	68.831	0.836	62.804	957.14	194.04	9.11	4.484	0.002	5.79
14	77.301	0.623	60.102	824.37	188.09	19.409	5.721	5.055	8.413
15	76.948	1.022	68.001	1255.42	211.55	11.102	3.133	0.01	3.425
16	99.265	0.654	60.702	1251.03	220.91	4.383	4.615	0.011	5.593
17	118.505	0.661	63.304	1246.47	242.16	10.706	6.053	0.154	8.701
18	141.473	0.737	54.206	814.21	193.46	11.419	6.442	0.012	12.945
19	137.761	0.598	55.901	1124.05	228.44	9.521	7.881	0.069	12.654
20	117.612	1.245	54.503	805.67	175.23	18.106	5.789	0.048	8.461
21	122.781	0.731	49.102	1313.11	236.29	26.724	7.162	0.092	10.078

步骤如下：将表中的数据作标准差标准化处理，然后将它们代入公式计算相关系数矩阵

表2 相关系数矩阵

	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9
x_1	1	-0.327	-0.714	-0.336	0.309	0.408	0.79	0.156	0.744
x_2	-0.33	1	-0.035	0.644	0.42	0.255	0.009	-0.078	0.094
x_3	-0.71	-0.035	1	0.07	-0.74	-0.755	-0.93	-0.109	-0.924
x_4	-0.34	0.644	0.07	1	0.383	0.069	-0.05	-0.031	0.073
x_5	0.309	0.42	-0.74	0.383	1	0.734	0.672	0.098	0.747
x_6	0.408	0.255	-0.755	0.069	0.734	1	0.658	0.222	0.707
x_7	0.79	0.009	-0.93	-0.046	0.672	0.658	1	-0.03	0.89
x_8	0.156	-0.078	-0.109	-0.031	0.098	0.222	-0.03	1	0.29
x_9	0.744	0.094	-0.924	0.073	0.747	0.707	0.89	0.29	1

(2) 由相关系数矩阵计算特征值，以及各个主成分的贡献率与累计贡献率（见表3）。由表3可知，第一，第二，第三主成分的累计贡献率已高达86.596%（大于85%），故只需要求出第一、第二、第三主成分 z_1 ， z_2 ， z_3 即可。

表3 特征值及主成分贡献率

主成分	特征值	贡献率(%)	累积贡献率(%)
z_1	4.661	51.791	51.791
z_2	2.089	23.216	75.007
z_3	1.043	11.589	86.596
z_4	0.507	5.638	92.234
z_5	0.315	3.502	95.736
z_6	0.193	2.14	97.876
z_7	0.114	1.271	99.147
z_8	0.0453	0.504	99.65
z_9	0.0315	0.35	100

(3) 对于特征值 $\lambda_1=4.6610$, $\lambda_2=2.0890$, $\lambda_3=1.0430$ 分别求出其特征向量 e_1 , e_2 , e_3 , 再用公式计算各变量 $x_1, x_2, \dots, x_9$ 在主成分 z_1, z_2, z_3 上的载荷（表4）。

表4 主成分载荷

	z_1	z_2	z_3	占方差的百分数 (%)
x_1	0.739	-0.532	-0.0061	82.918
x_2	0.123	0.887	-0.0028	80.191
x_3	-0.964	0.0096	0.0095	92.948
x_4	0.0042	0.868	0.0037	75.346
x_5	0.813	0.444	-0.0011	85.811
x_6	0.819	0.179	0.125	71.843
x_7	0.933	-0.133	-0.251	95.118
x_8	0.197	-0.1	0.97	98.971
x_9	0.964	-0.0025	0.0092	92.939

上述计算过程，可以借助于SPSS或MATLAB软件系统实现。

分析:

- ①第一主成分 z_1 与 x_1, x_5, x_6, x_7, x_9 呈显出较强的正相关, 与 x_3 呈显出较强的负相关, 而这几个变量则综合反映了生态经济结构状况, 因此可以认为第一主成分 z_1 是生态经济结构的代表。
- ②第二主成分 z_2 与 x_2, x_4, x_5 呈显出较强的正相关, 与 x_1 呈显出较强的负相关, 其中, 除了 x_1 为人口总数外, x_2, x_4, x_5 都反映了人均占有资源量的情况, 因此可以认为第二主成分 z_2 代表了人均资源量

③第三主成分 z_3 ，与 x_8 呈显出的正相关程度最高，其次是 x_6 ，而与 x_7 呈负相关，因此可以认为第三主成分在一定程度上代表了农业经济结构

④另外，表4中最后一列（占方差的百分数），在一定程度上反映了三个主成分 z_1 、 z_2 、 z_3 包含原变量（ $x_1, x_2, \dots, x_9$ ）的信息量多少

显然，用三个主成分 z_1 、 z_2 、 z_3 代替原来9个变量（ $x_1, x_2, \dots, x_9$ ），描述农业生态经济系统，可以使问题更进一步简化、明了