

第6章：聚类分析主要内容

- 1 聚类分析的思想
- 2 聚类统计量-相似性度量
- 3 类和类的特征
- 4 系统聚类法
- 5 K-均值聚类和有序样本聚类



复习

1 聚类分析的思想

- 聚类分析就是按照研究对象之间的“相似程度”把对象按一定规则进行分类
- 把相似的对象放到一起，从而使得同一类内的“差异”尽可能小，而不同类别之间的“差异”尽可能大
- 这些类不是事先给定的，而是直接根据数据特征确定的

1 聚类分析的思想

- 对样品的分类常称为 **Q型聚类**
- 对变量的分类常称为 **R型聚类**

数据矩阵

No	x_1	x_2	...	x_p
1	x_{11}	x_{12}	...	x_{1p}
...	...	...	...	...
n	x_{n1}	x_{n2}	...	x_{np}

按什么原则分类？

按对象“相似”程度分类

对变量分类

夹角余弦
相关系数

对样本分类

欧氏距离
马氏距离
兰氏距离

距离计算方法

组间距离选取

类 G_p 与类 G_q 之间的距离 D_{pq}



最短距离法:

$$D_{pq} = \min d(x_i, x_j)$$

最长距离法:

$$D_{pq} = \max d(x_i, x_j)$$

重心法:

$$D_{pq} = d(\bar{x}_p, \bar{x}_q)$$

类平均距离法:

$$D_{pq} = \frac{1}{n_1 n_2} \sum_{x_i \in G_p} \sum_{x_j \in G_q} d(x_i, x_j)$$

离差平方和:(Wald)

$$D_1 = \sum_{x_i \in G_p} (x_i - \bar{x}_p)'(x_i - \bar{x}_p), D_2 = \sum_{x_j \in G_q} (x_j - \bar{x}_q)'(x_j - \bar{x}_q),$$

$$D_{1+2} = \sum_{x_k \in G_p \cup G_q} (x_k - \bar{x})'(x_k - \bar{x}) \Rightarrow D_{pq} = D_{1+2} - D_1 - D_2$$

类间距离用最短距离法衡量的主要缺点

最短距离法的主要缺点是它有链接聚合的趋势，因为类与类之间的距离为所有距离中的最短者，两类合并以后，它与其他类的距离缩小了，这样容易形成一个比较大的类，大部分样品都被聚在一类中，在树状聚类图中，会看到一个延伸的链状结构，所以最短距离法的聚类效果并不好，实际中不提倡使用。

系统聚类法--例子


例1研究我国31个省、市、自治区2001年城镇居民生活消费的分布规律，作区域消费类型划分。

x1: 人均食品支出；x2: 人均衣着商品支出；x3: 人均家庭设备用品及服务支出；x4: 人均医疗保健支出；x5: 人均交通和通信支出；x6: 人均娱乐教育文化服务支出；x7: 人均居住支出；x8: 人均杂项商品和服务支出


表 7 - 3 各地区城镇居民家庭平均每人全年消费性支出 (元/人)

地区	X_1	X_2	X_3	X_4	X_5	X_6	X_7	X_8
1. 北京	3 229.28	821.72	847.39	677.66	768.34	1 429.15	587.98	561.19
2. 天津	2 588.10	531.97	806.36	435.38	585.94	897.02	808.05	334.40
3. 河北	1 583.68	530.02	399.04	420.15	390.24	498.06	461.18	197.39
4. 山西	1 412.95	518.10	316.99	347.49	317.83	567.85	391.06	250.74
5. 内蒙	1 423.22	594.69	292.42	268.88	390.18	548.21	403.69	274.33
6. 辽宁	1 846.11	592.01	272.75	378.31	347.47	575.06	412.09	230.62
7. 吉林	1 650.95	547.04	257.73	325.37	344.97	528.61	453.85	228.70
8. 黑龙江	1 561.00	531.98	259.61	353.48	318.34	534.22	432.09	201.64
9. 上海	4 021.77	577.39	642.08	557.96	875.35	1 359.75	732.44	569.37
10. 江苏	2 194.04	525.88	603.36	297.46	483.77	691.50	438.16	298.58
11. 浙江	2 888.28	669.03	926.68	532.69	689.00	1 065.10	724.46	457.15

#欧氏距离 最短距离法




#欧氏距离 最长距离法



D
hclust (*, "complete")

#欧氏距离 类平均法





5 K-均值聚类

K-均值法(快速聚类法)

- 非谱系聚类法是把样品（而不是变量）聚集成K个类的集合。类的个数K可以预先给定，或者在聚类过程中确定。非谱系方法可应用于比系统聚类法大得多的数据组。
- 非谱系聚类法或者一开始就对元素分组，或者从一个构成各类核心的“种子”集合开始。
 - 选择好的初始构形，将能免除系统的偏差。
 - 一种方法是从所有项目中随机地选择“种子”点或者随机地把元素分成若干个初始类。

- K-均值法, 又叫快速聚类法, 是Macqueen于1967年提出的, 其思想是把每个样品聚集到其最近形心(均值)类中去。在它的最简单说明中, 这个过程由下列三步所组成:
1. 把样品粗略分成K个初始类;
 2. 进行修改, 逐个分派样品到其最近均值的类中去(通常用标准化数据或非标准化数据计算欧氏距离)。重新计算接受新样品的类和失去样品的类的形心(均值);
 3. 重复第2步, 直到各类无元素进出。

基本思想： 开始先**初步分类**，然后按照某种最优的原则**修改**不合理的分类，直到类分的比较合理为止



聚类循环的终止










聚类循环什么时候终止呢？

随着循环次数逐渐增加，分类是趋于稳定的。

即样品点还是一直属于某一个类，不会被归到其他类中。

此时，第 m 个类的重心新就会无限接近于第 $m+1$ 个类的重心。甚至相同，也就是说分类趋于稳定。

聚类算法可以结束。




选择初始聚点


1) 经验选择。

如果对研究对象比较了解，根据以往的经验定下 k 个对象作为聚点。


2) 随机选定 k 个对象作为聚点




(a) 迭代 1



(b) 迭代 2




(c) 迭代 3




(d) 迭代 4

聚类效果
不佳


随机选择初始质心




(a) 迭代 1



(b) 迭代 2



(c) 迭代 3



(d) 迭代 4

聚类效果
不佳

初始质心选择

- **3)** 将 **n** 个样品随机地分成 **k** 类，以每类的重心作为聚点。

初始质心选择

4) **最小最大原则**。先选择所有样品中距离最远的两个样品

$\mathbf{x}_{i_1}$, $\mathbf{x}_{i_2}$ 为前两个聚点, 然后, 选择第**3**个聚点 $\mathbf{x}_{i_3}$, 使得其与前两个聚点的距离较小者最大。用公式表示为

$$\begin{aligned} & \min\{d(x_{i_3}, x_{i_r}), r = 1, 2\} \\ & = \max\{\min[d(x_j, x_{i_r}), r = 1, 2], j \neq i_1, i_2\}. \end{aligned}$$

然后按相同的原则选取 $\mathbf{x}_{i_4}$, 依次下去, 直至选定**k**个聚点

例 6.1

例 6.1 根据表 6.1, 把 13 个国家分成 4 类.

表 6.1 13 个国家可持续发展综合国力的评估得分

序 号	国 家	1990 年	1995 年	2000 年
1	澳大利亚	1 249.39	1 273.61	1 282.68
2	巴西	821.60	859.85	919.73
3	加拿大	1 641.01	1 591.54	1 608.32
4	中国	1 330.45	1 382.68	1 462.08

类间距离 & 距离的递推公式


类间距离

- 由于类的形式和形状多种多样，所以类与类之间的距离有多种定义与计算方法。

类 G_p 与 G_q 之间的距离记为 D_{pq} 。

(1) 最短距离


$$D_{pq} = \min_{i \in G_p, j \in G_q} d_{ij}, \quad (6.16)$$



类间距离

(2) 最长距离

$$D_{pq} = \max_{i \in G_p, j \in G_q} d_{ij},$$



即用两类中样品之间的距离最长者作为两类距离。

(3) 类平均距离


$$D_{pq} = \frac{1}{n_p n_q} \sum_{i \in G_p} \sum_{j \in G_q} d_{ij},$$

即用两类中所有两两样品之间的距离平均作为两类之间的距离。类平均距离还可用于下列方式定义：

$$D_{pq}^2 = \frac{1}{n_p n_q} \sum_{i \in G_p} \sum_{j \in G_q} d_{ij}^2,$$

类间距离

(4) 重心距离



$$D_{pq} = d(\bar{x}_p, \bar{x}_q),$$

其中 $\bar{x}_p, \bar{x}_q$ 分别是 G_p, G_q 的重心。这是用两类的重心之间的距离作为两类距离。

(5) 离差平方和距离

$$D_1 = \sum_{x_i \in G_p} (x_i - \bar{x}_p)'(x_i - \bar{x}_p), D_2 = \sum_{x_j \in G_q} (x_j - \bar{x}_q)'(x_j - \bar{x}_q),$$

$$D_{1+2} = \sum_{x_k \in G_p \cup G_q} (x_k - \bar{x})'(x_k - \bar{x}) \Rightarrow D_{pq} = D_{1+2} - D_1 - D_2$$

类间距离的递推公式

(1) 最短距离

$$D_{rk} = \min\{D_{pk}, D_{qk}\}.$$

(2) 最长距离

$$D_{rk} = \max\{D_{pk}, D_{qk}\}.$$

(3) 类平均距离

$$D_{rk} = \frac{n_p}{n_r} D_{pk} + \frac{n_q}{n_r} D_{qk}.$$

类间距离的递推公式

(4) 重心距离
$$D_{rk}^2 = \frac{n_p}{n_r} D_{pk}^2 + \frac{n_q}{n_r} D_{qk}^2 - \frac{n_p}{n_r} \frac{n_q}{n_r} D_{pq}^2. \quad (6.26)$$

由 G_p, G_q 合并集 G_r 的重心是 $\bar{x}_r = \frac{1}{n_r} (n_p \bar{x}_p + n_q \bar{x}_q).$

类间距离的递推公式

(5) 离差平方和距离

$$D_{rk}^2 = \frac{n_p + n_k}{n_r + n_k} D_{pk}^2 + \frac{n_q + n_k}{n_r + n_k} D_{qk}^2 - \frac{n_k}{n_r + n_k} D_{pq}^2.$$

类间距离的递推公式

- 在一定条件下，以上介绍的**5**种类间距离的递推公式可以构成统一的形式。假定观测样品之间的距离皆采用欧式平方距离，即

则类间距离递推公式有统一的形式：

$$d_{ij}^2 = d^2(x_i, x_j) = (x_i - x_j)^T (x_i - x_j) = \|x_i - x_j\|^2,$$

$$D_{kr}^2 = \alpha_p D_{kp}^2 + \alpha_q D_{kq}^2 + \beta D_{pq}^2 + \gamma |D_{kp}^2 - D_{kq}^2|.$$

类间距离的递推公式

$$D_{kr}^2 = \alpha_p D_{kp}^2 + \alpha_q D_{kq}^2 + \beta D_{pq}^2 + \gamma |D_{kp}^2 - D_{kq}^2|.$$

类间距离的参数

距离名称	α_p	α_q	β	γ
最短距离	$\frac{1}{2}$	$\frac{1}{2}$	0	$-\frac{1}{2}$
最长距离	$\frac{1}{2}$	$\frac{1}{2}$	0	$\frac{1}{2}$
类平均距离	$\frac{n_p}{n_r}$	$\frac{n_q}{n_r}$	0	0
重心距离	$\frac{n_p}{n_r}$	$\frac{n_q}{n_r}$	$\alpha_p \alpha_q$	0
离差平方和距离	$\frac{n_k + n_p}{n_k + n_r}$	$\frac{n_k + n_q}{n_k + n_r}$	$-\frac{n_k}{n_k + n_r}$	0

例6.5

例 6.5 测量中学生 8 个体型指标(变量), 即

$$X_1, X_2, \dots, X_8$$










分别表示: 身高; 手臂长; 手肘长; 小腿长; 体重;
二转子的直径; 胸围; 胸宽.

8 个指标的观测向量的相关系数阵为,

令 $D = (1 - r_{ij})$ 出发, 用

(1) 类平均距离法; (2) 最长距离法;

进行聚类分析, 并给出聚为两类的结果.



凝聚计划

阶段	组合的集群		系数	首次出现阶段集群		下一个阶段
	集群 1	集群 2		集群 1	集群 2	
1	6	7	285.550	0	0	5
2	2	8	884.000	0	0	4
3	1	4	2997.000	0	0	4
4	1	2	3893.000	3	2	6
5	5	6	5369.441	0	1	7
6	1	3	7115.250	4	0	7
7	1	5	13898.232	6	5	0

