

# 第3章：方差分析

两类变量：定量变量 连续取值，计数取值；

定性变量 性质标记，称为因素。

方差分析：因素取不同状态时，对因变量的影响。

**对应SPSS软件中的“分析” ---- “比较平均值” ---- “单因素ANOVA”**

## §3.1 单因素方差分析

因素的水平：因素的不同状态；

因素  $A$  的  $a$  个水平：  $A_1, A_2, \dots, A_a$ ，等等。

例如某农作物产量  $Y$ ，作物品种  $A$ ，化肥品种  $B$ ，

连续性随机  
变量

$A_1, A_2, A_3; B_1, B_2, B_3, B_4$



# 第3章：方差分析

主要思想为显著性检验，即

$Y$  的总变化量=各因素各水平及交互影响+随误影响

1. 单因素方差分析模型  $y_{ij} \sim N(\mu_i, \sigma^2), \quad j = 1, 2, \dots, n_i$

设所关心变量为  $Y$ , 影响  $Y$  的因素为  $A$ , 有  $a$  个水平,

假设如下表: (各样本独立, 同方差)

| 因素 $A$ 的水平 | 总 体                  | 样 本                               |
|------------|----------------------|-----------------------------------|
| $A_1$      | $N(\mu_1, \sigma^2)$ | $y_{11}, y_{12}, \dots, y_{1n_1}$ |
| $A_2$      | $N(\mu_2, \sigma^2)$ | $y_{21}, y_{22}, \dots, y_{2n_2}$ |
| $\vdots$   | $\vdots$             | $\vdots$                          |
| $A_a$      | $N(\mu_a, \sigma^2)$ | $y_{a1}, y_{a2}, \dots, y_{an_a}$ |



# 基础的定义

$$y_{ij} \sim N(\mu_i, \sigma^2), \quad j = 1, 2, \dots, n_i$$

令  $\varepsilon_{ij} = y_{ij} - \mu_i, \quad j = 1 \sim n_i, \quad i = 1 \sim a$

则有(相当于  $a$  个回归模型)

$$\begin{cases} y_{ij} = \mu_i + \varepsilon_{ij}, & j = 1 \sim n_i, i = 1 \sim a \\ \varepsilon_{ij} \sim N(0, \sigma^2), \text{且诸 } \varepsilon_{ij} \text{ 相互独立} \end{cases} \quad (3.1)$$

单因素方差  
分析模型

称  $n = \sum_{i=1}^n n_i$  为总容量;

$$\mu = \frac{1}{n} \sum_{i=1}^n n_i \mu_i \text{ 为总平均;}$$

总平均

$\delta_i = \mu_i - \mu, \quad i = 1 \sim a$  为水平  $A_i$  的效应(影响度).



# 第3章：方差分析

且满足  $\sum_{i=1}^a n_i \delta_i = 0$ ，最后归结为

$$\begin{cases} y_{ij} = \mu + \delta_i + \varepsilon_{ij}, j = 1 \sim n_i, i = 1 \sim a \\ \varepsilon_{ij} \sim N(0, \sigma^2), \text{且诸 } \varepsilon_{ij} \text{ 相互独立} \\ \sum_{i=1}^a n_i \delta_i = 0 \end{cases} \quad (3.2)$$

改写后的  
方差分析模  
型

## 2. 因素效应的显著性检验

对于单因素，

目标之一：该因素各水平对  $Y$  取值有无显著差异。

即检验如下假设。



# 第3章：方差分析

$$H_0: \mu_1 = \mu_2 = \cdots = \mu_a \leftrightarrow$$

**$H_0$ : 假设各水平对结果  
无显著影响:  $\mu$ 相等**

$$H_1: \mu_i (i=1 \sim a) \text{ 不全相等 (3.3)}$$

等价地, 对模型(3.2), 检验假设

$$H_0: \delta_1 = \delta_2 = \cdots = \delta_a = 0 \leftrightarrow$$

$$H_1: \text{至少有某个 } \delta_i \neq 0 \text{ (3.4)}$$

分解影响且设计统计量

令

$$\bar{\varepsilon}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} \varepsilon_{ij}, \text{ 则 } \bar{\varepsilon}_{i\cdot} \sim N(0, \frac{\sigma^2}{n_i}), i=1 \sim a$$



# 第3章：方差分析

$$\bar{\varepsilon} = \frac{1}{n} \sum_{i=1}^a \sum_{j=1}^{n_i} \varepsilon_{ij} = \frac{1}{n} \sum_{i=1}^a n_i \bar{\varepsilon}_{i\cdot}, \text{ 则 } \bar{\varepsilon} \sim N(0, \frac{\sigma^2}{n}),$$

$$\bar{y}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij} \stackrel{\text{即}}{=} \frac{1}{n_i} \sum_{j=1}^{n_i} (\mu + \delta_i + \varepsilon_{ij}) = \mu + \delta_i + \bar{\varepsilon}_{i\cdot},$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^a \sum_{j=1}^{n_i} y_{ij} = \frac{1}{n} \sum_{i=1}^a n_i \bar{y}_{i\cdot}, \text{ 则 } \bar{y} = \mu + \bar{\varepsilon}$$

数据的总变化量

总平方和:

$$SS_T = \sum_{i=1}^a \sum_{j=1}^{n_i} (y_{ij} - \bar{y})^2$$

数据的总变化量



# 第3章：方差分析

分解为

$$SS_T = \sum_{i=1}^a \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.} + \bar{y}_{i.} - \bar{y})^2 \quad (\text{展开交叉项}=0)$$

$$= \sum_{i=1}^a \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2 + \sum_{i=1}^a \sum_{j=1}^{n_i} (\bar{y}_{i.} - \bar{y})^2$$

$$\triangleq SS_E \text{ (误差平方和)} + SS_A \text{ (因素 } A \text{ 的平方和)}$$

书上有证明  
p101

与前面所学“回归方程显著性检验”类似

基本分析

1)  $y_{ij} - \bar{y}_{i.} \approx y_{ij} - \mu_i = \varepsilon_{ij}$

对假设检验统计量的推导

2)  $SS_A$  随  $\bar{y}_{1.}, \bar{y}_{2.}, \dots, \bar{y}_{a.} \approx \mu_1, \mu_2, \dots, \mu_a$  差异小而小



# 第3章：方差分析

$SS_E, SS_A$  的统计性质。

对于因素的  
单个水平

令  $s_i^2 = \frac{1}{n_i - 1} \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2$ ，则  $E(s_i^2) = \sigma^2$ ，从而。

$$E(SS_E) = \sum_{i=1}^a E((n_i - 1)s_i^2) = \sum_{i=1}^a (n_i - 1)\sigma^2$$
$$= (n - a)\sigma^2,$$

对于总的误差平方和  $SS_E$

无论  $H_0$  成立否， $\frac{SS_E}{n - a}$  是  $\sigma^2$  的一个无偏估计。

另一面，因。



# 第3章：方差分析

$$\begin{aligned} SS_A &= \sum_{i=1}^a n_i (\mu + \delta_i + \bar{\varepsilon}_{i\cdot} - \mu - \bar{\varepsilon})^2 \\ &= \sum_{i=1}^a n_i \delta_i^2 + \sum_{i=1}^a n_i (\bar{\varepsilon}_{i\cdot} - \bar{\varepsilon})^2 + 2 \sum_{i=1}^a n_i \delta_i (\bar{\varepsilon}_{i\cdot} - \bar{\varepsilon}) \\ &= (a-1)\sigma^2 + \sum_{i=1}^a n_i \delta_i^2 \end{aligned}$$

$$\text{所以 } E\left(\frac{SS_A}{a-1}\right) = \sigma^2 + \frac{1}{a-1} \sum_{i=1}^a n_i \delta_i^2,$$

从而可知



# 第3章：方差分析

当  $H_0: \delta_i = 0, i = 1 \sim a$  为真,  $\frac{SS_A}{a-1}$  是  $\sigma^2$  无偏估计.

否则, 有偏大趋势, 构造统计量

$$F = \frac{SS_A / (a-1)}{SS_E / (n-a)} \triangleq \frac{MS_A (\text{因素A的均方})}{MS_E (\text{误差均方})}$$

方差比率

当  $H_0$  为真, 则  $F$  应在 1 波动, 否则趋大.

因为

正态分布标准化  
 $\Rightarrow$  卡方分布

$$\frac{n_i - 1}{\sigma^2} s_i^2 = \frac{1}{\sigma^2} \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2 \sim \chi^2(n_i - 1)$$

$(i = 1 \sim a)$



# 第3章：方差分析

又由各总体样本的相互独立性、 $\chi^2$ 的可加性，得

$$\frac{SS_E}{\sigma^2} = \sum_{i=1}^a \frac{n_i - 1}{\sigma^2} s_i^2 \sim \chi^2 \left( \sum_{i=1}^a (n_i - 1) \right) = \chi^2 (n - a).$$

另有(参见[4])  $\frac{SS_A}{\sigma^2} \sim \chi^2 (a-1)$  且与  $SS_E$  独立，

故当  $H_0$  真，

$$F = \frac{MS_A}{MS_E} \sim F(a-1, n-a)$$

检验统计量

检验的  $p$  值为



# 第3章：方差分析

$$p = P_{H_0}(F \geq f) = P(F(a-1, n-a) \geq f).$$

对给出的  $\alpha$ ,

若  $p < \alpha$ , 则拒绝  $H_0$ , 各水平的效应有显著差异;

否则, 不能拒绝, 认为各水平的效应无显著差异.

例 3.1 幼鼠对三种食谱的体重增加量的数据如下,



# 第3章：方差分析

试分析营养效果是否明显差异.

| 食谱 | 体重增加量 |     |     |     |     |     |     |     |
|----|-------|-----|-----|-----|-----|-----|-----|-----|
| 甲  | 164   | 190 | 203 | 205 | 206 | 214 | 228 | 257 |
| 乙  | 185   | 197 | 201 | 231 |     |     |     |     |
| 丙  | 187   | 212 | 215 | 220 | 248 | 265 | 281 |     |

解 调用 `proc anova(example3_1)`, 计算得到:

| 方差来源 | 自由度 | 平方和          | 均方          | F 值  | p 值     |
|------|-----|--------------|-------------|------|---------|
| 因素 A | 2   | 3 011.094 9  | 1 505.547 5 | 1.87 | 0.186 3 |
| 误差   | 16  | 12 882.589 3 | 805.161 8   |      |         |
| 总和   | 18  | 15 893.684 2 |             |      |         |

$p = 0.1863$  较大, 不能拒绝  $H_0$ , 认为无明显差异.



例 3.2 分析四个实验室试制的纸张光滑度有无差异。

| 实验室   | 纸张光滑度 |      |      |      |      |      |      |      |
|-------|-------|------|------|------|------|------|------|------|
| $A_1$ | 38.7  | 41.5 | 43.8 | 44.5 | 45.5 | 46.0 | 47.7 | 58.0 |
| $A_2$ | 39.2  | 39.3 | 39.7 | 41.4 | 41.8 | 42.9 | 43.3 | 45.8 |
| $A_3$ | 34.0  | 35.0 | 39.0 | 40.0 | 43.0 | 43.0 | 44.0 | 45.0 |
| $A_4$ | 34.0  | 34.8 | 34.8 | 35.4 | 37.2 | 37.8 | 41.2 | 42.8 |

( $\alpha = 0.05$ )

解：调用 `proc anova(example3_2)`，计算得到。

| 方差来源 | 自由度 | 平方和       | 均方       | F 值  | p 值     |
|------|-----|-----------|----------|------|---------|
| 因素 4 | 3   | 294.880 9 | 98.293 6 | 6.03 | 0.002 7 |
| 误差   | 28  | 456.598 8 | 16.307 1 |      |         |
| 总和   | 31  | 751.479 7 |          |      |         |

$p = 0.027$  较小，四个实验室并不全相同，其中必有一个有明显差异。



### 例 3.2 分析四个实验室试制的纸张光滑度有无差异.

| 实验室   | 纸张光滑度 |      |      |      |      |      |      |      |
|-------|-------|------|------|------|------|------|------|------|
| $A_1$ | 38.7  | 41.5 | 43.8 | 44.5 | 45.5 | 46.0 | 47.7 | 58.0 |
| $A_2$ | 39.2  | 39.3 | 39.7 | 41.4 | 41.8 | 42.9 | 43.3 | 45.8 |
| $A_3$ | 34.0  | 35.0 | 39.0 | 40.0 | 43.0 | 43.0 | 44.0 | 45.0 |
| $A_4$ | 34.0  | 34.8 | 34.8 | 35.4 | 37.2 | 37.8 | 41.2 | 42.8 |

( $\alpha = 0.05$ )

解: 调用 `proc anova(example3_2)`, 计算得到.

| 方差来源 | 自由度 | 平方和       | 均方       | F 值  | p 值     |
|------|-----|-----------|----------|------|---------|
| 因素 4 | 3   | 294.880 9 | 98.293 6 | 6.03 | 0.002 7 |
| 误差   | 28  | 456.598 8 | 16.307 1 |      |         |
| 总和   | 31  | 751.479 7 |          |      |         |

$p = 0.027$  较小, 四个实验室并不全相同, 其中必有一个有明显差异.



# 各水平平均值的估计与比较

## 3. 因素各水平平均值的估计与比较

当知道各因素水平不全相同时，需要做下面两步，

(1) 各水平平均值的估计及其置信区间

$\bar{y}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij}$  是  $\mu_i$  的一个无偏估计，及

$$\bar{y}_{i\cdot} \sim N\left(\mu_i, \frac{\sigma^2}{n_i}\right) \Rightarrow \frac{\bar{y}_{i\cdot} - \mu_i}{\sqrt{\sigma^2/n_i}} \sim N(0,1)$$

由它与  $s_i^2$  (即与  $SS_E = \sum_{i=1}^n (n_i - 1)s_i^2$ ) 独立性及



# 点估计与区间估计:

□ 矩估计与极大似然估计，都是一种点估计。

□ 点估计的两个缺陷：

(1) 不能说明估计值与真值的偏差到底有多大(精确性)；

(2) 不能说明这个估计有多大的可信度(可靠性)；

□ 区间估计是指用一个(随机)区间去做未知参数 $\theta$ 的估计，可以解决这两个不足。



# 区间估计的步骤

(1) 选取一个合适的随机变量 $T$ , 这个随机变量一方面包括了待估参数 $\theta$ , 另一方面, 它的分布是已知的;

(2) 根据实际需要, 选取合适的置信度 $1-\alpha$ ;

(3) 根据相应分布的分位数概念, 写出如下

形式的概率表达式

$$P\{T_1 < T < T_2\} = 1 - \alpha$$

(4) 将上式表达式变形为 $P\{\hat{\theta}_1 < \theta < \hat{\theta}_2\} = 1 - \alpha$

(5) 写出参数 $\theta$ 的置信区间 $(\hat{\theta}_1, \hat{\theta}_2)$

# 第3章：方差分析

$$\frac{SS_E}{\sigma^2} \sim \chi^2(n-a), \text{ 可得}$$

$\sim N(0,1)$

$$\frac{\frac{\bar{y}_{i\cdot} - \mu_i}{\sqrt{\sigma^2/n_i}}}{\sqrt{\frac{SS_E}{\sigma^2} / (n-a)}} = \frac{\sqrt{n_i}(\bar{y}_{i\cdot} - \mu_i)}{\sqrt{MS_E}} \sim t(n-a)$$

t分布

$\sim \chi^2(n-a)$

假设X服从标准正态分布 $N(0,1)$ ，Y服从 $\chi^2(n)$ 分布，那么 $Z = \frac{X}{\sqrt{Y/n}}$ 的分布称为自由度为n的t分布。

对给定的置信水平 $\alpha$ ，由

$$P\left(\left|\frac{\sqrt{n_i}(\bar{y}_{i\cdot} - \mu_i)}{\sqrt{MS_E}}\right| \leq t_{1-\frac{\alpha}{2}}(n-a)\right) = 1 - \alpha$$

可求出均值的 $1-\alpha$ 置信区间的值



# 各均值差异的置信区间

得置信区间为

$$\left( \bar{y}_{i\cdot} - t_{1-\frac{\alpha}{2}}(n-a)\sqrt{\frac{MS_E}{n_i}}, \bar{y}_{i\cdot} + t_{1-\frac{\alpha}{2}}(n-a)\sqrt{\frac{MS_E}{n_i}} \right)$$

。

(2) 各对均值差异的置信区间。

因素水平  $A_i$  和  $A_j$  上的  $\mu_i - \mu_j$  的点估计与区间估计。

由  $\bar{y}_{i\cdot}$  与  $\bar{y}_{j\cdot}$  独立等性质，得

$$\bar{y}_{i\cdot} - \bar{y}_{j\cdot} \sim N\left( \mu_i - \mu_j, \left( \frac{1}{n_i} + \frac{1}{n_j} \right) \sigma^2 \right)$$



# 第3章：方差分析

从而有

$$\frac{\bar{y}_{i\cdot} - \bar{y}_{j\cdot} - (\mu_i - \mu_j)}{\sqrt{\left(\frac{1}{n_i} + \frac{1}{n_j}\right) \sigma^2}} \sim N(0, 1)$$

正态分布

与  $SS_E$  独立, 得

$$\frac{\bar{y}_{i\cdot} - \bar{y}_{j\cdot} - (\mu_i - \mu_j)}{\sqrt{\left(\frac{1}{n_i} + \frac{1}{n_j}\right) \sigma^2}} \bigg/ \sqrt{\frac{SS_E}{\sigma^2} / (n-a)} \sim t(n-a)$$

t分布

即



# 第3章：方差分析

$$\frac{\bar{y}_{i\cdot} - \bar{y}_{j\cdot} - (\mu_i - \mu_j)}{\sqrt{\left(\frac{1}{n_i} + \frac{1}{n_j}\right) MS_E}} \sim t(n-a)$$

t分布

由此可得置信区间:

$$\left( \bar{y}_{i\cdot} - \bar{y}_{j\cdot} - t_{1-\frac{\alpha}{2}}(n-a) \sqrt{\left(\frac{1}{n_i} + \frac{1}{n_j}\right) MS_E}, \right.$$

置信区间

$$\left. \bar{y}_{i\cdot} - \bar{y}_{j\cdot} + t_{1-\frac{\alpha}{2}}(n-a) \sqrt{\left(\frac{1}{n_i} + \frac{1}{n_j}\right) MS_E} \right)$$



# 第3章：方差分析

---

若含 0, 则认为  $\mu_i$  与  $\mu_j$  无明显差异;

若在 0 左侧, 则认为  $\mu_i < \mu_j$  ;

若在 0 右侧, 则认为  $\mu_i > \mu_j$  .



# 第3章：方差分析

例 3.3 续上例求各实验室的均值及之差的置信区间,

$$\alpha = 0.05.$$

解：调用 SAS 直接获得。

$$\bar{y}_{1,2,3,4} = 45.712, 41.675, 40.375, 37.25.$$

$$n_{1,2,3,4} = 8, MS_E = 16.307, t_{0.975}(28) = 2.048 \Rightarrow$$

(42.788, 48.637), (38.751, 44.600), (37.451, 43.300)等。

$$\mu_1 - \mu_2: (-0.098, 8.173); \quad \mu_1 - \mu_3: (1.202, 9.473)$$

$$\mu_1 - \mu_4: (4.327, 12.598); \quad \mu_2 - \mu_3: (-2.836, 5.436)$$

$$\mu_2 - \mu_4: (0.289, 8.561); \quad \mu_3 - \mu_4: (-1.011, 7.261)$$



# 多重比较及Bonferroni同时置信区间

$\mu_1, \mu_2, \mu_3$  无显著差异,  $\mu_1 > \mu_{3,4}, \mu_2 > \mu_4$  较显著.

## (3) 多重比较及Bonferroni同时置信区间

多重比较  
同时置信区间

若因素  $A$  有  $\alpha$  个水平, 则需检  $C_\alpha^2 = \frac{\alpha(\alpha-1)}{2}$  对,

$$\begin{aligned} \alpha &= 0.05 \\ 1-\alpha &= 0.95 \end{aligned}$$

数量过多计算复杂, 最主要的是, 理论上行不通, 因为Bonferroni证明了.

若  $P(E_i) = 1 - \alpha, i = 1 \sim m$ , 则

需同时检验的  
事件个数  $m$

$$P\left(\bigcap_{i=1}^m E_i\right) = 1 - P\left(\bigcup_{i=1}^m \bar{E}_i\right) \geq 1 - \sum_{i=1}^m P(\bar{E}_i) \geq 1 - m\alpha$$

# 第3章：方差分析

为此，可先设每个

$$P(E_i) = 1 - \frac{\alpha}{m}, \quad i = 1 \sim m$$

则

除以  $m$

$$P\left(\bigcap_{i=1}^m E_i\right) \geq 1 - \alpha$$

应用此思想，设

综合置信区间  
为  $1 - \alpha$

$$E_i = \{\text{每对均值比较}\}$$

**Bonferroni校正：**如果在同一数据集上同时检验  $n$  个独立的假设，那么用于每一假设的统计显著水平，应为仅检验一个假设时的显著水平的  $1/n$ 。



# 第3章：方差分析

$$= \left( \frac{|\bar{y}_{i\cdot} - \bar{y}_{j\cdot} - (\mu_i - \mu_j)|}{\sqrt{(1/n_i + 1/n_j) MS_E}} \leq t \right)$$

即选  $t = t_{1-\frac{\alpha}{2m}}(n-a)$ , 使

$$P \left( \frac{|\bar{y}_{i\cdot} - \bar{y}_{j\cdot} - (\mu_i - \mu_j)|}{\sqrt{(1/n_i + 1/n_j) MS_E}} \leq t_{1-\frac{\alpha}{2m}}(n-a) \right) = 1 - \frac{\alpha}{m}$$

这时, 这  $m$  个事件同时发生的概率  $> 1 - \alpha$ , 由此得 Bonferroni 置信区间。



# 第3章：方差分析

$$\left( \bar{y}_{i\cdot} - \bar{y}_{j\cdot} - t_{1-\frac{\alpha}{2m}}(n-a) \sqrt{\left( \frac{1}{n_i} + \frac{1}{n_j} \right) MS_E}, \right. \\ \left. \bar{y}_{i\cdot} - \bar{y}_{j\cdot} + t_{1-\frac{\alpha}{2m}}(n-a) \sqrt{\left( \frac{1}{n_i} + \frac{1}{n_j} \right) MS_E} \right)$$

对单因素方差分析中，一般取  $m = \frac{1}{2}a(a-1)$ 。缺点是较保守，有改进方法(Thkey等)。



## 例 3.4

例3,4 续例3.3,求置信度95%的Bonferroni置信区间.

解: 按照Bonferroni方法, 应将各区间的置信水平调

整为  $\alpha/m = 0.05/6 = 0.0083$  ,

而  $t_{1-\frac{\alpha}{2m}}(n-1) = t_{0.9958}(28) = 2.839$  .



原来:  $t_{0.975}(28)=2.048$



## 例 3.4

### 同时置信区间

**Bonferroni**  
校正前

$$\mu_1 - \mu_2: (-0.098, 8.173); \quad \mu_1 - \mu_3: (1.202, 9.473)$$

$$\mu_1 - \mu_4: (4.327, 12.598); \quad \mu_2 - \mu_3: (-2.836, 5.436)$$

$$\mu_2 - \mu_4: (0.289, 8.561); \quad \mu_3 - \mu_4: (-1.011, 7.261)$$



**校正后**

$$\mu_1 - \mu_2: (-1.695, 9.770); \quad \mu_1 - \mu_3: (-0.395, 11.070)$$

$$\mu_1 - \mu_4: (2.730, 14.195); \quad \mu_2 - \mu_3: (-4.432, 7.032)$$

$$\mu_2 - \mu_4: (-1.307, 10.157); \quad \mu_3 - \mu_4: (-2.607, 8.857)$$

结果置信区间较大，只能断言 $\mu_1 > \mu_4$ 。

