
第2章：线性回归分析

-- 2.4 回归方程选取



2.4 回归方程选取

- 全部可能自变量建立的回归方程不一定是最好的。对因变量影响很小或没有影响的变量包含在回归方程中，会使计算量增加，并会导致因变量预测值的精度下降。
- 选择一个“最优”的自变量子集，以建立一个即合理又简单的回归方程是十分重要的。
- 回归方程选取方法：
 1. 穷举法
 2. 逐步回归法



回归方程选取方法分类

1. 穷举法

- 修正复相关系数准则
- C_p 准则
- 预测平方和准则 ($PRESS_p$)

问题：随自变量个数的增加，计算量增大

2. 逐步回归法



逐步回归法

2. 逐步回归法 (穷举法, 计量较大)

设已有 $l-1$ 变量集 A , 相应的 $SSE(A)$, 添 X_k 后,
相对减少量

添加 X_k 后, SSE 的相对
减少量

额外回归平方和

$$F_k = \frac{SSE(A) - SSE(A, X_k)}{SSE(A, X_k) / (n - l - 1)} \triangleq \frac{SSR(X_k | A)}{MSE(A, X_k)}$$

已有

偏F统计量;



第2章：线性回归分析

$$F_k = \left(\frac{\hat{\beta}_k}{s(\hat{\beta}_k)} \right)^2 \stackrel{\Delta}{=} t_k^2$$

标准差估计

用于检验 $\beta_k = 0$ ，假设其真，则

$$F_k = t_k^2 \sim F(1, n-l-1)$$

F分布

检验后，若拒之，则添得。类似分析剔除一个变量。

具体步骤如下：

首先给出两个显著水平：添入的 α_E ；剔除的 α_D 。 $\alpha_E \leq \alpha_D$

第 1 步

设 $A = \Phi$ (空)，逐个单个拟合。



第2章：线性回归分析

$$Y = \beta_0 + \beta_k X_k + \varepsilon, \quad \leftarrow$$

$$SSE(A) = SST, \quad \leftarrow$$

$$SSR(X_k | A) = SST - SSE(X_k) = SSR(X_k), \quad \leftarrow$$

$$MSE(A, X_k) = MSE(X_k). \quad \leftarrow$$

对每个 k ，计算

$$F_k^{(1)} = \frac{SSR(X_k)}{MSE(X_k)}, k = 1 \sim M - 1 \quad \leftarrow \text{对每个 } X_k \text{ 求解}$$

及其 p 值

$$p_k^{(1)} = P(F(1, n - 2) \geq F_k^{(1)}), k = 1 \sim M - 1 \quad \leftarrow \text{对每个 } X_k \text{ 求解}$$



第2章：线性回归分析

设 $F_{k_1}^{(1)} = \max_{1 \leq k \leq M-1} \{F_k^{(1)}\}$ (变化最明显的), 对应的 $p_{k_1}^{(1)}$, 最大的 F_k

若 $p_{k_1}^{(1)} < \alpha_E$, 则拒 $\beta_k = 0$, 即选择含 X_{k_1} 的模型:

判断条件
添加

$$Y = \beta_0 + \beta_{k_1} X_{k_1} + \varepsilon (\wedge _ \wedge)$$

第 2 步

逐个将 $M - 2$ 个自变量添入 $(\wedge _ \wedge)$ 中, 拟合并计算

$$F_k^{(2)} = \frac{SSR(X_k | X_{k_1})}{MSE(X_{k_1}, X_k)}, \quad k \neq k_1$$

逐个添加下
一个自变量

$$p_k^{(2)} = P(F(1, n-3) \geq F_k^{(2)}), \quad k \neq k_1$$



第2章：线性回归分析

设 $F_{k_2}^{(2)} = \max_{k \neq k_2} \{F_k^{(2)}\}$, 对应的 p 值 $p_{k_2}^{(2)}$,

若 $p_{k_2}^{(2)} \geq \alpha_E$, 则 $F_k^{(2)}$ 均不显著, 结束过程选择.

若 $p_{k_2}^{(2)} < \alpha_E$, 则将 X_{k_2} 添加入模型($\wedge$), 得

判断条件

$$Y = \beta_0 + \beta_{k_1} X_{k_1} + \beta_{k_2} X_{k_2} + \varepsilon (\wedge)$$

下一步考察是否要剔除某变量.

剔除操作

为此拟合模型($\wedge$), 并计算

$$F_{k_1}^{(2)} = \frac{SSR(X_{k_1} | X_{k_2})}{MSE(X_{k_1}, X_{k_2})} = t_{k_1}^2$$

含 X_{k_2} 式中添加 X_{k_1}



第2章：线性回归分析

$$F_{k_2}^{(2)} = \frac{SSR(X_{k_2} | X_{k_1})}{MSE(X_{k_1}, X_{k_2})} = t_{k_2}^2$$

含 X_{k1} 式中添加 X_{k2}

及其 p 值

$$p_{k_1}^{(2)} = P(F(1, n-3) \geq F_{k_1}^{(2)})$$

$$p_{k_2}^{(2)} = P(F(1, n-3) \geq F_{k_2}^{(2)})$$

在 $F_{k_1}^{(2)}, F_{k_2}^{(2)}$ 中最小者对应的 p 值为 $p_{\min}^{(2)}$

取最小值

若 $p_{\min}^{(2)} \geq \alpha_D$, 则意为 $\hat{\beta}_{\min} = 0$, 当剔除对应变量

判断条件
删除

(进一步考察余下的变量是否该剔除, 一般不会)



第2章：线性回归分析

若 $p_{\min}^{(2)} < \alpha_D$ ，则无自变量被剔除, $(\wedge)$ 为当前模型.

第 3 步

类似重复第 2 步的过程, 直到无添无剔为止.

循环

注: $\alpha_E \leq \alpha_D$, 否则容易出现刚添进就被剔出的可能.

实用中, 诸多其他因素.

例 10 (续例 8) 验证 Box-Cox 变换后模型的合理性, 在此基础上, 通过逐步回归法选择最优回归方程.

解: 取 $\alpha_E = \alpha_D = 0.05$, 调用 proc reg 过程, 得:



第2章：线性回归分析

Statistics for Entry; Step 1

$DF = 1,52$

Variable	F	Prob > F
X_1	7.314 6	0.009 2
X_2	28.340 1	0.000 1
X_3	40.665 7	0.000 1
X_4	59.940 5	0.000 1

Variable X_4 Entered

Variable	Parameter Estimate	Standard Error	F	Prob > F
INTERCEP	4.420 9	0.235 3	353.16	0.000 1
X_4	0.619 1	0.078 0	59.94	0.000 1

$\because X_4$ 的偏 F 值 59.940 最大, 且 $p < \alpha_E \therefore X_4$ 进模;

又 $\because$ 拟合后, X_4 的偏 F 的 $p < \alpha_D$, $\therefore X_4$ 不能剔.



第2章：线性回归分析

Statistics for Entry: Step 2				
DF = 1,51				
Variable		F		Prob > F
X_1		0.039 9		0.842 5
X_2		18.052 7		0.000 1
X_3		25.493 7		0.000 1
Variable X_3 Entered				
Variable	Parameter Estimate	Standard Error	F	Prob > F
INTERCEP	3.417 5	0.277 7	151.45	0.000 1
X_3	0.018 4	0.003 7	25.49	0.000 1
X_4	0.466 6	0.072 5	41.40	0.000 1

$\because X_3$ 的偏 F 值 25.493 最大,且 $p < \alpha_E \therefore X_3$ 进模;

又 $\because$ 拟合后最小的偏 F 的 X_3 的 $p < \alpha_D$, $\therefore X_{3,4}$ 均不剔。



第2章：线性回归分析

Statistics for Entry: Step 3				
DF = 1,50				
Variable		F		Prob > F
X_1		5.875 3		0.019 0
X_2		84.229 2		0.000 1
Variable X_2 Entered				
Variable	Parameter Estimate	Standard Error	F	Prob > F
INTERCEP	1.948 3	0.234 4	69.10	0.000 1
X_2	0.026 0	0.002 8	84.23	0.000 1
X_3	0.022 9	0.002 3	98.69	0.000 1
X_4	0.278 5	0.049 2	32.08	0.000 1

$\because X_2$ 的偏 F 值 84.229 最大, 且 $p < \alpha_E \therefore X_2$ 进模;

又 $\because$ 拟合后最小的偏 F 的 X_4 的 $p < \alpha_D, \therefore X_{2,3,4}$ 均不剔。



第2章：线性回归分析

Statistics for Entry: Step 4

DF = 1,49

Variable	F	Prob > F
X_1	165.158 1	0.000 1

Variable X_1 Entered

Variable	Parameter Estimate	Standard Error	F	Prob > F
INTERCEP	0.452 5	0.162 4	7.76	0.007 6
X_1	0.226 0	0.017 6	165.16	0.000 1
X_2	0.030 5	0.001 4	465.47	0.000 1
X_3	0.031 0	0.001 3	586.95	0.000 1
X_4	0.014 9	0.031 4	0.23	0.637 2

剔除

∵ 余唯一 X_1 的偏 F 值为 165.158, 且 $p < \alpha_E$ ∴ X_1 进模;
 又 ∵ 拟合后最小的偏 F 的 X_4 的 $p = 0.637 > \alpha_D$, ∴ X_4 被剔除. 重新拟合后最小的偏 F 的 X_1 的 $p < \alpha_D$, 故无余剔.



第2章：线性回归分析

最后一步， X_4 的 p 值 $0.637 > \alpha_E$ ，故 X_4 不能进入模型，选择过程结束。

↵

本章小结

首先，选择合适的因变量、自变量、个数，

数据量 n 是 $p-1$ 的 6 倍或 10 倍，

别错保真；

其次，大致判断“线回”模型的可行性，

先建一个自变量的“线回”模型，

检验模型的合理性(是否线回,正态,同方差)。



第2章：线性回归分析

有无必要引入高次项, 交叉项等;

有无必要变换因变量等;

最后, 选择有显著影响的自变量, 确定几个最优的模型, 再比出合适的模型.

