

第5章 判 别 分 析

判 别 分 析

距离判别

贝叶斯判别

逐步判别

典型判别

§ 1 什么是判别分析

例 中小企业的破产模型

为了研究中小企业的破产模型，选定4个经济指标：

X1总负债率（现金收益/总负债）

X2收益性指标（纯收入/总财产）

X3短期支付能力（流动资产/流动负债）

X4生产效率性指标（流动资产/纯销售额）

对17个破产企业（第1类）和21个正常运行企业（第2类）进行了调查，得如下资料：

总负债率	收益性指标	短期支付能力	生产效率指标	类别
-. 45	-. 41	1. 09	. 45	1
-. 56	-. 31	1. 51	. 16	1
. 06	. 02	1. 01	. 40	1
-. 07	-. 09	1. 45	. 26	1
-. 10	-. 09	1. 56	. 67	1
-. 14	-. 07	. 71	. 28	1
-. 23	-. 30	. 22	. 18	1
. 07	. 02	1. 31	. 25	1
. 01	. 00	2. 15	. 70	1
-. 28	-. 23	1. 19	. 66	1
. 15	. 05	1. 88	. 27	1
. 37	. 11	1. 99	. 38	1
-. 08	-. 08	1. 51	. 42	1
. 05	. 03	1. 68	. 95	1
. 01	. 00	1. 26	. 60	1
. 12	. 11	1. 14	. 17	1
-. 28	-. 27	1. 27	. 51	1
. 51	. 10	2. 49	. 54	2
. 08	. 02	2. 01	. 53	2

. 38	. 11	3. 27	. 55	2
. 19	. 05	2. 25	. 33	2
. 32	. 07	4. 24	. 63	2
. 31	. 05	4. 45	. 69	2
. 12	. 05	2. 52	. 69	2
-. 02	. 02	2. 05	. 35	2
. 22	. 08	2. 35	. 40	2
. 17	. 07	1. 80	. 52	2
. 15	. 05	2. 17	. 55	2
-. 10	-1. 01	2. 50	. 58	2
. 14	-. 03	. 46	. 26	2
. 14	. 07	2. 61	. 52	2
-. 33	-. 09	3. 01	. 47	2
. 48	. 09	1. 24	. 18	2
. 56	. 11	4. 29	. 45	2
. 20	. 08	1. 99	. 30	2
. 47	. 14	2. 92	. 45	2
. 17	. 04	2. 45	. 14	2
. 58	. 04	5. 06	. 13	2
. 04	. 01	1. 50	. 71	待判
-. 06	-. 06	1. 37	. 40	待判

. 07	-. 01	1. 37	. 34	待判
-. 13	-. 14	1. 42	. 44	待判
. 15	. 06	2. 23	. 56	待判
. 16	. 05	2. 31	. 20	待判
. 29	. 06	1. 84	. 38	待判
. 54	. 11	2. 33	. 48	待判

企业序号	判别类型	判别函数得分	判别为1的概率	判别的为2概率
1	1	-.56509	.69479	.30521
2	1	-.89817	.80234	.19766
3	1	-.59642	.70620	.29380
4	1	-1.02182	.83420	.16580
5	2	.25719	.35312	.64688
6	2	.34253	.32005	.67995
7	2	.27925	.34442	.65558
8	2	1.24010	.09012	.90988

- 判别分析是利用已知类别的样本培训模型，为未知样本判类的一种统计方法。
- 它产生于本世纪30年代。近年来，在自然科学、社会学及经济管理学科中都有广泛的应用。
- 判别分析的特点是根据已掌握的、历史上每个类别的若干样本的数据信息，总结出客观事物分类的规律性，建立判别公式和判别准则。然后，当遇到新的样本点时，只要根据总结出来的判别公式和判别准则，就能判别该样本点所属的类别。

§ 2 距离判别

(一) 马氏距离

距离判别的最直观的想法是计算样品到第 i 类总体的平均数的距离，哪个距离最小就将它判归哪个总体。

我们首先考虑的是是否能够构造一个恰当的距离函数，通过样本与某类别之间距离的大小，判别其所属类别。

马氏距离和欧式距离之间的差别

马氏距离



Σ : 协方差
矩阵

$$d^2(\mathbf{x}, G) = (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})$$

欧氏距离


$$d^2(\mathbf{x}, G) = (\mathbf{x} - \boldsymbol{\mu})' (\mathbf{x} - \boldsymbol{\mu})$$

欧氏距离 vs. 马氏距离





A、B到中心点
距离相等

空间中的点



马氏距离 $\longrightarrow$ 欧氏距离



设 $\mathbf{x} = (x_1, x_2, \dots, x_m)'$ 和 $\mathbf{y} = (y_1, y_2, \dots, y_m)'$ 是从期望 $\boldsymbol{\mu} = (\mu_1, \mu_2, \dots, \mu_m)$ 和方差阵 $\boldsymbol{\Sigma} = (\sigma_{ij})_{m \times m} > 0$ 的总体 $\mathbf{G}$ 抽得的两个观测值，则称

X与Y之间的Mahalanobis距离

$$d^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \mathbf{y})$$

样本 $\mathbf{X}$ 和 G_i 类之间的马氏距离定义为 $\mathbf{X}$ 与 G_i 类重心的距离：

$$d^2(\mathbf{x}, G_i) = (\mathbf{x} - \boldsymbol{\mu}_i)' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) \quad i = 1, 2, \dots, k$$

马氏距离和欧式距离之间的差别

马氏距离

$$d^2(\mathbf{x}, G) = (\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})$$

欧氏距离

$$d^2(\mathbf{x}, G) = (\mathbf{x} - \boldsymbol{\mu})' (\mathbf{x} - \boldsymbol{\mu})$$

马氏距离有如下的特点：

- 1、马氏距离不受**计量单位**的影响；
- 2、马氏距离是**标准化**后的变量的欧式距离

$$X \sim N(\mu, \sigma^2), Y = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

$$\mathbf{y} = \Sigma^{-\frac{1}{2}}(\mathbf{x} - \boldsymbol{\mu})$$

$$\begin{aligned} \mathbf{y}'\mathbf{y} &= \left(\Sigma^{-\frac{1}{2}}(\mathbf{x} - \boldsymbol{\mu}) \right)' \Sigma^{-\frac{1}{2}}(\mathbf{x} - \boldsymbol{\mu}) \\ &= (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-\frac{1}{2}} \Sigma^{-\frac{1}{2}} (\mathbf{x} - \boldsymbol{\mu}) \\ &= (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \end{aligned}$$

3、若变量之间是相互无关的，则协方差矩阵为对角矩阵

$$\mathbf{\Sigma} = \begin{pmatrix} \sigma_{11} & & & \\ & \sigma_{22} & & \\ & & \ddots & \\ & & & \sigma_{pp} \end{pmatrix} \quad \mathbf{\Sigma}^{-1} = \begin{pmatrix} \frac{1}{\sigma_{11}} & & & \\ & \frac{1}{\sigma_{22}} & & \\ & & \ddots & \\ & & & \frac{1}{\sigma_{pp}} \end{pmatrix}$$

$$d^2(\mathbf{x}, G) = (\mathbf{x} - \boldsymbol{\mu})' \begin{pmatrix} \frac{1}{\sigma_{11}} & & & \\ & \frac{1}{\sigma_{22}} & & \\ & & \ddots & \\ & & & \frac{1}{\sigma_{pp}} \end{pmatrix} (\mathbf{x} - \boldsymbol{\mu})$$

$$= \frac{(x_1 - \mu_1)^2}{\sigma_{11}} + \frac{(x_2 - \mu_2)^2}{\sigma_{22}} + \dots + \frac{(x_p - \mu_p)^2}{\sigma_{pp}}$$

设 $\mathbf{x}, \mathbf{y}$ 来自总体 $G(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 的两个样本, 则

$\mathbf{x}$ 与 $\mathbf{y}$ 的马氏距离:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \mathbf{y})},$$

$\mathbf{x}$ 与总体 G 的马氏距离:

$$d(\mathbf{x}, G) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})}$$

两个总体 $G(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}), G(\boldsymbol{\mu}_2, \boldsymbol{\Sigma})$ 的距离

$$d(G_1, G_2) = \sqrt{(\boldsymbol{\mu}_2 - \boldsymbol{\mu}_1)^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_2 - \boldsymbol{\mu}_1)}$$

距离三性质

1) $d(\mathbf{x}, \mathbf{y}) \geq 0$, 当且仅当 $\mathbf{x} = \mathbf{y}$, $d(\mathbf{x}, \mathbf{y}) = 0$;

2) $d(\mathbf{x}, \mathbf{y}) = d(\mathbf{y}, \mathbf{x})$;

3) $d(\mathbf{x}, \mathbf{y}) \leq d(\mathbf{x}, \mathbf{z}) + d(\mathbf{z}, \mathbf{y})$;

距离判别准则法:

设 $G_1(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1)$ 与 $G_2(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_2)$, 有待判点 $\mathbf{x}$,

$$\begin{cases} \mathbf{x} \in G_1, & \text{if } d(\mathbf{x}, G_1) \leq d(\mathbf{x}, G_2) \\ \mathbf{x} \in G_2, & \text{if } d(\mathbf{x}, G_1) > d(\mathbf{x}, G_2) \end{cases}$$

此判定与统计学上似然大小比较结果是一致的.

虽直观, 但不很方便, 其他方法.(本质相通)

(1) 对于 $G(\mu_1, \Sigma), G(\mu_2, \Sigma)$ 协方差相等

$$d^2(\mathbf{x}, G_2) - d^2(\mathbf{x}, G_1)$$

$$= (\mathbf{x} - \mu_2)^T \Sigma^{-1} (\mathbf{x} - \mu_2) - (\mathbf{x} - \mu_1)^T \Sigma^{-1} (\mathbf{x} - \mu_1)$$

$$= \underline{-2\mu_2^T \Sigma^{-1} \mathbf{x}} + \underline{\mu_2^T \Sigma^{-1} \mu_2} + \underline{2\mu_1^T \Sigma^{-1} \mathbf{x}} - \underline{\mu_1^T \Sigma^{-1} \mu_1}$$

$$\begin{aligned} & \underline{a_1^T \triangleq \mu_1^T \Sigma^{-1}}, b_1 \triangleq -\frac{1}{2} \mu_1^T \Sigma^{-1} \mu_1 \\ & \underline{\underline{\underline{\underline{\underline{-2[(a_2^T \mathbf{x} + b_2) - (a_1^T \mathbf{x} + b_1)]}}}}}} \end{aligned}$$

$$\underline{a_2^T \triangleq \mu_2^T \Sigma^{-1}}, b_2 \triangleq -\frac{1}{2} \mu_2^T \Sigma^{-1} \mu_2$$

$$\underline{\underline{\underline{\underline{\underline{W_1(\mathbf{x}) \triangleq a_1^T \mathbf{x} + b_1}}}}}} - 2 \underline{[W_2(\mathbf{x}) - W_1(\mathbf{x})]}, \text{ 此时有}$$

$$\underline{W_2(\mathbf{x}) \triangleq a_2^T \mathbf{x} + b_2}$$

$$\begin{cases} \mathbf{x} \in G_1, & \text{if } W_1(\mathbf{x}) \geq W_2(\mathbf{x}) \\ \mathbf{x} \in G_2, & \text{if } W_1(\mathbf{x}) < W_2(\mathbf{x}) \end{cases}$$



也可配成

$$d^2(\mathbf{x}, G_2) - d^2(\mathbf{x}, G_1)$$

$$= 2(\mathbf{x} - \bar{\boldsymbol{\mu}})^T \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = 2(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \bar{\boldsymbol{\mu}})$$

$$\stackrel{a^T \triangleq (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \boldsymbol{\Sigma}^{-1}}{=} \underline{2a^T(\mathbf{x} - \bar{\boldsymbol{\mu}}) \triangleq 2W(\mathbf{x})}, \text{ 由此得}$$

$$\begin{cases} \mathbf{x} \in G_1, & \text{if } W(\mathbf{x}) \geq 0 \\ \mathbf{x} \in G_2, & \text{if } W(\mathbf{x}) < 0 \end{cases}$$



$$\begin{aligned}
 W(\mathbf{y}) &= (\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\alpha} = \boldsymbol{\alpha}'(\mathbf{y} - \boldsymbol{\mu}) \\
 &= a_1(y_1 - \mu_1) + \cdots + a_p(y_p - \mu_p) \\
 &= \boldsymbol{\alpha}'\mathbf{y} - \boldsymbol{\alpha}'\boldsymbol{\mu}
 \end{aligned}$$

则前面的判别法则表示为

$$\begin{cases} \mathbf{y} \in G_1, & \text{如 } W(\mathbf{y}) > 0, \\ \mathbf{y} \in G_2, & \text{如 } W(\mathbf{y}) < 0. \\ \text{待判}, & \text{如 } W(\mathbf{y}) = 0 \end{cases}$$

当 μ_1, μ_2 和 Σ 已知时, $\boldsymbol{\alpha} = \Sigma^{-1}(\mu_1 - \mu_2)$ 是一个已知的 p 维向量, $W(\mathbf{y})$ 是 $\mathbf{y}$ 的线性函数, 称为**线性判别函数**。 $\boldsymbol{\alpha}$ 称为判别系数。用线性判别函数进行判别分析非常直观, 使用起来最方便, 在实际中的应用也最广泛。

实际中, 用来自 G_1 和 G_2 训练样本

$$\mathbf{x}_1^{(1)}, \mathbf{x}_2^{(1)}, \dots, \mathbf{x}_{n_1}^{(1)}, \mathbf{x}_1^{(2)}, \mathbf{x}_2^{(2)}, \dots, \mathbf{x}_{n_2}^{(2)}$$

的均值 $\bar{\mu}_1, \bar{\mu}_2$ 和协方差 $\mathbf{S}_1, \mathbf{S}_2$ 代总体的均值和方差.

由此得 $\mathbf{S} = \hat{\Sigma} = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}$ 及相应的.

$$\begin{cases} \mathbf{x} \in G_1, & \text{if } \hat{W}_1(\mathbf{x}) \geq \hat{W}_2(\mathbf{x}) \\ \mathbf{x} \in G_2, & \text{if } \hat{W}_1(\mathbf{x}) < \hat{W}_2(\mathbf{x}) \end{cases}$$

或

$$\begin{cases} \mathbf{x} \in G_1, & \text{if } \hat{W}(\mathbf{x}) \geq 0 \\ \mathbf{x} \in G_2, & \text{if } \hat{W}(\mathbf{x}) < 0 \end{cases}$$

(2) 对 $\Sigma_1 \neq \Sigma_2$ 协方差不相等⁴

$$d_1(\mathbf{x}) = \sqrt{(\mathbf{x} - \mu_1)^T \Sigma_1^{-1} (\mathbf{x} - \mu_1)},$$

$$d_2(\mathbf{x}) = \sqrt{(\mathbf{x} - \mu_2)^T \Sigma_2^{-1} (\mathbf{x} - \mu_2)},$$

仍为距离判别准则:⁴

$$\begin{cases} \mathbf{x} \in G_1, & \text{if } d_2^2(\mathbf{x}) \geq d_1^2(\mathbf{x}) \\ \mathbf{x} \in G_2, & \text{if } d_2^2(\mathbf{x}) < d_1^2(\mathbf{x}) \end{cases}$$


实用中, 把一部分数据作为训练样本, 估计出相应的均值和协方差.⁴

2. 判别准则的评价

设两个一维正态总体 $G_{1,2} : N(\mu_{1,2}, \sigma^2)$, $\mu_1 < \mu_2$,

判别准则:
$$\begin{cases} x \in G_1, & \text{if } x \leq (\mu_1 + \mu_2)/2 \\ x \in G_2, & \text{if } x > (\mu_1 + \mu_2)/2 \end{cases}$$

两种误判



本来为2
判断是1

$$p(1|2) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\frac{\mu_1 + \mu_2}{2}} e^{-\frac{(x - \mu_2)^2}{2\sigma^2}} dt, \quad p(2|1) = \frac{1}{\sqrt{2\pi}\sigma} \int_{\frac{\mu_1 + \mu_2}{2}}^{+\infty} e^{-\frac{(x - \mu_1)^2}{2\sigma^2}} dt$$

基于R准则

准则 $\mathbf{R}$ 的误判率:

$$p^* = p_1 P(2 | 1, \mathbf{R}) + p_2 (P(1 | 2, \mathbf{R}))$$

其中 $P(2 | 1, \mathbf{R})$ 表示: 在准则 $\mathbf{R}$ 下将 1 类错判为 2,

p_1, p_2 为先验概率.

(1) 误判率回代估计法

设来自 G_1 和 G_2 样本为

$$\mathbf{x}_1^{(1)}, \mathbf{x}_2^{(1)}, \dots, \mathbf{x}_{n_1}^{(1)}, \quad \mathbf{x}_1^{(2)}, \mathbf{x}_2^{(2)}, \dots, \mathbf{x}_{n_2}^{(2)}$$

代入判别准则后, 得

	G_1 回判情况	G_2
实际 G_1	n_{11}	n_{12}
归类 G_2	n_{21}	n_{22}

则误判率回代估计

$$\hat{p}_r^* = \frac{n_{12} + n_{21}}{n_1 + n_2}$$

(2) 误判率的交叉确认估计法

步骤:

- 1) 依次 $G_1\{\mathbf{x}\} : x_i$ 用余 $n_1 - 1 + n_2$ 个, 建判别准则, ..
- 2) 判别 $\mathbf{x}$, 记录正误, 直到结束, 记录误判数 n_{12}^* ..
- 3) 对 G_2 作类似步骤, 记录误判数 n_{21}^* ..

$$\hat{p}_c^* = \frac{n_{12}^* + n_{21}^*}{n_1 + n_2} ..$$

● 判别准则的评价：误判率越小，准则越优秀

1. 回代估计法

根据全体样本建立判断准则，然后将全体训练样本作为新样本，逐个代入已经建立的判断准则中，判断其归属，根据结果计算误判率。（计算量小，只需要建立一个判断准则，误判率误差大，比真实值小）

2. 交叉确认估计法

每次剔除训练样本中的一个样本，利用剩余的样本建立判别准则，然后将剔除的这个样本代入至判别准则中进行判断。后续建立一系列判断准则，然后代入判断。（计算量大，需要建立一个 $N-1$ 个判断准则，误判率误差小，与真实值接近）

3. 多个总体的距离判别(最近者)

设 k 个总体 $G_1, G_1, \dots, G_k$ 的均值和协方差分别为

$$\mu_1, \mu_1, \dots, \mu_k \text{ 和 } \Sigma_1, \Sigma_1, \dots, \Sigma_k$$

(1) 总体协方差矩阵相等

以前类定义记号,

$$d^2(\mathbf{x}, G_j) - d^2(\mathbf{x}, G_i) = -2[W_j(\mathbf{x}) - W_i(\mathbf{x})]$$

显然有

$$d^2(\mathbf{x}, G_j) \geq d^2(\mathbf{x}, G_i) \Leftrightarrow W_i(\mathbf{x}) - W_j(\mathbf{x}) \geq 0$$

若 $W_{j_0}(\mathbf{x}) = \max_{1 \leq j \leq k} W_j(\mathbf{x})$, 则 $\mathbf{x} \in W_{j_0}(\mathbf{x})$.

选最大

实用中 $\hat{W}_{j0}(\mathbf{x}) = \max_{1 \leq j \leq k} \hat{W}_j(\mathbf{x})$, 则 $\mathbf{x} \in G_{j0}$.

(2) 总体协方差矩阵不全等.

$$d_j(\mathbf{x}) = d(\mathbf{x}, G_j)$$

$$= \sqrt{(\mathbf{x} - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}_j^{-1} (\mathbf{x} - \boldsymbol{\mu}_j)}, j = 1 \sim k,$$

仍用距离判别准则:

若 $d_{j0}(\mathbf{x}) = \min_{1 \leq j \leq k} d_j(\mathbf{x})$, 则 $\mathbf{x} \in G_{j0}$.

实用中, 用样本数据估计出相应的均值和协方差.

对于多总体的距离判别, 也可同两个总体的情

例 在企业的考核种，可以根据企业的生产经营情况把企业分为**优秀企业**和**一般企业**。考核企业经营状况的**指标有**：

资金利润率=利润总额/资金占用总额

劳动生产率=总产值/职工平均人数

产品净值率=净产值/总产值

给予三个指标的均值向量和协方差矩阵。现有二个企业，观测值分别为

(7.8, 39.1, 9.6) 和 (8.1, 34.2, 6.9) ，问这两个企业应该**属于哪一类**？

变量	均值向量		协方差矩阵		
	优秀	一般			
资金利润率	13.5	5.4	68.39	40.24	21.41
劳动生产率	40.7	29.8	40.24	54.58	11.67
产品净值率	10.7	6.2	21.41	11.67	7.90

线性判别函数:

$$y = -0.60581x_1 + 0.25362x_2 + 1.83679x_3 - 18.73596$$

$$y_1 = -0.60581 \times 7.8 + 0.25362 \times 39.1 + 1.83679 \times 9.6 - 18.73596 \\ = 4.0892 > 0$$

属于G1

$$y_2 = -0.60581 \times 8.1 + 0.25362 \times 34.2 + 1.83679 \times 6.9 - 18.73596 \\ = -2.2956 < 0$$

属于G2

看例题5.1、 5.2

- 思考：
- 1. 例题的解题步骤；
- 2. 验证待判样本分类正确否；