

第5章：判别分析

判别分析是为了解决未来的**个案归类问题**，而提出一种数据分类技术，它**基于已有的**分类个案，寻求有效的**判别规则**，并借助判别规则对**未来**个案的归属进行判定。

◆基于距离的判别分析

利用**马氏距离**，计算样本点与总体之间的距离，然后判断样本点归属为离其距离最近的总体。

第5章：判别分析

对于任意一个 p 维样本 $x = (x_1, x_2, \dots, x_p)$ 判别的关键是：

1. 线性判别函数 $W(x)$ 的建立

- ◆ 通常是一个多元一次方程，如果有 k 个总体，那么就应该有 k 个线性判别函数。

$$W_i(\mathbf{x}) = \mathbf{a}_i^T \mathbf{x} + b_i, \quad i = 1, 2, \dots, k$$

当然如果我们使用步进法进行判别函数的建立，则对判决影响较小的维度样本 x_i 可以去掉。这时候线性判别函数的个数就会少于 k 。

第5章：判别分析

2. 根据判别函数 $W(x)$ 进行判别

◆ 方法：将待判断的样本 $x = (x_1, x_2, \dots, x_p)$ 代入至判别函数中，值最大的判别函数对应的总体就是该样本的归属总体。

➤ 当只有两个总体 G_1, G_2 时

$$\begin{cases} x \in G_1, & \text{若 } W_1(x) \geq W_2(x) \\ x \in G_2, & \text{若 } W_1(x) < W_2(x) \end{cases}$$

➤ 当有 k 个总体 $G_1, G_2, \dots, G_k$ 时

$$x \in G_i, \quad \text{若 } W_i(x) = \max_{1 \leq j \leq k} W_j(x)$$

第5章：判别分析

● 判别准则的评价：误判率越小，准则越优秀

1. 回代估计法

根据全体样本建立判断准则，然后将全体训练样本作为新样本，逐个代入已经建立的判断准则中，判断其归属，根据结果计算误判率。（计算量小，只需要建立一个判断准则，误判率误差大，比真实值小）

2. 交叉确认估计法

每次剔除训练样本中的一个样本，利用剩余的样本建立判别准则，然后将剔除的这个样本代入至判别准则中进行判断。后续建立一系列判断准则，然后代入判断。（计算量大，需要建立一个N-1个判断准则，误判率误差小，与真实值接近）

判别分析

Bayes判别法

♠ 在统计学中有两个大的学派：**经典学派** (频率学派) 和**贝叶斯学派**。利用经典学派进行统计推断时要使用到两种信息：**总体信息**和**样本信息**；而贝叶斯学派认为，除了上述两种信息以外，统计推断还应该使用第三种信息：**先验信息**。

♥ 在统计学中有两个大的学派：**经典学派**（频率学派）和**贝叶斯学派**。

✓利用经典学派进行统计推断时要使用到两种信息：**总体信息**和**样本信息**；

✓而贝叶斯学派认为，除了上述两种信息以外，统计推断还应该使用第三种信息：**先验信息**。

♠ **总体信息**即总体分布或总体所属分布族提供的信息。

♠ **样本信息**即抽取样本所得观测值提供的信息。

♠ **先验信息**即是抽样之前有关统计问题的一些信息。

一般来说，**先验信息**来源于**经验和历史资料**。

♠ 贝叶斯学派的基本观点是：

- 总是假定对研究的对象已有一定的认识，可用一个概率分布去描述，这个分布称为先验分布；
- 在获得样本之后，总体分布、样本与先验分布通过贝叶斯公式结合起来，得到研究对象的一个新的分布—后验分布；
- 任何关于研究对象的统计推断都应该基于后验分布进行。

抛硬币：假如我连续抛了很多次，例如100次，出现的都是正面，当然，稍懂概率的人都知道，这是一个小概率事件，但是小概率事件是可能发生的。我要问你，下次也就是我抛第101次，出现正、反的概率是不是相等。


贝叶斯学派



经典学派

【例子】假阳性问题

已知某种疾病的**发病率是0.001**，即1000人中会有1个人得病。现有一种试剂可以检验患者是否得病，它的**准确率是0.99**，即在患者确实得病的情况下，它有99%的可能呈现阳性。它的**误报率是1%**，即在患者没有得病的情况下，它有1%的可能呈现阳性。现有一个病人的**检验结果为阳性**，请问他确实**得病的可能性有多大**？




患病的概率为：

$$P(\text{患}/\text{阳}) = \frac{P(\text{患}) * P(\text{阳}/\text{患})}{P(\text{患}) * P(\text{阳}/\text{患}) + P(\text{不患}) * P(\text{阳}/\text{不患})} = \frac{99\% * 1/1000}{99\% * 1/1000 + 1\% * 999/1000} \approx 9\%$$

A已发生的条件下B发生的概率:

$$P(B | A) = P(A \cap B) / P(A)$$

$$P(A \cap B) = P(B | A) \times P(A)$$



$$P(A \cap B) = P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$$



$$P(A|B) = P(B|A) \cdot P(A) / P(B)$$

$$P(B|A) = P(A|B) \cdot P(B) / P(A)$$

♠ Bayes公式

设 $B_1, B_2, \dots, B_n$ 是样本空间 Ω 的一个分割,

即 $B_1, B_2, \dots, B_n$ 互不相容, 且 $\bigcup_{i=1}^n B_i = \Omega$, 如

果 $P(A) > 0, P(B_i) > 0, i = 1, 2, \dots, n$, 则

$$P(B_j|A) = \frac{P(A|B_j)P(B_j)}{\sum_{i=1}^n P(A|B_i)P(B_i)}, \quad j = 1, 2, \dots, n$$

贝叶斯公式是由先验概率求后验概率的公式。举一个简单的例子：一口袋里有3只红球、2只白球，采用不放回方式摸取，求：(1) 第一次摸到红球（记作A）的概率；(2) 第二次摸到红球（记作B）的概率；(3) 已知第二次摸到了红球，求第一次摸到的是红球的概率。
<= 即求： $P(A|B)$ ？

贝叶斯公式是由先验概率求后验概率的公式。举一个简单的例子：一口袋里有3只红球、2只白球，采用不放回方式摸取，求：(1) 第一次摸到红球（记作A）的概率；(2) 第二次摸到红球（记作B）的概率；(3) 已知第二次摸到了红球，求第一次摸到的是红球的概率。
≤ 即求： $P(A|B)$ ？

解：

(1) $P(A)=3/5$ ，这就是先验概率；

(2) $P(B)=P(A)P(B|A)+P(A^{-})P(B|A^{-})$
 $=3/5*2/4 + 2/5*3/4 = 3/5$

(3) $P(A|B)=P(A)P(B|A)/P(B)$
 $=(3/5*2/4)/(3/5) = 1/2$ ，这就是后验概率

♠ Bayes判别法的基本思想

将Bayes思想用于判别分析就得到Bayes判别法.

基本思想样品属于哪个总体的后验概率大, 就判断它属于哪个总体.

♠ 两个总体的Bayes判别问题

问题: 设有两个总体 G_1 和 G_2 , 各自出现的概率为 q_1 和 q_2 , 概率密度函数为 $f_1(\mathbf{x})$ 和 $f_2(\mathbf{x})$. 对于一个新样品 $\mathbf{X}$, 要判断它来自哪个总体?

想法: 计算后验概率 $P(j|\mathbf{X}) \triangleq P(\mathbf{X} \in G_j | \mathbf{X} \text{ 已知})$, $j = 1, 2$, 并按照如下的判别准则判断.

$$\left\{ \begin{array}{ll} \text{判 } \mathbf{X} \in G_1, & \text{如果 } P(1|\mathbf{X}) > P(2|\mathbf{X}) \\ \text{判 } \mathbf{X} \in G_2, & \text{如果 } P(1|\mathbf{X}) < P(2|\mathbf{X}) \quad (\star) \\ \text{待判,} & \text{如果 } P(1|\mathbf{X}) = P(2|\mathbf{X}) \end{array} \right.$$

$$P(B_j|A) = \frac{P(A|B_j)P(B_j)}{\sum_{i=1}^2 P(A|B_i)P(B_i)}, \quad j = 1, 2$$

取事件 $A = \{\mathbf{X} \text{ 已知}\}$, 事件 $B_j = \{\mathbf{X} \in G_j\}$, 则后验概率为

$$P(j|\mathbf{X}) = \frac{q_j f_j(\mathbf{X})}{\sum_{i=1}^2 q_i f_i(\mathbf{X})}, \quad j = 1, 2$$

只判断分子即可

分母为常数

令 $Y_j(\mathbf{X}) = q_j f_j(\mathbf{X})$ ($j = 1, 2$), 则

$$\star \iff \begin{cases} \text{判 } \mathbf{X} \in G_1, & \text{如果 } Y_1(\mathbf{X}) > Y_2(\mathbf{X}) \\ \text{判 } \mathbf{X} \in G_2, & \text{如果 } Y_1(\mathbf{X}) < Y_2(\mathbf{X}) \\ \text{待判,} & \text{如果 } Y_1(\mathbf{X}) = Y_2(\mathbf{X}) \end{cases}$$

♠ 正态总体的Bayes判别函数

设 G_1 和 G_2 为正态总体, 其密度函数分别为

$$f_1(\mathbf{X}) = (2\pi)^{-p/2} |\boldsymbol{\Sigma}_1|^{-1/2} \exp \left\{ -\frac{1}{2} (\mathbf{X} - \boldsymbol{\mu}_1)' \boldsymbol{\Sigma}_1^{-1} (\mathbf{X} - \boldsymbol{\mu}_1) \right\}$$

$$f_2(\mathbf{X}) = (2\pi)^{-p/2} |\boldsymbol{\Sigma}_2|^{-1/2} \exp \left\{ -\frac{1}{2} (\mathbf{X} - \boldsymbol{\mu}_2)' \boldsymbol{\Sigma}_2^{-1} (\mathbf{X} - \boldsymbol{\mu}_2) \right\}$$

两个总体的先验概率分别为 q_1 和 q_2 , 则

$$\begin{aligned} Y_j(\mathbf{X}) &= q_j f_j(\mathbf{X}) \\ &= q_j (2\pi)^{-p/2} |\boldsymbol{\Sigma}_j|^{-1/2} e^{\left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_j)' \boldsymbol{\Sigma}_j^{-1} (\mathbf{x} - \boldsymbol{\mu}_j) \right\}}, \quad j = 1, 2 \end{aligned}$$

- $\Sigma_1 \neq \Sigma_2$

比较 $Y_j(\mathbf{X})$ ($j = 1, 2$)

常数可去掉

$$\Leftrightarrow \text{比较 } \ln q_j - \frac{p}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma_j| - \frac{1}{2} (\mathbf{X} - \mu_j)' \Sigma_j^{-1} (\mathbf{X} - \mu_j)$$

$$\Leftrightarrow \text{比较 } \underbrace{\ln q_j - \frac{1}{2} \ln |\Sigma_j| - \frac{1}{2} (\mathbf{X} - \mu_j)' \Sigma_j^{-1} (\mathbf{X} - \mu_j)}_{R_j(\mathbf{X})}$$

$$\left\{ \begin{array}{ll} \text{判 } \mathbf{X} \in G_1, & \text{如果 } R_1(\mathbf{X}) > R_2(\mathbf{X}) \\ \text{判 } \mathbf{X} \in G_2, & \text{如果 } R_1(\mathbf{X}) < R_2(\mathbf{X}) \\ \text{待判,} & \text{如果 } R_1(\mathbf{X}) = R_2(\mathbf{X}) \end{array} \right.$$

- ♣ 例: 已知9个样品分别来自两个2维正态总体, 观测数据见下表. 利用Bayes判别法判断样品 $(0,0)'$ 属于哪一类.

类别	序号	X_1	X_2
第一类	1	1	0
	2	1	1
	3	0	1
	4	-1	1
	5	-1	0
第二类	1	0	-1
	2	1	-2
	3	0	-2
	4	-1	-2

比较 $R_j(\mathbf{X}) = \ln q_j - \frac{1}{2} \ln |\boldsymbol{\Sigma}_j| - \frac{1}{2}(\mathbf{X} - \boldsymbol{\mu}_j)' \boldsymbol{\Sigma}_j^{-1} (\mathbf{X} - \boldsymbol{\mu}_j)$, $j = 1, 2$

先验概率的赋值方法有

(1) 利用历史资料及经验进行估计.

(2) 利用样本中各类样品占的比例作为估计值.

(3) 假定各类出现的概率都相等.

本例中, 利用方法(2)得到先验概率分别为

$$q_1 = 5/9, \quad q_2 = 4/9$$

类别	序号	X_1	X_2
第一类	1	1	0
	2	1	1
	3	0	1
	4	-1	1
	5	-1	0
第二类	1	0	-1
	2	1	-2
	3	0	-2
	4	-1	-2

第一类，第
5个数据

$$\mathbf{x}_{(1)}^{(1)} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \dots, \mathbf{x}_{(5)}^{(1)} = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

$$\mathbf{x}_{(1)}^{(2)} = \begin{bmatrix} 0 \\ -1 \end{bmatrix}, \dots, \mathbf{x}_{(4)}^{(2)} = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

类别	序号	X_1	X_2
第一类	1	1	0
	2	1	1
	3	0	1
	4	-1	1
	5	-1	0
第二类	1	0	-1
	2	1	-2
	3	0	-2
	4	-1	-2



类别	序号	X_1	X_2
第一类	1	1	0
	2	1	1
	3	0	1
	4	-1	1
	5	-1	0
第二类	1	0	-1
	2	1	-2
	3	0	-2
	4	-1	-2

$$\mathbf{x}_{(1)}^{(1)} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \dots, \mathbf{x}_{(5)}^{(1)} = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

$$\mathbf{x}_{(1)}^{(2)} = \begin{bmatrix} 0 \\ -1 \end{bmatrix}, \dots, \mathbf{x}_{(4)}^{(2)} = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

$$\hat{\mu}_1 = \bar{\mathbf{x}}^{(1)} = \frac{1}{5} \sum_{i=1}^5 \mathbf{x}_{(i)}^{(1)} = \begin{bmatrix} 0 \\ 3/5 \end{bmatrix}$$

$$\hat{\mu}_2 = \bar{\mathbf{x}}^{(2)} = \frac{1}{4} \sum_{i=1}^4 \mathbf{x}_{(i)}^{(2)} = \begin{bmatrix} 0 \\ -7/4 \end{bmatrix}$$

$$\hat{\Sigma}_1 = \frac{1}{n_1 - 1} \sum_{i=1}^5 (\mathbf{x}_{(i)}^{(1)} - \bar{\mathbf{x}}^{(1)})(\mathbf{x}_{(i)}^{(1)} - \bar{\mathbf{x}}^{(1)})' = \begin{bmatrix} 1 & 0 \\ 0 & 3/10 \end{bmatrix}$$

$$\hat{\Sigma}_2 = \frac{1}{n_2 - 1} \sum_{i=1}^4 (\mathbf{x}_{(i)}^{(2)} - \bar{\mathbf{x}}^{(2)})(\mathbf{x}_{(i)}^{(2)} - \bar{\mathbf{x}}^{(2)})' = \begin{bmatrix} 2/3 & 0 \\ 0 & 1/4 \end{bmatrix}$$

$$\hat{\Sigma}_1^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & 10/3 \end{bmatrix}$$

$$\hat{\Sigma}_2^{-1} = \begin{bmatrix} 3/2 & 0 \\ 0 & 4 \end{bmatrix}$$

$$|\hat{\Sigma}_1| = 3/10$$

$$|\hat{\Sigma}_2| = 1/6$$

$$R_j(\mathbf{X}) = \ln q_j - \frac{1}{2} \ln |\boldsymbol{\Sigma}_j| - \frac{1}{2} (\mathbf{X} - \boldsymbol{\mu}_j)' \boldsymbol{\Sigma}_j^{-1} (\mathbf{X} - \boldsymbol{\mu}_j), \quad j = 1, 2$$

$$R_1(\mathbf{X}) = \ln \frac{5}{9} - \frac{1}{2} \times \ln \frac{3}{10} - \frac{1}{2} \times \begin{bmatrix} 0 \\ -\frac{3}{5} \end{bmatrix}' \begin{bmatrix} 1 & 0 \\ 0 & \frac{10}{3} \end{bmatrix} \begin{bmatrix} 0 \\ -\frac{3}{5} \end{bmatrix} = -1.79$$

$$R_2(\mathbf{X}) = \ln \frac{4}{9} - \frac{1}{2} \times \ln \frac{1}{6} - \frac{1}{2} \times \begin{bmatrix} 0 \\ \frac{7}{4} \end{bmatrix}' \begin{bmatrix} \frac{3}{2} & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} 0 \\ \frac{7}{4} \end{bmatrix} = -7.832$$

因为 $R_1(\mathbf{X}) > R_2(\mathbf{X})$, 所以判 $\mathbf{X} \in G_1$.

- $\Sigma_1 = \Sigma_2 = \Sigma$

$$R_j(\mathbf{X}) = \ln q_j - \frac{1}{2} \ln |\Sigma| - \frac{1}{2} \mathbf{X}' \Sigma^{-1} \mathbf{X} + \mathbf{X}' \Sigma^{-1} \mu_j - \frac{1}{2} \mu_j' \Sigma^{-1} \mu_j$$

比较 $R_j(\mathbf{X})$ ($j = 1, 2$)

定值

$$\Leftrightarrow \text{比较 } \ln q_j - \frac{1}{2} \ln |\Sigma| - \frac{1}{2} \mathbf{X}' \Sigma^{-1} \mathbf{X} + \mathbf{X}' \Sigma^{-1} \mu_j - \frac{1}{2} \mu_j' \Sigma^{-1} \mu_j$$

$$\Leftrightarrow \text{比较 } \underbrace{\ln q_j + \mathbf{X}' \Sigma^{-1} \mu_j - \frac{1}{2} \mu_j' \Sigma^{-1} \mu_j}_{T_j(\mathbf{X})}$$

$$\left\{ \begin{array}{ll} \text{判 } \mathbf{X} \in G_1, & \text{如果 } T_1(\mathbf{X}) > T_2(\mathbf{X}) \\ \text{判 } \mathbf{X} \in G_2, & \text{如果 } T_1(\mathbf{X}) < T_2(\mathbf{X}) \\ \text{待判,} & \text{如果 } T_1(\mathbf{X}) = T_2(\mathbf{X}) \end{array} \right.$$

- ♣ 例: 已知9个样品分别来自两个2维正态总体, 观测数据见下表. 利用Bayes判别法判断样品 $(0,0)'$ 属于哪一类.

类别	序号	X_1	X_2
第一类	1	1	0
	2	1	1
	3	0	1
	4	-1	1
	5	-1	0
第二类	1	0	-1
	2	1	-2
	3	0	-2
	4	-1	-2

假设两个总体的协方差阵相等.

$$\text{比较 } T_j(\mathbf{X}) = \ln q_j + \mathbf{X}'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_j - \frac{1}{2}\boldsymbol{\mu}_j'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_j$$

$$\hat{\boldsymbol{\Sigma}}_1 = \begin{bmatrix} 1 & 0 \\ 0 & 3/10 \end{bmatrix} \quad \hat{\boldsymbol{\Sigma}}_2 = \begin{bmatrix} 2/3 & 0 \\ 0 & 1/4 \end{bmatrix}$$

$$\begin{aligned} \hat{\boldsymbol{\Sigma}} &= \frac{1}{n_1 + n_2 - 2} [(n_1 - 1)\hat{\boldsymbol{\Sigma}}_1 + (n_2 - 1)\hat{\boldsymbol{\Sigma}}_2] \\ &= \frac{4}{7}\hat{\boldsymbol{\Sigma}}_1 + \frac{3}{7}\hat{\boldsymbol{\Sigma}}_2 \end{aligned}$$

$$\hat{\boldsymbol{\Sigma}}^{-1} = \begin{bmatrix} 7/6 & 0 \\ 0 & 14/39 \end{bmatrix}$$

$$T_1(\mathbf{X}) = \ln \frac{5}{9} - \frac{1}{2} \times \begin{bmatrix} 0 \\ -\frac{3}{5} \end{bmatrix}' \begin{bmatrix} \frac{7}{6} & 0 \\ 0 & \frac{140}{39} \end{bmatrix} \begin{bmatrix} 0 \\ -\frac{3}{5} \end{bmatrix} = -1.234$$

$$T_2(\mathbf{X}) = \ln \frac{4}{9} - \frac{1}{2} \times \begin{bmatrix} 0 \\ \frac{7}{4} \end{bmatrix}' \begin{bmatrix} \frac{7}{6} & 0 \\ 0 & \frac{140}{39} \end{bmatrix} \begin{bmatrix} 0 \\ \frac{7}{4} \end{bmatrix} = -6.308$$

因为 $T_1(\mathbf{X}) > T_2(\mathbf{X})$, 所以判 $\mathbf{X} \in G_1$.

由GDP等数据判定归属

类别	序号	国家	预期寿命 X_1	成人识字率 X_2	人均GDP X_3
第一类	1	美国	76	99	5374
	2	日本	79.5	99	5359
	3	瑞士	78	99	5372
	4	阿根廷	72.1	95.9	5242
	5	阿联酋	73.8	77.7	5370
第二类	6	保加利亚	71.2	93	4250
	7	古巴	75.3	94.9	3412
	8	巴拉圭	70	91.2	3390
	9	格鲁吉亚	72.8	99	2300
	10	南非	62.9	80.6	3799
待判样品	11	中国	68.5	79.3	1950
	12	罗马尼亚	69.9	96.9	2840
	13	希腊	77.6	93.8	5233

假定两总体为正态总体并且协差阵相等.

对判别效果作检验

$H_0: \mu_1 = \mu_2$. 假设 G_i 为 $N(\mu_i, \Sigma)$ ($i = 1, 2$). 检验统计量为

$$F = \frac{n_1 n_2 (n_1 + n_2 - p - 1)}{p(n_1 + n_2)} (\bar{\mathbf{X}}^{(1)} - \bar{\mathbf{X}}^{(2)})' \mathbf{S}^{-1} (\bar{\mathbf{X}}^{(1)} - \bar{\mathbf{X}}^{(2)})$$

在原假设成立下, $F \sim F(p, n_1 + n_2 - p - 1)$.

当 $F > F_{\alpha}(p, n_1 + n_2 - p - 1)$ 时, 拒绝原假设.

本例中

$$F = 12.6746 > F_{0.05}(3, 6) = 4.76$$

故在 $\alpha = 0.05$ 检验水平下, 两总体间差异显著, 即判别函数有效.

先验概率

$$q_1 = q_2 = 0.5, \quad \ln q_1 = \ln q_2 = -0.693147$$

计算两类样本均值

$$\hat{\mu}_1 = \bar{\mathbf{X}}^{(1)} = \begin{bmatrix} 75.88 \\ 94.08 \\ 5343.4 \end{bmatrix} \quad \text{和} \quad \hat{\mu}_2 = \bar{\mathbf{X}}^{(2)} = \begin{bmatrix} 70.44 \\ 91.74 \\ 3430.2 \end{bmatrix}$$

计算样本协方差, 从而求出 $\hat{\Sigma}$

$$\begin{aligned} \mathbf{S}_1 &= \sum_{i=1}^{n_1} (\mathbf{x}_{(i)}^{(1)} - \bar{\mathbf{x}}^{(1)})(\mathbf{x}_{(i)}^{(1)} - \bar{\mathbf{x}}^{(1)})' \\ &= \begin{bmatrix} 36.228 & 56.022 & 448.74 \\ 56.022 & 344.228 & -252.24 \\ 448.74 & -252.24 & 12987.2 \end{bmatrix} \end{aligned}$$

$$\begin{aligned}
 \mathbf{S}_2 &= \sum_{i=1}^{n_2} (\mathbf{x}_{(i)}^{(2)} - \bar{\mathbf{x}}^{(2)})(\mathbf{x}_{(i)}^{(2)} - \bar{\mathbf{x}}^{(2)})' \\
 &= \begin{bmatrix} 86.812 & 117.682 & -4895.74 \\ 11.682 & 188.672 & -11316.54 \\ -4895.74 & -11316.54 & 2087384.8 \end{bmatrix}
 \end{aligned}$$

$$\begin{aligned}
 \mathbf{S} &= \mathbf{S}_1 + \mathbf{S}_2 \\
 &= \begin{bmatrix} 123.04 & 173.704 & -4447 \\ 173.704 & 532.9 & -11568.78 \\ -4447 & -11568.78 & 2100372 \end{bmatrix}
 \end{aligned}$$

$$\begin{aligned}
 \hat{\Sigma} &= \frac{1}{n_1 + n_2 - 2} (\mathbf{S}_1 + \mathbf{S}_2) = \frac{1}{8} (\mathbf{S}_1 + \mathbf{S}_2) \\
 &= \begin{bmatrix} 15.38 & 21.713 & -55.875 \\ 21.713 & 66.6125 & -1446.0975 \\ -555.675 & -1446.0975 & 262546.5 \end{bmatrix} \\
 \hat{\Sigma}^{-1} &= \begin{bmatrix} 0.120896 & -0.03845 & 0.0000442 \\ -0.03845 & 0.029278 & 0.0000799 \\ 0.0000442 & 0.0000799 & 0.00000434 \end{bmatrix}
 \end{aligned}$$

代入判别函数:

$$T_j(\mathbf{X}) = \ln q_j + \mathbf{X}'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_j - \frac{1}{2}\boldsymbol{\mu}_j'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_j, \quad j = 1, 2$$

得两组的判别函数分别为:

$$T_1(\mathbf{X}) = 5.79X_1 + 0.26X_2 + 0.034X_3 - 323.17$$

$$T_2(\mathbf{X}) = 5.14X_1 + 0.25X_2 + 0.025X_3 - 236.02$$

样品号	国家	$T_1(\mathbf{X})$	$T_2(\mathbf{X})$	判别归类
11	中国	160.9455	185.4252	2
12	罗马尼亚	202.2739	219.5939	2
13	希腊	329.3008	319.0073	1

样品号	国家	$T_1(\mathbf{X})$	$T_2(\mathbf{X})$	原类号	回判类别
1	美国	326.2073	315.6630	1	1
2	日本	345.9698	333.2735	1	1
3	瑞士	337.7240	325.8926	1	1
4	阿根廷	298.3032	291.4929	1	1
5	阿联酋	307.7082	298.8939	1	1
6	保加利亚	258.5374	261.0097	2	2
7	古巴	254.2452	261.3358	2	2
8	巴拉圭	221.8201	232.6049	2	2
9	格鲁吉亚	202.9712	221.3502	2	2
10	南非	191.8280	203.8027	2	2

回判结果表明, 误判概率为0.

♠ 多个总体的Bayes判别问题

问题: 设有 k 个总体 $G_1, G_2, \dots, G_k$, 各自出现的概率为 $q_1, q_2, \dots, q_k$, 密度函数为 $f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_k(\mathbf{x})$. 对于一个新样品 $\mathbf{X}$, 判断它来自哪个总体?

想法: 计算后验概率

$$P(j|\mathbf{X}) = \frac{q_j f_j(\mathbf{X})}{\sum_{i=1}^k q_i f_i(\mathbf{X})}, \quad j = 1, 2, \dots, k$$

令 $Y_j(\mathbf{X}) = q_j f_j(\mathbf{X}) (j = 1, 2, \dots, k)$, 则判别准则为

$$\text{判 } \mathbf{X} \in G_i, \quad \text{如果 } Y_i(\mathbf{X}) = \max_{1 \leq j \leq k} Y_j(\mathbf{X})$$

♣ 练习: 设三个总体 G_1, G_2 和 G_3 的分布分别为: $N(2, 0.5^2)$, $N(0, 2^2)$ 和 $N(3, 1^2)$. 按 Bayes 判别准则样品 $x = 2.5$ 应判归哪一类? (假设 $q_1 = q_2 = q_3 = 1/3$, $\ln 2 = 0.6931$)

分析:

$$R_j(\mathbf{x}) = \ln q_j - \frac{1}{2} \ln |\Sigma_j| - \frac{1}{2} (\mathbf{x} - \mu_j)' \Sigma_j^{-1} (\mathbf{x} - \mu_j) \quad (j = 1, 2, 3)$$

一维时,

$$R_j(x) = \ln q_j - \frac{1}{2} \ln(\sigma_j^2) - \frac{1}{2} (x - \mu_j)^2 / \sigma_j^2 \quad (j = 1, 2, 3)$$

本例中, $q_1 = q_2 = q_3 = 1/3$, 只需比较

$$R_j(x) = -\frac{1}{2} \ln(\sigma_j^2) - \frac{1}{2} (x - \mu_j)^2 / \sigma_j^2 \quad (j = 1, 2, 3).$$

$$R_1(x) = -\frac{1}{2} \ln(0.5^2) - \frac{1}{2} \times \frac{(2.5 - 2)^2}{0.5^2} = \ln 2 - 0.5 = 0.1931$$

$$R_2(x) = -\frac{1}{2} \ln 2^2 - \frac{1}{2} \times \frac{(2.5 - 0)^2}{2^2} = -\ln 2 - 0.78125 = -1.4744$$

$$R_3(x) = -\frac{1}{2} \ln 1^2 - \frac{1}{2} \times \frac{(2.5 - 3)^2}{1^2} = -\frac{1}{2} \times 0.5^2 = -0.125$$

因为 $R_1 = \max_{1 \leq i \leq 3} R_i$, 故判 $x \in G_1$.

Bayes判别基于误判平均损失的基本思想

$c(2|1)$: 属于G1的样品误判为G2造成的损失

对 G_1 误判的平均损失: $l(1, R) = C(2|1)P(2|1, R)$

$P(2|1, R)$: 准则R下, 属于G1的样品误判为G2的概率

对 G_2 误判的平均损失: $l(2, R) = C(1|2)P(1|2, R)$

关于先验分布 p_1, p_2 , 误判造成的平均损失为:

$$\begin{aligned} L(R) &= p_1 l(1, R) + p_2 l(2, R) \\ &= C(2|1)p_1 P(2|1, R) + C(1|2)p_2 P(1|2, R) \end{aligned}$$

Bayes判别基于误判平均损失的基本思想

使平均损失 L 最小的最优划分为:

是2的误判为1时, 损失较小, 设为归属类

$$\begin{cases} R_1 = \{x : C(2|1)p_1f_1(x) \geq C(1|2)p_2f_2(x)\} \\ R_2 = \{x : C(2|1)p_1f_1(x) < C(1|2)p_2f_2(x)\} \end{cases}$$



$$\begin{cases} R_1 = \{x : C(2|1)P(G_1|x) \geq C(1|2)P(G_2|x)\} \\ R_2 = \{x : C(2|1)P(G_1|x) < C(1|2)P(G_2|x)\} \end{cases}$$

$$\begin{cases} R_1 = \{\mathbf{x} : c(2|1)P(G_1 | \mathbf{x}) \geq c(1|2)P(G_2 | \mathbf{x})\} \\ R_2 = \{\mathbf{x} : c(2|1)P(G_1 | \mathbf{x}) < c(1|2)P(G_2 | \mathbf{x})\} \end{cases}$$

当 $p_1 = p_2$ 时, 有 先验概率相等

$$\begin{cases} R_1 = \{\mathbf{x} : c(2|1)f_1(\mathbf{x}) \geq c(1|2)f_2(\mathbf{x})\} \\ R_2 = \{\mathbf{x} : c(2|1)f_1(\mathbf{x}) < c(1|2)f_2(\mathbf{x})\} \end{cases}$$

当 $p_1 = p_2$, 且时 $c(1|2) = c(2|1) = c$, 有

$$\begin{cases} R_1 = \{\mathbf{x} : f_1(\mathbf{x}) \geq f_2(\mathbf{x})\} \\ R_2 = \{\mathbf{x} : f_1(\mathbf{x}) < f_2(\mathbf{x})\} \end{cases}$$
误判损失相等

相当于经典统计学中的似然比准则判别。